Technische Hochschule Augsburg

Fakultät für Informatik

Thesis

zur Erlangung des Grades
Bachelor of Engineering in Mathematik

Proximitätssuche von EPLAN-Makros auf Basis des LambdaRank-Algorithmus

erstellt von Andreas Alstetter

Andreas Alstetter

Pfarrer-Kempter Str. 4
89358 Kammeltal/Behlingen
T +49 3141-5926
andreas.alstetter@tha.de

Matrikelnummer:
2147455

Technische Hochschule Augsburg

An der Hochschule 1
D-86161 Augsburg
T +49 821 5586-0
F +49 821 5586-3222
www.tha.de
info@tha.de

Erstprüfer	Prof. Dr. Thomas Kirchmeier
Zweitprüfer	Prof. Dr. Jürgen Grinninger
Themenvergabe am	1. September 2026
Eingereicht am	1. September 2026
Geheimhaltungsvereinbarung	Nein

Inhaltsverzeichnis

1 Motivation 2

2 Stand der Technik 4
- 2.1 Einordnung des Systems . . . 4
- 2.2 Kandidatenretrieval mittels BM25 . . . 6
  - 2.2.1 BM25 als Relevanzsignal . . . 6
  - 2.2.2 Grundidee von BM25 . . . 6
  - 2.2.3 Bedeutung in modernen Rankingarchitekturen . . . 7
- 2.3 Rank Fusion mittels Reciprocal Rank Fusion . . . 7
- 2.4 Feature Engineering . . . 8
- 2.5 Learning-to-Rank mit LambdaMART . . . 8
  - 2.5.1 Learning-to-Rank . . . 8
  - 2.5.2 Von RankNet zu LambdaMART . . . 9
  - 2.5.3 Gradient Boosted Decision Trees . . . 9
- 2.6 Mehrstufiges Ranking und Re-Ranking . . . 10
- 2.7 Makroaggregation und Rank Aggregation . . . 10
- 2.8 Evaluierung von Retrieval- und Ranking-Systemen . . . 11
  - 2.8.1 Recall@K . . . 11
  - 2.8.2 Discounted Cumulative Gain . . . 11
  - 2.8.3 Normalized Discounted Cumulative Gain . . . 11
  - 2.8.4 Hierarchical nDCG . . . 12
  - 2.8.5 Candidate Coverage . . . 12
  - 2.8.6 Data Leakage Detection . . . 12

3 Verwandte industrielle Systeme 13
- 3.1 Einordnung industrieller Retrieval- und Ranking-Systeme . . . 13
- 3.2 Microsoft Bing . . . 13
- 3.3 Azure AI Search . . . 14
- 3.4 Elasticsearch Learning-to-Rank . . . 14
- 3.5 Apache Solr Learning-to-Rank . . . 15
- 3.6 Amazon Produktsuche . . . 16
- 3.7 eBay Cassini . . . 16
- 3.8 Vergleich der Systeme . . . 17
- 3.9 Zusammenfassung . . . 17

4 Zielsetzung und Vorgehensweise 18

5 Analyse der Makrostrukturen und Ableitung eines Trainingsformats 19

6 Prototypische Umsetzung 20

7 Evaluierungskonzept und Ergebnisse 21

8 Diskussion, Grenzen und Ausblick 22

9 Zusammenfassung und Fazit 23

Literaturverzeichnis 27

1 Motivation

Die zunehmende Digitalisierung von industriellen Prozessen führt zu einer immer größer werdenden Menge an Prozess- und Produktdaten. Die Informationen liegen dabei oft in strukturierter und unstrukturierter Form wie Datenblätter, Produktbeschreibungen sowie Spezifikationen vor. Im gleichen Zuge steigt die Bedeutung von datengetriebenen Methoden für die Innovations- und Wettbewerbsfähigkeit in Deutschland. KI und dessen Potential die Daten sowie das Know-How der Industrie 4.0 zu nutzen, schafft somit den Grundstein um diese Herausforderung für die Industrie und deren Systeme zu meistern. Bundesministerium für Wirtschaft und Energie 2026.

Im Anlagen- sowie Maschinenbau entsteht durch die Variantenvielfalt technischer Komponenten eine besondere Herausforderung. Dabei werden von Unternehmen einerseits häufig umfangreiche Artikelbestände verwaltet, die eine Vielzahl an technischen Merkmalen beinhalten, während andernseits große Mengen an Dokumentationen und Datenblättern vorliegen. Eine Auswahl geeigneter Komponenten sowie die Artikelzuordnung zu standardisierten Lösungen erfolgt oftmals auf Basis von manueller Recherche und Erfahrung einzelner Mitarbeiter. Dadurch entsteht ein hoher Bearbeitungsaufwand, geringere Skalierbarkeit und eine hohen Abhängigkeit von Expertenwissen. Pfenning 2022.

Arbeiten aus der Wissenschaft zeigen, dass zur erfolgreichen Wissensextraktion, Automatisierung und Entscheidungsfindung KI-Verfahren in industirellen Prozessen eingesetzt werden. Einer der zentralen Punkte ist dabei die Extraktion von Informationen und Wissen aus aus heterogenen Datenquellen sowie die anschließende Nutzung dieser Extraktion für die technische Entscheidungsfindung. Als bewährter Ansatz hierfür eignen sich Empfehlungssysteme, die den Anwender dabei unterstützen, die am besten geeigneten Optionen für einen konkreten Anwendugsfall aus einer Vielzahl an Alternativen zu finden. Die Urspüngliche Verwendung solcher Systeme aus dem E-Commerce-Bereich, werden zunehmend auch im Industriellen Kontext angewendet, wie zum Beispiel bei der Auswahl von Produkten, Konfigurationen oder der erneuten Verwendung von Systemen. Joshi u. a. 2024.

Auf Basis dieser Recherche ergibt sich ein erhebliches Potential für ein KI-basiertes Empfehlungssystem zur automatisierten Zuordnung von EPLAN-Artikeln EPLAN GmbH & Co. KG 2026 zu EPLAN-Fenstermakros. EPLAN GmbH & Co. KG 2025. Hierfür notwendige Informationen sind bereits in den vorhandenen EPLAN-Artikeln EPLAN GmbH & Co. KG 2026 sowie den zugehörigen Datenblättern enthalten, werden aber für die automatisierte Verarbeitung bislang nur unzureichend genutzt. Die intelligente Auswertung dieser strukturierten und unstrukturierten Daten bietet die Grundlage für die Erkennung relevanter Zusammenhänge und die Empfehlung passendender EPLAN-Fenstermakros. EPLAN GmbH & Co. KG 2025. Hierdurch wird der manuelle

Aufwand entscheidend reduziert, sowie das vorhandene Unternehmenswissen besser genutzt und für eine konsistentere Entscheidungsfindung verwendet. Das Projekt leiste somit einen Beitrag zur praktischen Umsetzung von datengetriebenen und KI-Unterstützen Entscheidungen im Industrie 4.0 Umfeld. Nayak 2025.

2 Stand der Technik

2.1 Einordnung des Systems

Die automatische Zuordnung technischer EPLAN-Artikel EPLAN GmbH & Co. KG 2026 zu EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 ist eine komplexe Problemstellung, welche durch die Kombination von Information-Retrieval (IR), maschinellen Lernens und Learning-to-Rank-Methoden (LTR) behandelt werden kann. Das Ziel besteht darin, nach einer Systemanfrage mittels Datenblatt aus einer großen Menge an potentiellen EPLAN-Artikeln EPLAN GmbH & Co. KG 2026 diejenigen zu identifizieren, die auf Basis ihrer technischen Eigenschaften ein EPLAN-Fenstermakro EPLAN GmbH & Co. KG 2025 am besten repräsentieren. Hierbei muss dann eine Rangfolge erstellt werden, welche die EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 die die höchste Relevanz für ein Suchanfrage besitzen an die Spitze der Ergebnisliste setzt.

Solche Rankingporblem treten in einer Vielzahl von Anwendungsfällen auf, wie zum Beispiel in Suchmaschinen, Produktempfehlungen oder Enterprise-Search-Systemen. Die Bewertung durch ein komplexes Rankingmodell wird dabei schnell unübersichtlich und bietet weniger Raum für Analysen und Interpretationen. Stattdessen haben sich mehrstufige Architekturen etabliert, die zu Beginn eine schnelle Kandidatenselektion durchführen und im Anschluss ein Rankingmodell auf die selektierten Kandidaten anwenden. Dieses Konzept wird in der Literatur als *Candidate Generation* und *Learning-to-Rank* bezeichnet Robertson und Zaragoza 2009; Liu 2009; Burges 2010. Teile davon werden für diese Arbeit übernommen und in abgeändeter Form für die Trainingsvorbereitung sowie das eigentliche Rankingmodell verwendet.

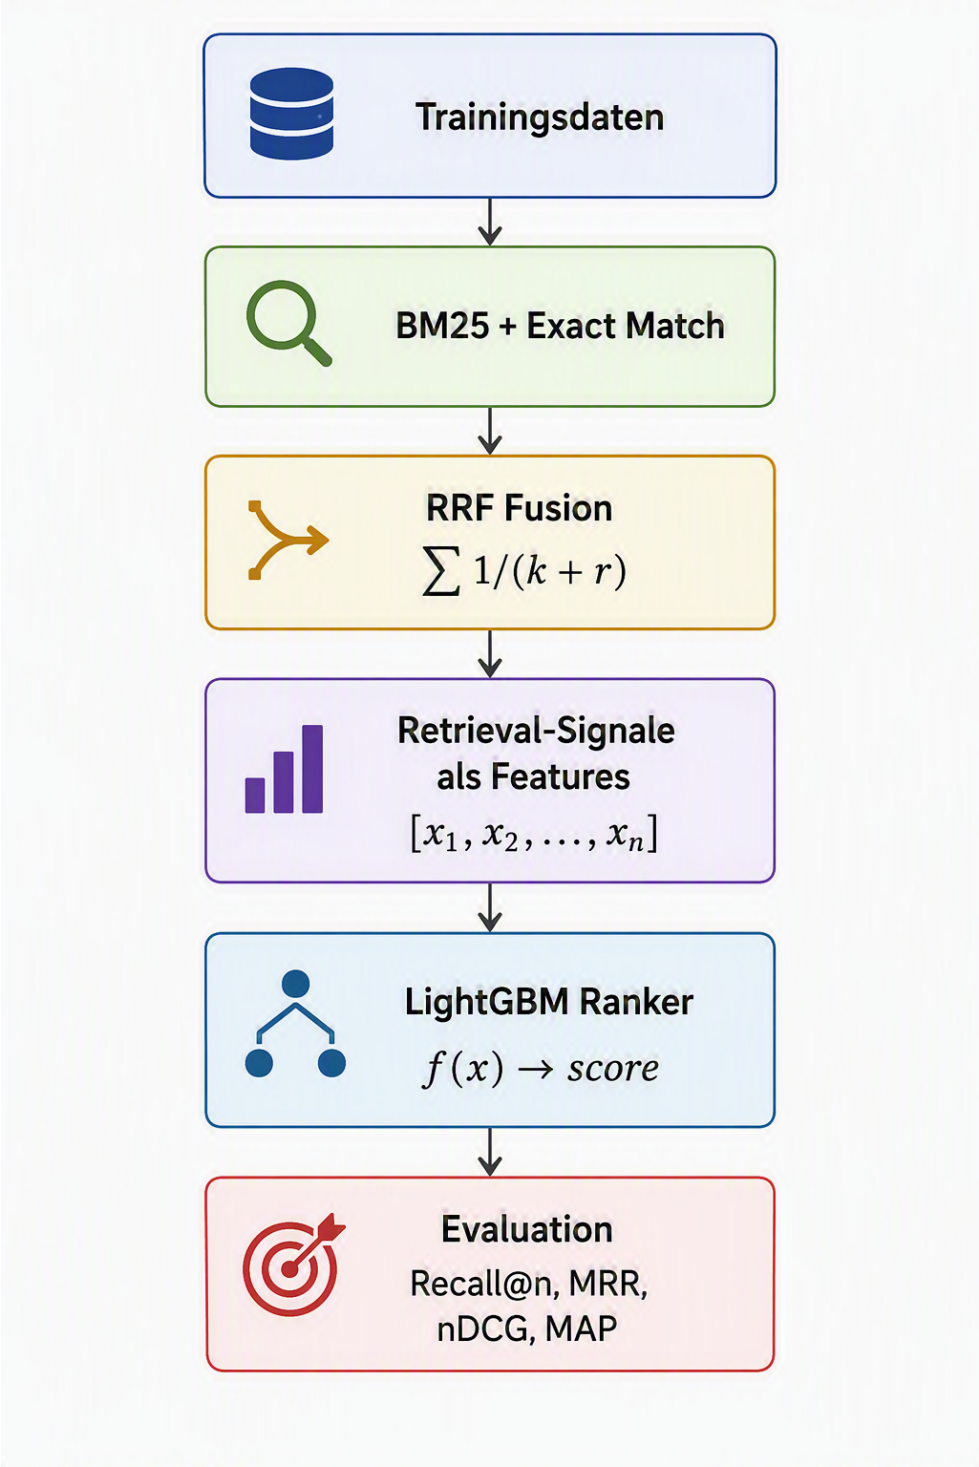


Abbildung 2.1: Architektur der System-Pipeline

Im E-Comerce Bereich werden mehrstufige Architekturen bereits seit Jahren erfolgreich eingesetzt,

um die Relevanz von Suchergebnissen und Empfehlungen zu verbessern. Aktuelle Untersuchungen in diesem Bereich zeigen, dass Produktsuchen großer Plattformen wie Amazon, eBay oder Alibaba weiterhin stark auf mehrstufige Retrievalpipelines, strukturierte Merkmale, und Learning-to-Rank-Verfahren setzen. Kabir u. a. 2024.

2.2 Kandidatenretrieval mittels BM25

2.2.1 BM25 als Relevanzsignal

Ein Bestandteil des vorgestellten Systems ist die Nutzung lexikalischer Retrievalsignale zur Beschreibung der Ähnlichkeit zwischen einer Anfrage und einem potentiellen EPLAN-Artikel EPLAN GmbH & Co. KG 2026. Hier für wird unter anderem der BM25-Algorithmus verwendet, welcher ein etabliertes Verfahren im Bereich des Information Retrieval darstellt Robertson und Zaragoza 2009. Anders als in klassischen Suchmaschinen, wird BM25 hier nicht als weitere Rankingstufe verwendet, sondern als eines von mehreren Signalen, die dem Learning-to-Rank-Modell als Eingabe dienen. Die Aufgabe von diesem Algorithmus besteht deswegen darin, der Trainings-Kandidatenmenge ein erstes Relevanzsignal zu geben, um dadurch dem späteren Rankingmodell einen bewussten Bias in Richtung möglicher Query-Anfragen zu geben.

2.2.2 Grundidee von BM25

BM25 basiert auf dem Probabilistic Relevance Framework von Robertson und Zaragoza. Dabei wird für jedes Anfrage-Dokument-Paar einen Relevanzwert bestimmt Robertson und Zaragoza 2009.

Die Grundannahme besteht darin, dass ein Dokument umso relevanter ist,

- je häufiger relevante Suchbegriffe darin vorkommen,
- je seltener diese Begriffe innerhalb der Gesamtdokumentensammlung auftreten,
- und je besser die Dokumentlänge berücksichtigt wird.

Dadurch erlangen seltene und spezifische Begriffe eine höhere Gewichtung, während häufige Begriffe wie ünd", öderöder "der"weniger Einfluss auf die Relevanzbewertung haben. Bei technischen Produktdaten ist dies besonders relevant, Artikelnummern, Typenbezeichnungen oder normierte Fachbegriffe häufig eine hohe Differenzierungskraft besitzen.

$$Score(D,Q) = \sum_{i=1}^{n} IDF(q_i) \cdot \frac{f(q_i,D)(k_1+1)}{f(q_i,D) + k_1\left(1 - b + b\frac{|D|}{avgdl}\right)} \tag{2.1}$$

Die einzelnen Parameter besitzen folgende Bedeutung:

q_i Suchbegriff der Anfrage
$f(q_i, D)$ Häufigkeit des Begriffs q_i im Dokument
$|D|$ Dokumentlänge
$avgdl$ durchschnittliche Dokumentlänge aller Dokumente
k_1 Parameter zur Steuerung der Termfrequenzsättigung
b Parameter zur Dokumentlängennormalisierung
$IDF(q_i)$ inverse Dokumenthäufigkeit

Die inverse Dokumenthäufigkeit wird durch

$$IDF(q_i) = \log \frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} \tag{2.2}$$

mit

N Gesamtzahl aller Dokumente
$n(q_i)$ Anzahl der Dokumente, welche den Begriff q_i enthalten

berechnet.

Die resultierende Kennzahl stellt somit einen Relevanzscore dar, die die lexikalische Ähnlichkeit zwischen einer Anfrage und einem Kandidaten beschreibt.

2.2.3 Bedeutung in modernen Rankingarchitekturen

Trotz der zunehmenden Verbreitung von Deep-Learning-basierten Ansätzen im Information Retrieval, bleibt BM25 ein weit verbreitetes und effektives Verfahren. Aktuelle Studien zeigen, dass BM25 insbesondere bei Domänenspezifischen Datensätzen und als Basis für Learning-to-Rank-Modelle weiterhin eine hohe Relevanz besitzt Thakur u. a. 2021.

2.3 Rank Fusion mittels Reciprocal Rank Fusion

Mehrere Retrievalverfahren erzeugen typischerweise unterschiedliche Ranglisten. Zur Zusammenführung dieser Ergebnisse wird Reciprocal Rank Fusion (RRF) verwendet Cormack u. a. 2009. RRF bewertet ein Dokument anhand seiner Position in mehreren Ranglisten:

$$RRF(d) = \sum_{r \in R} \frac{1}{k + r(d)} \tag{2.3}$$

mit

R Menge aller Ranglisten
$r(d)$ Rangposition des Dokuments
k Glättungskonstante (typischerweise $k = 60$)

Im Gegensatz zu scorebasierten Fusionsverfahren sind die ursprünglichen Retrievalscores nicht erforderlich. Ausschließlich die Rangposition wird berücksichtigt. Dies ermöglicht die Fusion heterogener Retrievalmethoden und führt nachweislich zu robusteren Suchergebnissen als die isolierte Nutzung einzelner Verfahren Cormack u. a. 2009. Rank-Fusion-Verfahren finden Anwendung in:

- Suchmaschinen
- Meta-Suchsystemen
- Enterprise Search
- Produktsuchen

2.4 Feature Engineering

Nach der Kandidatengenerierung werden strukturierte Merkmale für Anfrage-Kandidaten-Paare erzeugt. Typische Merkmale sind:

- Dimensionsdifferenzen
- technische Eigenschaftsabweichungen
- numerische Distanzmaße
- binäre Matching-Merkmale
- Kategorien- und Familienübereinstimmungen

Feature Engineering stellt seit den LETOR-Datensätzen die dominante Vorgehensweise für Learning-to-Rank-Systeme auf strukturierten Daten dar Liu 2009. Insbesondere in technischen Produktkatalogen und E-Commerce-Systemen besitzen explizit modellierte Merkmale häufig eine höhere Aussagekraft als rein semantische Repräsentationen Liu 2009.

2.5 Learning-to-Rank mit LambdaMART

2.5.1 Learning-to-Rank

Learning-to-Rank bezeichnet Verfahren, die die Reihenfolge einer Ergebnisliste optimieren. Hierbei wird nicht lediglich eine Klassifikation durchgeführt, sondern die Anordnung einer gesamten Dokumentmenge bewertet Liu 2009.

2.5.2 Von RankNet zu LambdaMART

Burges beschreibt die Entwicklung von RankNet über LambdaRank bis LambdaMART als zentrale Evolution moderner Rankingverfahren Burges 2010. Für zwei Dokumente i und j wird zunächst eine Paarwahrscheinlichkeit definiert:

$$P_{ij} = \frac{1}{1 + e^{-\sigma(s_i - s_j)}} \tag{2.4}$$

mit

s_i Score von Dokument i
s_j Score von Dokument j
σ Steigungsparameter

Der Paarverlust ergibt sich zu

$$L_{ij} = -\log(P_{ij}) \tag{2.5}$$

LambdaRank erweitert diesen Ansatz um Gradienten, die proportional zur Veränderung einer Rankingmetrik wie nDCG gewichtet werden. LambdaMART kombiniert diese Idee mit Gradient Boosted Decision Trees und zählt bis heute zu den leistungsfähigsten Verfahren für tabellarische Rankingdaten Burges 2010; Lyzhin u. a. 2023.

2.5.3 Gradient Boosted Decision Trees

Das Gesamtmodell ergibt sich aus der Summe einzelner Entscheidungsbäume:

$$F(x) = \sum_{m=1}^{M} \gamma_m h_m(x) \tag{2.6}$$

mit

$h_m(x)$ Entscheidungsbaum
γ_m Gewichtung des Baumes
M Anzahl der Bäume

2.6 Mehrstufiges Ranking und Re-Ranking

Moderne Informationssysteme verwenden typischerweise mehrere Rankingstufen Zhang u. a. 2021. Die erste Stufe maximiert den Recall und erzeugt einen breiten Kandidatenpool. Die zweite Stufe verwendet aufwendigere Merkmale und Modelle zur Verbesserung der Präzision. Ein typischer Ablauf lautet:

1. Retrieval (BM25)
2. Candidate Set
3. Learning-to-Rank
4. Re-Ranking

Derartige Architekturen werden unter anderem in:

- Websuchmaschinen
- Produktsuchen
- Enterprise Search
- Empfehlungssystemen

eingesetzt Zhang u. a. 2021.

2.7 Makroaggregation und Rank Aggregation

Mehrere Artikel können Evidenz für dieselbe Makroklasse liefern. Daher werden Rankingergebnisse aggregiert. Rank Aggregation beschäftigt sich mit der Zusammenführung mehrerer Ranglisten zu einer Gesamtliste Dwork u. a. 2001.

Anwendungen umfassen:

- Suchmaschinen
- Abstimmungssysteme
- Empfehlungssysteme
- Produktrankings

Typische Strategien sind:

- Best-Item-Prinzip
- Mehrheitsentscheidungen
- gewichtetes Voting
- Evidenzaggregation

2.8 Evaluierung von Retrieval- und Ranking-Systemen

2.8.1 Recall@K

Recall gehört zu den grundlegenden Metriken des Information Retrieval Manning u. a. 2008.

$$Recall@K = \frac{\text{\# relevante Treffer in Top-K}}{\text{\# relevante Treffer}} \tag{2.7}$$

Im vorliegenden System werden insbesondere

- target_recall@1
- target_recall@3
- target_recall@5
- target_recall@10

sowie Family-Recall-Metriken verwendet.

2.8.2 Discounted Cumulative Gain

Järvelin und Kekäläinen führten DCG und nDCG zur Bewertung gewichteter Ranglisten ein Järvelin und Kekäläinen 2002.

$$DCG@K = \sum_{i=1}^{K} \frac{2^{rel_i} - 1}{\log_2(i+1)} \tag{2.8}$$

mit

rel_i Relevanz am Rangplatz i

2.8.3 Normalized Discounted Cumulative Gain

Die Normalisierung erfolgt mittels

$$nDCG@K = \frac{DCG@K}{IDCG@K} \tag{2.9}$$

Der Wertebereich liegt zwischen 0 und 1.

2.8.4 Hierarchical nDCG

Für technische Katalogsysteme besitzen Fehler unterschiedliche Schweregrade. Daher wird eine hierarchische Relevanzfunktion verwendet:

$$rel = \begin{cases} 3 & \text{exaktes Ziel} \\ 2 & \text{gleiche Familie} \\ 0 & \text{sonst} \end{cases} \tag{2.10}$$

Diese Erweiterung erlaubt die differenzierte Bewertung von Variantenfehlern innerhalb derselben Produktfamilie.

2.8.5 Candidate Coverage

Die Candidate Coverage bewertet die maximale Leistungsfähigkeit des Retrievalsystems vor dem eigentlichen Ranking. Hierbei wird gemessen, ob sich das korrekte Ziel überhaupt im Kandidatenpool befindet.

2.8.6 Data Leakage Detection

Kaufman et al. definieren Data Leakage als unbeabsichtigte Nutzung von Informationen, die zum Zeitpunkt der Vorhersage nicht verfügbar sein dürfen Kaufman u. a. 2012. Die Verhinderung von Leakage stellt eine zentrale Voraussetzung für valide Evaluierungen und reproduzierbare Modellqualität dar.

3 Verwandte industrielle Systeme

3.1 Einordnung industrieller Retrieval- und Ranking-Systeme

Die im vorliegenden Projekt eingesetzte Architektur basiert auf etablierten Verfahren des Information Retrieval und Learning-to-Rank. Vergleichbare Architekturen finden sich seit vielen Jahren in Suchmaschinen, Enterprise-Search-Plattformen, Produktsuchen sowie Empfehlungssystemen. Obwohl moderne Systeme zunehmend neuronale Verfahren und Vektorsuchen integrieren, bilden die in Kapitel 2 beschriebenen Komponenten weiterhin einen wesentlichen Bestandteil produktiver Suchsysteme. Insbesondere die Kombination aus

- Kandidatenretrieval,
- Rank Fusion,
- Feature Engineering,
- Learning-to-Rank,
- Re-Ranking sowie
- Ergebnisaggregation

stellt bis heute die dominierende Architektur vieler industrieller Retrievalsysteme dar.

3.2 Microsoft Bing

Microsoft Bing gilt als eines der bekanntesten produktiven Learning-to-Rank-Systeme und spielte eine zentrale Rolle bei der Entwicklung der RankNet-, LambdaRank- und LambdaMART-Verfahren Burges 2010. Die Bing-Sucharchitektur besteht aus mehreren aufeinanderfolgenden Retrieval- und Rankingstufen:

1. Candidate Retrieval
2. Feature Extraction
3. Learning-to-Rank
4. Re-Ranking
5. Ergebnispräsentation

Die initiale Kandidatenselektion erfolgt mithilfe effizienter Retrievalverfahren. Die erzeugten Kandidaten werden anschließend durch eine Vielzahl strukturierter Merkmale beschrieben. Ein

Learning-to-Rank-Modell berechnet daraus eine Relevanzbewertung. Die grundlegende Architektur entspricht damit dem folgenden Aufbau:

$$Query \rightarrow Retrieval \rightarrow Feature\ Extraction \rightarrow LTR \rightarrow Ranking \tag{3.1}$$

Dieses Architekturprinzip bildet die Grundlage zahlreicher moderner Suchmaschinen.

3.3 Azure AI Search

Azure AI Search stellt die Enterprise-Search-Plattform von Microsoft dar. Das System kombiniert mehrere Retrievalverfahren innerhalb einer Hybrid-Search-Architektur. Dabei werden unterschiedliche Suchverfahren parallel ausgeführt und anschließend durch Rank-Fusion zusammengeführt. Die Architektur umfasst typischerweise:

- Volltextsuche auf Basis von BM25,
- semantische Suchverfahren,
- Hybrid Search,
- Rank Fusion mittels Reciprocal Rank Fusion,
- zusätzliches Re-Ranking.

Die verwendete Rank-Fusion basiert auf demselben RRF-Verfahren, das durch Cormack et al. beschrieben wurde Cormack u. a. 2009. Im Gegensatz zur klassischen Vektorsuche besitzt dieser Ansatz den Vorteil, dass sowohl exakte Merkmalstreffer als auch ähnliche Dokumente berücksichtigt werden können. Anwendungsbereiche umfassen:

- technische Dokumentensuche,
- Wissensdatenbanken,
- Produktkataloge,
- Serviceportale,
- unternehmensweite Dokumentensuche.

3.4 Elasticsearch Learning-to-Rank

Elasticsearch zählt zu den am weitesten verbreiteten Suchplattformen im industriellen Umfeld. Die optionale Learning-to-Rank-Erweiterung implementiert nahezu dieselbe Architektur wie das vorliegende Projekt:

1. BM25-Kandidatenretrieval
2. Merkmalsextraktion
3. Learning-to-Rank-Modell

4. Re-Ranking der Kandidatenliste

Das zugrunde liegende Modell wird üblicherweise außerhalb von Elasticsearch trainiert und anschließend als Rankingmodell eingebunden. Typische Merkmale umfassen:

- Termstatistiken,
- BM25-Scores,
- Dokumentattribute,
- Kategoriesignale,
- numerische Ähnlichkeitsmaße.

Die resultierende Architektur entspricht praktisch dem klassischen LETOR-Ansatz nach Liu Liu 2009. Einsatzgebiete finden sich insbesondere in

- E-Commerce-Plattformen,
- Produktkatalogen,
- Dokumentensuchen,
- technischen Wissensdatenbanken.

3.5 Apache Solr Learning-to-Rank

Apache Solr implementiert ein Learning-to-Rank-Framework, welches ähnlich wie Elasticsearch aufgebaut ist. Die Pipeline besteht aus:

1. Dokumentretrieval,
2. Featuregenerierung,
3. Rankingmodell,
4. Re-Ranking.

Unterstützt werden unter anderem:

- Gradient Boosted Trees,
- LambdaMART,
- externe Machine-Learning-Modelle.

Solr wird häufig eingesetzt für:

- E-Commerce,
- Produktfindung,
- Unternehmenssuche,
- Wissensmanagementsysteme.

Die technische Nähe zum vorliegenden Projekt ist insbesondere bei der Nutzung expliziter strukturierter Merkmale sehr hoch.

3.6 Amazon Produktsuche

Die Produktsuche von Amazon zählt zu den bekanntesten kommerziellen Suchsystemen. Aufgrund der Größe des Produktkataloges müssen Suchanfragen in mehreren Stufen verarbeitet werden. Typischerweise erfolgt:

1. schnelles Kandidatenretrieval,
2. Ranking über Produktmerkmale,
3. Personalisierung,
4. Re-Ranking.

Für Produktsuchen besitzen strukturierte Merkmale eine besondere Bedeutung:

- Kategorie,
- Hersteller,
- technische Eigenschaften,
- Preise,
- Verfügbarkeit,
- Produktspezifikationen.

Somit ähneln Produktsuchen dem hier betrachteten technischen Artikel-Makro-Matching wesentlich stärker als allgemeine Websuchmaschinen. Insbesondere das intensive Feature Engineering und die Nutzung Gradient-Boosted-Tree-basierter Rankingverfahren gelten in Produktsuchen seit vielen Jahren als etablierter Standard.

3.7 eBay Cassini

Cassini ist die Suchplattform von eBay. Das System nutzt eine mehrstufige Rankingpipeline zur Bewertung von Produktangeboten. Berücksichtigt werden unter anderem:

- Suchbegriffe,
- Kategorien,
- Angebotsattribute,
- Verkaufsmetriken,
- Qualitätsindikatoren.

Die Architektur folgt ebenfalls dem Retrieval- und Re-Ranking-Paradigma und nutzt zahlreiche strukturierte Merkmale zur Bestimmung der Ergebnisreihenfolge. Damit weist Cassini starke Parallelen zu klassischen Learning-to-Rank-Systemen auf.

3.8 Vergleich der Systeme

Die Tabelle zeigt die Ähnlichkeit zwischen den betrachteten industriellen Systemen und der entwickelten Architektur.

Tabelle 3.1: Vergleich industrieller Suchsysteme

System	BM25	RRF	LTR	Re-Ranking	Aggregation
Bing	✓	-	✓	✓	✓
Azure AI Search	✓	✓	✓	✓	-
Elasticsearch LTR	✓	-	✓	✓	-
Apache Solr LTR	✓	-	✓	✓	-
Amazon Search	✓	-	✓	✓	-
eBay Cassini	✓	-	✓	✓	-
Vorliegendes System	✓	✓	✓	✓	✓

3.9 Zusammenfassung

Die Analyse verwandter industrieller Systeme zeigt, dass die entwickelte Architektur keinen experimentellen Ansatz darstellt, sondern auf etablierten Retrieval- und Rankingverfahren basiert. Insbesondere die Kombination aus

- BM25-Retrieval,
- Rank Fusion mittels RRF,
- strukturierter Merkmalsextraktion,
- LambdaMART-basiertem Learning-to-Rank,
- mehrstufigem Re-Ranking sowie
- Evidenzaggregation

entspricht einem Architekturmuster, das seit vielen Jahren in Suchmaschinen, Produktsuchen und Enterprise-Search-Systemen erfolgreich eingesetzt wird. Die entwickelte Lösung kann daher als fachlich fundierte, industriell etablierte und wissenschaftlich abgesicherte Retrieval- und Rankingarchitektur eingeordnet werden.

4 Zielsetzung und Vorgehensweise

5 Analyse der Makrostrukturen und Ableitung eines Trainingsformats

6 Prototypische Umsetzung

7 Evaluierungskonzept und Ergebnisse

8 Diskussion, Grenzen und Ausblick

9 Zusammenfassung und Fazit

Erklärung zur Abschlussarbeit

Hiermit versichere ich, die eingereichte Abschlussarbeit selbständig verfasst und keine andere als die von mir angegebenen Quellen und Hilfsmittel benutzt zu haben. Wörtlich oder inhaltlich verwendete Quellen wurden entsprechend den anerkannten Regeln wissenschaftlichen Arbeitens zitiert. Ich erkläre weiterhin, dass die vorliegende Arbeit noch nicht anderweitig als Abschlussarbeit eingereicht wurde. Das Merkblatt zum Täuschungsverbot im Prüfungsverfahren der Hochschule Augsburg habe ich gelesen und zur Kenntnis genommen. Ich versichere, dass die von mir abgegebene Arbeit keinerlei Plagiate, Texte oder Bilder umfasst, die durch von mir beauftragte Dritte erstellt wurden.

Augsburg, den 1. September 2026

_____

Andreas Alstetter

Abbildungsverzeichnis

2.1 Architektur der System-Pipeline 5

Tabellenverzeichnis

3.1 Vergleich industrieller Suchsysteme 17

Literaturverzeichnis

Bundesministerium für Wirtschaft und Energie (2026). *Wirtschaft und Forschung richten Plattform Industrie 4.0 auf industrielle KI aus*. Bundesministerium für Wirtschaft und Energie (siehe S. 2).

Burges, Christopher J. C. (2010). „From RankNet to LambdaRank to LambdaMART: An Overview“. In: *Microsoft Research Technical Report* (siehe S. 4, 9, 13).

Cormack, Gordon V., Charles L. A. Clarke und Stefan Büttcher (2009). „Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods“. In: *SIGIR 2009*, S. 758–759. DOI: 10.1145/1571941.1572114 (siehe S. 7, 8, 14).

Dwork, Cynthia, Ravi Kumar, Moni Naor und D. Sivakumar (2001). „Rank Aggregation Methods for the Web“. In: *WWW 2001*, S. 613–622 (siehe S. 10).

EPLAN GmbH & Co. KG (2025). *Makros*. EPLAN-Plattform Infoportal (siehe S. 2, 4).

EPLAN GmbH & Co. KG (2026). *Artikelverwaltung*. EPLAN-Hilfe (siehe S. 2, 4, 6).

Järvelin, Kalervo und Jaana Kekäläinen (2002). „Cumulated Gain-Based Evaluation of IR Techniques“. In: *ACM TOIS*. Bd. 20. 4, S. 422–446. DOI: 10.1145/582415.582418 (siehe S. 11).

Joshi, Tripuresh, Bhavesh Joshi, Karimulla Syed, S. Vijayarani, Sandeep Kumar und Naveen Naval (2024). „Industrial data analysis using Machine Learning Techniques“. In: *2024 IEEE North Karnataka Subsection Flagship International Conference (NKCon)*. IEEE. DOI: 10.1109/NKCon62728.2024.10774728 (siehe S. 2).

Kabir, Md. Ahsanul, Mohammad Al Hasan, Aritra Mandal, Daniel Tunkelang und Zhe Wu (2024). „A Survey on E-Commerce Learning to Rank“. In: *Procedia Computer Science* (siehe S. 6).

Kaufman, Shachar, Saharon Rosset und Claudia Perlich (2012). „Leakage in Data Mining: Formulation, Detection, and Avoidance“. In: *ACM Transactions on Knowledge Discovery from Data* 6.4. DOI: 10.1145/2382577.2382579 (siehe S. 12).

Liu, Tie-Yan (2009). „Learning to Rank for Information Retrieval“. In: *Foundations and Trends in Information Retrieval* 3.3, S. 225–331. DOI: 10.1561/1500000016 (siehe S. 4, 8, 15).

Lyzhin, Ivan, Aleksei Ustimenko, Andrey Gulin und Liudmila Prokhorenkova (2023). „Which Tricks Are Important for Learning to Rank?“ In: *Proceedings of ICML* (siehe S. 9).

Manning, Christopher D., Prabhakar Raghavan und Hinrich Schütze (2008). *Introduction to Information Retrieval*. Cambridge University Press (siehe S. 11).

Nayak, Srikumar (2025). „Enhancing Manufacturing with Artificial Intelligence: An Overview of the Present Situation, Insights, Recommended Practices, Obstacles and Future Trends“. In: *World Journal of Advanced Research and Reviews* 28.3, S. 009–019. DOI: 10.30574/wjarr.2025.28.3.4033 (siehe S. 3).

Pfenning, Michael (2022). *Wie Maschinenbauer die Variantenvielfalt beherrschen* (siehe S. 2).

Robertson, Stephen und Hugo Zaragoza (2009). „The Probabilistic Relevance Framework: BM25 and Beyond“. In: *Foundations and Trends in Information Retrieval* 3.4, S. 333–389. DOI: 10.1561/1500000019 (siehe S. 4, 6).

Thakur, Nandan, Nils Reimers, Andreas Rücklé, Abhishek Srivastava und Iryna Gurevych (2021). „BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models“. In: *NeurIPS Datasets and Benchmarks* (siehe S. 7).

Zhang, Yue, Chengcheng Hu, Yuqi Liu, Hui Fang und Jimmy Lin (2021). „Learning to Rank in the Age of Muppets: Effectiveness-Efficiency Tradeoffs in Multi-Stage Ranking“. In: *SustaiNLP 2021* (siehe S. 10).