Technische Hochschule Augsburg

Fakultät für Informatik

Thesis

zur Erlangung des Grades
Bachelor of Engineering in Mathematik

Proximitätssuche von EPLAN-Makros auf Basis des LambdaRank-Algorithmus

erstellt von Andreas Alstetter

Andreas Alstetter

Pfarrer-Kempter Str. 4
89358 Kammeltal/Behlingen
T +49 3141-5926
andreas.alstetter@tha.de

Matrikelnummer:
2147455

Technische Hochschule Augsburg

An der Hochschule 1
D-86161 Augsburg
T +49 821 5586-0
F +49 821 5586-3222
www.tha.de
info@tha.de

Erstprüfer	Prof. Dr. Thomas Kirchmeier
Zweitprüfer	Prof. Dr. Jürgen Grinninger
Themenvergabe am	3. September 2026
Eingereicht am	3. September 2026
Geheimhaltungsvereinbarung	Nein

Inhaltsverzeichnis

1 Motivation 2

2 Stand der Technik 4
- 2.1 Architektur- und Rankingansatz . . . 4
- 2.2 BM25 . . . 4
  - 2.2.1 Grundidee von BM25 . . . 4
  - 2.2.2 Bedeutung in modernen Rankingarchitekturen . . . 5
- 2.3 Exact-Match . . . 6
  - 2.3.1 Grundprinzip des Exact Matching . . . 6
  - 2.3.2 Bedeutung von Exact-Match im modernen Information Retrieval . . . 7
- 2.4 Fusion von Retrievalsignalen mittels Reciprocal Rank Fusion . . . 7
  - 2.4.1 Grundidee von Reciprocal Rank Fusion . . . 7
  - 2.4.2 Klassische RRF-Formulierung . . . 7
  - 2.4.3 Aktuelle Bedeutung von Rank-Fusion-Verfahren . . . 8
- 2.5 Learning-to-Rank mit LambdaRank . . . 8
  - 2.5.1 Grundprinzip von Learning-to-Rank . . . 8
  - 2.5.2 LambdaRank . . . 8
  - 2.5.3 LambdaMART und LightGBM . . . 9
  - 2.5.4 Aktuelle Bedeutung von LambdaMART . . . 10

3 Zielsetzung und Vorgehensweise 11
- 3.1 Zielsetzung . . . 11
- 3.2 Methodisches Vorgehen . . . 12
- 3.3 Iterativer Entwicklungsprozess . . . 12

4 Architekturübersicht 14
- 4.1 Gesamtarchitektur . . . 14

5 Analyse der Datenstrukturen und Ableitung eines Trainingsformats 16
- 5.1 Analyse der Ausgangsdaten . . . 16
- 5.2 Analyse der Makrostrukturen . . . 16
- 5.3 Aufbereitung der Artikeldaten . . . 17
- 5.4 Erstellung von Makrokandidatenprofilen . . . 18
- 5.5 Transformation in ein Rankingproblem . . . 18
- 5.6 Berechnung der Pairwise-Merkmale . . . 19

5.7 Erzeugung der Relevanzlabels . . . 20
5.8 Erstellung des Trainingsformats . . . 21
5.9 Vermeidung von Zielinformations-Leakage . . . 21

6 Datensplit und Training 23
6.1 Anforderrungen an die Datenbasis . . . 23
6.2 Datensplit und Trainingsbasis . . . 23
6.3 Aufbau der Retrievalsignale . . . 25
6.4 Training des Learning-to-Rank-Modells . . . 26
6.5 Hyperparameteroptimierung . . . 27
6.6 Modellartefakte und Reproduzierbarkeit . . . 28
6.7 Pipeline-Orchestrierung . . . 28

7 Evaluierungskonzept und Ergebnisse 29
7.1 Evaluierung von Retrieval- und Ranking-Systemen . . . 29
7.1.1 Recall@K . . . 29
7.1.2 Discounted Cumulative Gain . . . 29
7.1.3 Normalized Discounted Cumulative Gain . . . 30
7.1.4 Hierarchical nDCG . . . 30
7.1.5 Candidate Coverage . . . 30
7.1.6 Data Leakage Detection . . . 30

8 Diskussion, Grenzen und Ausblick 31

9 Zusammenfassung und Fazit 32

Literaturverzeichnis 36

1 Motivation

Die zunehmende Digitalisierung von industriellen Prozessen führt zu einer immer größer werdenden Menge an Prozess- und Produktdaten. Die Informationen liegen dabei oft in strukturierter und unstrukturierter Form wie Datenblätter, Produktbeschreibungen sowie Spezifikationen vor. Im gleichen Zuge steigt die Bedeutung von datengetriebenen Methoden für die Innovations- und Wettbewerbsfähigkeit in Deutschland. KI und dessen Potential die Daten sowie das Know-How der Industrie 4.0 zu nutzen, schafft somit den Grundstein um diese Herausforderung für die Industrie und deren Systeme zu meistern. Bundesministerium für Wirtschaft und Energie 2026.

Im Anlagen- sowie Maschinenbau entsteht durch die Variantenvielfalt technischer Komponenten eine besondere Herausforderung. Dabei werden von Unternehmen einerseits häufig umfangreiche Artikelbestände verwaltet, die eine Vielzahl an technischen Merkmalen beinhalten, während andernseits große Mengen an Dokumentationen und Datenblättern vorliegen. Eine Auswahl geeigneter Komponenten sowie die Artikelzuordnung zu standardisierten Lösungen erfolgt oftmals auf Basis von manueller Recherche und Erfahrung einzelner Mitarbeiter. Dadurch entsteht ein hoher Bearbeitungsaufwand, geringere Skalierbarkeit und eine hohen Abhängigkeit von Expertenwissen. Pfenning 2022.

Arbeiten aus der Wissenschaft zeigen, dass zur erfolgreichen Wissensextraktion, Automatisierung und Entscheidungsfindung KI-Verfahren in industirellen Prozessen eingesetzt werden. Einer der zentralen Punkte ist dabei die Extraktion von Informationen und Wissen aus aus heterogenen Datenquellen sowie die anschließende Nutzung dieser Extraktion für die technische Entscheidungsfindung. Als bewährter Ansatz hierfür eignen sich Empfehlungssysteme, die den Anwender dabei unterstützen, die am besten geeigneten Optionen für einen konkreten Anwendugsfall aus einer Vielzahl an Alternativen zu finden. Die Urspüngliche Verwendung solcher Systeme aus dem E-Commerce-Bereich, werden zunehmend auch im Industriellen Kontext angewendet, wie zum Beispiel bei der Auswahl von Produkten, Konfigurationen oder der erneuten Verwendung von Systemen. Joshi u. a. 2024.

Eine Bekannte Software in diesem Kontext ist EPLAN, welche für die Planung und Dokumentation elektrotechnischer Systeme eingesetzt wird. Diese unterstützt Ingenieure bei der Erstellung von Schaltplänen, Stücklisten und weiteren technischen Dokumentationen. Desweiteren ermöglicht EPLAN die Verwaltung von EPLAN-Artikeln EPLAN GmbH & Co. KG 2026b und die Integration von EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025, wodurch die Effizienz und Konsistenz in der Planung und Dokumentation elektrotechnischer Systeme erhöht wird.EPLAN GmbH & Co. KG 2026a

Auf Basis dieser Recherche ergibt sich ein erhebliches Potential für ein KI-basiertes Empfehlungssystem zur automatisierten Zuordnung von EPLAN-Artikeln EPLAN GmbH & Co. KG 2026b zu EPLAN-Fenstermakros. EPLAN GmbH & Co. KG 2025. Hierfür notwendige Informationen sind bereits in den vorhandenen EPLAN-Artikeln EPLAN GmbH & Co. KG 2026b enthalten, werden aber für die automatisierte Verarbeitung bislang nur unzureichend genutzt. Die intelligente Auswertung dieser strukturierten und unstrukturierten Daten bietet die Grundlage für die Erkennung relevanter Zusammenhänge und die Empfehlung passendender EPLAN-Fenstermakros. EPLAN GmbH & Co. KG 2025. Hierdurch wird der manuelle Aufwand entscheidend reduziert, sowie das vorhandene Unternehmenswissen besser genutzt und für eine konsistentere Entscheidungsfindung verwendet. Das Projekt leiste somit einen Beitrag zur praktischen Umsetzung von datengetriebenen und KI-Unterstützen Entscheidungen im Industrie 4.0 Umfeld. Nayak 2025.

2 Stand der Technik

2.1 Architektur- und Rankingansatz

Rankingprobleme treten in einer Vielzahl von Anwendungsfällen auf, wie zum Beispiel in Suchmaschinen, Produktempfehlungen oder Enterprise-Search-Systemen. Die Bewertung durch ein komplexes Rankingmodell wird dabei schnell unübersichtlich und bietet weniger Raum für Analysen und Interpretationen. Stattdessen haben sich mehrstufige Architekturen etabliert, die zu Beginn eine schnelle Kandidatenselektion durchführen und im Anschluss ein Rankingmodell auf die selektierten Kandidaten anwenden. Dieses Konzept wird in der Literatur als *Candidate Generation* und *Learning-to-Rank* bezeichnet Robertson und Zaragoza 2009; Liu 2009; Burges 2010. Teile davon werden für diese Arbeit übernommen und in abgeändeter Form für die Trainingsvorbereitung sowie das eigentliche Rankingmodell verwendet.

Im E-Comerce Bereich werden mehrstufige Architekturen bereits seit Jahren erfolgreich eingesetzt, um die Relevanz von Suchergebnissen und Empfehlungen zu verbessern. Aktuelle Untersuchungen in diesem Bereich zeigen, dass Produktsuchen großer Plattformen wie Amazon, eBay oder Alibaba weiterhin stark auf mehrstufige Retrievalpipelines, strukturierte Merkmale, und Learning-to-Rank-Verfahren setzen. Kabir u. a. 2024.

In diesem Kapitel werden die Verwendeten technischen Grundlagen für die Entwicklung des Systems erläutert. Die genaue Architektur sowie die Verwendung der einzelnen Komponenten wird im Kapitel **??** beschrieben.

2.2 BM25

2.2.1 Grundidee von BM25

BM25 basiert auf dem Probabilistic Relevance Framework von Robertson und Zaragoza. Dabei wird für jedes Anfrage-Dokument-Paar einen Relevanzwert bestimmt Robertson und Zaragoza 2009.

Die Grundannahme besteht darin, dass ein Dokument umso relevanter ist,

- je häufiger relevante Suchbegriffe darin vorkommen,
- je seltener diese Begriffe innerhalb der Gesamtdokumentensammlung auftreten,

- und je besser die Dokumentlänge berücksichtigt wird.

Dadurch erlangen seltene und spezifische Begriffe eine höhere Gewichtung, während häufige Begriffe wie ünd", öderöder "der"weniger Einfluss auf die Relevanzbewertung haben. Bei technischen Produktdaten ist dies besonders relevant, Artikelnummern, Typenbezeichnungen oder normierte Fachbegriffe häufig eine hohe Differenzierungskraft besitzen.

$$Score(D, Q) = \sum_{i=1}^{n} IDF(q_i) \cdot \frac{f(q_i, D)(k_1 + 1)}{f(q_i, D) + k_1 \left(1 - b + b\frac{|D|}{avgdl}\right)} \tag{2.1}$$

Die einzelnen Parameter besitzen folgende Bedeutung:

q_i Suchbegriff der Anfrage
$f(q_i, D)$ Häufigkeit des Begriffs q_i im Dokument
$|D|$ Dokumentlänge
$avgdl$ durchschnittliche Dokumentlänge aller Dokumente
k_1 Parameter zur Steuerung der Termfrequenzsättigung
b Parameter zur Dokumentlängennormalisierung
$IDF(q_i)$ inverse Dokumenthäufigkeit

Die inverse Dokumenthäufigkeit wird durch

$$IDF(q_i) = \log \frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} \tag{2.2}$$

mit

N Gesamtzahl aller Dokumente
$n(q_i)$ Anzahl der Dokumente, welche den Begriff q_i enthalten

berechnet.

Die resultierende Kennzahl stellt somit einen Relevanzscore dar, die die lexikalische Ähnlichkeit zwischen einer Anfrage und einem Kandidaten beschreibt.

2.2.2 Bedeutung in modernen Rankingarchitekturen

Trotz der zunehmenden Verbreitung von Deep-Learning-basierten Ansätzen im Information Retrieval, bleibt BM25 ein weit verbreitetes und effektives Verfahren. Aktuelle Studien zeigen, dass BM25 insbesondere bei Domänenspezifischen Datensätzen und als Basis für Learning-to-Rank-Modelle weiterhin eine hohe Relevanz besitzt Thakur u. a. 2021.

2.3 Exact-Match

2.3.1 Grundprinzip des Exact Matching

Exact-Match-Verfahren sind Teil der klassischen Konzepte des Information Retrieval und basieren auf dem Prinzip der exakten Übereinstimmung von Merkmalen zwischen einer Anfrage und einem Dokument Manning u. a. 2008; Baeza-Yates und Ribeiro-Neto 2011. Klassische Boolean-Syteme unterscheiden zwischen Treffer und Kein Treffer. Ein Dokument erfüllt nur dann die Anfrage, wenn alle geforderten Merkmale exakt übereinstimmen. Um quantiative Übereinstimmungen zu berücksichten, kann die Anzahl bzw. das Gewicht der übereinstimmenden Merkmale berücksichtigt werden.

Der Exact-Match-Score berechnet sich aus dem Verhältnis der Gewichte aller übereinstimmenden Merkmale zu den Gewichten aller in der Anfrage spezifizierten Merkmale:

$$ExactScore = \frac{\sum_{i=1}^{n} w_i \cdot m_i}{\sum_{i=1}^{n} w_i} \tag{2.3}$$

mit

w_i Gewicht des Merkmals i
m_i Match-Indikator des Merkmals i

Der Match-Indikator wird definiert als

$$m_i = \begin{cases} 1, & \text{wenn der Merkmalswert exakt übereinstimmt} \\ 0, & \text{sonst} \end{cases} \tag{2.4}$$

Der resultierende Score liegt im Intervall

$$0 \leq ExactScore \leq 1. \tag{2.5}$$

Ein Wert von 1 bedeutet, dass sämtliche relevanten technischen Eigenschaften übereinstimmen. Ein Wert von 0 signalisiert das Fehlen jeglicher fachlich relevanter Übereinstimmung.

2.3.2 Bedeutung von Exact-Match im modernen Information Retrieval

Eine aktuelle Wissenschaftliche Arbeit zeigt mit dem COIL-Ansatz, dass exakte lexikalische Übereinstimmungen im Zeitalter neuronaler Suchverfahren weiterhin eine hohe Relevanz besitzen. Die Autoren kombinieren klassische Exact-Match-Mechanismen mit modernen Sprachmodellrepräsentationen und zeigen, dass exakte Trefferinformationen weiterhin hochrelevante Signale für Retrieval- und Rankingverfahren darstellen Gao u. a. 2021.

2.4 Fusion von Retrievalsignalen mittels Reciprocal Rank Fusion

2.4.1 Grundidee von Reciprocal Rank Fusion

Reciprocal Rank Fusion (RRF) ist ein Verfahren zur Aggregation von Ranglisten, das die Rangpositionen der Dokumente in den einzelnen Listen berücksichtigt. Dabei lautet die Zentrale Annahme, dass ein Kandidat ein hohe Relevanz besitzt, wenn er in mehreren Ranglisten einen hohen Rang besitzt. Wenn ein Kandidat nur von einer Rangliste hoch bewertet wird, erhält er dadurch eine geringere Gewichtung. Dies führt zu einer robusteren Gesamtrangliste, die die Stärken der einzelnen Retrievalverfahren kombiniert. Ein wesentlicher Vorteil von RRF besteht darin, dass unterschiedliche Scales und Bewertungsmetriken problemlos kombiniert werden können. Hierfür ist keine Normalisierung der Scores auf einen Wertebereich erforderlich, da ausschließlich die Rangpositionen berücksichtigt werden.Cormack u. a. 2009.

2.4.2 Klassische RRF-Formulierung

Die ursprüngliche Formel von Cormack et al. lautet:

$$RRF(d) = \sum_{r \in R} \frac{1}{k + r(d)} \tag{2.6}$$

mit

R Menge aller Ranglisten
$r(d)$ Rangposition des Dokuments d in der jeweiligen Rangliste
k Glättungskonstante

Die Konstante k wird typischerweise auf den Wert 60 gesetzt und reduziert den Einfluss sehr hoher Einzelplatzierungen Cormack u. a. 2009.

2.4.3 Aktuelle Bedeutung von Rank-Fusion-Verfahren

In der aktuellen Forschung zu mehrstufigen Retrieval- und Rankingarchitekturen wird die Zusammenführung von Retrievalsignalen als wichtiger Bestandteil betrachtet, um die Leistungsfähigkeit von Rankingmodellen zu verbessern. Zhang et al. zeigen im Rahmen einer Multi-Stage-Ranking-Pipeline, dass unterschiedliche Kombinationen von Relevanzsignalen eine hohe Retrievalqualität ermöglichen Zhang u. a. 2021. Darüber hinaus beschreiben Zheng et al. im Rahmen des Full-Stage-Learning-to-Rank-Ansatz moderne Rankingarchitekturen, bei denen unterschiedliche Retrievalsignale in einem System optimiert werden und zur finalen Entscheidungsfindung beitragen Zheng u. a. 2024.

2.5 Learning-to-Rank mit LambdaRank

2.5.1 Grundprinzip von Learning-to-Rank

Learning-to-Rank (LTR) bezeichnet eine Klasse an maschinellen Lernverfahren, die das Ziel besitzen die Reihenfolge in einer Ergebnisliste zu optimieren Liu 2009. Im Gegensatz zu klassischen Klassifikations- oder Regressionsansätzen, bewertet Learning-to-Rank keine einzelnen Objekte isoliert, sondern die relative Relevanz dieser Objekte in einer Kandiatenmenge. Die Aufgabe eines Rankingmodells besteht darin, dass für eine Anfrage die relevanten Dokumente anhand ihrer Merkmale bewertet werden und anschließend in eine Rangliste überführt werden.

2.5.2 LambdaRank

LambdaRank ist eines der bekanntesten Verfahren im Bereich des Learning-to-Rank. Burges 2010

Die Grundidee von LambdaRank ist der paarweise Vergleich von Kandidaten. Dabei wird für zwei Kandidaten i und j mit den vorhergesagten Ergebnissen s_i und s_j die Wahrscheinlichkeit berechnet, dass Kandidat i vor Kandidat j eingeordnet werden sollte:

$$P_{ij} = \frac{1}{1 + e^{-\sigma(s_i - s_j)}} \tag{2.7}$$

mit

P_{ij} Wahrscheinlichkeit, dass Kandidat i vor Kandidat j gerankt wird
s_i vorhergesagter Score von Kandidat i
s_j vorhergesagter Score von Kandidat j

σ Skalierungsparameter der Sigmoidfunktion

Die Optimierung erfolgt anschließend durch die Änderung einer Rankingmetrik. Typischerweise wird dabei die Normalized Discounted Cumulative Gain (nDCG)-Funktion verwendet. Dabei werden die Gradienten anhand ihres Einflusses auf die Qualität der Rangliste gewichtet.

Der sogenannte Lambda-Gradient berechnet sich vereinfacht zu:

$$\lambda_{ij} = \frac{\partial L_{ij}}{\partial s_i} \cdot |\Delta nDCG| \tag{2.8}$$

mit

λ_{ij} gewichteter Gradient des Kandidatenpaares
$\frac{\partial L_{ij}}{\partial s_i}$ Ableitung der Verlustfunktion
$|\Delta nDCG|$ Änderung der Rankingqualität bei Vertauschung der Kandidaten

Kandidatenpaare, deren Reihnefolge einen größen Einfluss auf die Ranglisten-Qualität besitzen, erhalten einen höhrern Einfluss auf den Lernprozess. Dadurch wird das Modell auf die Qualität der Ergebnisliste optimiert und nicht auf die Vorhersage korrekter Einzelentscheidungen.Burges 2010.

2.5.3 LambdaMART und LightGBM

LambdaRank wird in modernen Rankinganwendungen häufig mit Gradient Boosted Decision Trees kombiniert, was als LambdaMART bezeichnet wird. Diese zählt zu den erfolgreichsten Verfahren im Bereich der strukturierten Rankingdaten Burges 2010.

Die zugrunde liegende Logik ist eine additive Zusammensetzung von Entscheidungsbäumen:

$$F(x) = \sum_{m=1}^{M} \gamma_m h_m(x) \tag{2.9}$$

mit

$F(x)$ vorhergesagter Gesamtscore
$h_m(x)$ Entscheidungsbaum m
γ_m Gewichtung des Baumes
M Anzahl aller Entscheidungsbäume

Dabei versucht jeder neu hinzugefügte Entscheidungsbaum, die Fehler des bisherigen Modells zu korrigieren.

Eine weit verbreitete Implementierung in der Industrie ist der LGBMRanker der LightGBM-Bibliothek. Dabei wird das Modell gruppenbasiert trainiert und alle Kandidaten einer Anfrage bilden eine Rankinggruppe, mit dem Ziel, die Reihenfolge der Kandiaten innerhalb einer Gruppe zu optimieren.

2.5.4 Aktuelle Bedeutung von LambdaMART

Trotz der zunehmenden Forschung im Bereich neuronaler Rankingverfahren, gehören LambdaMART-Basierte Modelle weiterhin zu den leistungsfähigsten Verfahren im Bereich der strukturierten tabellarischen Daten. Ein aktuelle Vergleichsstudie zeigt, dass Gradient-Boosted-Decision-Tree-Verfahren vorallem bei heterogenen Datensätzen noch immer State of the Art sind Lyzhin u. a. 2023.

Lyzhin et al. vergleiche in Ihrer Studie mehrer moderne Learning-to-Rank-Verfahren miteinander und kommen zu dem Ergebnis, dass LambdaMART-basierte Modelle immer noch äußerst konkurrenzfähig sind. Neue Optimierungsverfahren wie YetiRank and StochasticRank liefern dabei nur begrenzte Verbesserungen gegenüber LambdaMART-Modellen Lyzhin u. a. 2023.

Aktuelle Untersuchungen im Bereich der Rankingarchitekturen im E-Commerce zeigen, dass Learning-to-Rank-Modelle mit Gradient-Boosted-Decision-Trees weiterhin eine führende Rolle spielen. Dabei ist die Kombination aus strukturierten Merkmalen, Retrivalsignalen und LambdaMART-Optimierung insbesondere für strukturierte Domänen wie Produktkataloge und technische Informationssysteme von besonderer Bedeutung. Kabir u. a. 2024.

3 Zielsetzung und Vorgehensweise

3.1 Zielsetzung

Das Projektziel ist die Entwicklung eines Systems, welches automatisiert EPLAN-Artikel EPLAN GmbH & Co. KG 2026b zu EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 zuordnet. Für einen vorhanden technischen EPLAN-Artikel EPLAN GmbH & Co. KG 2026b soll anhand einer technischen Anfrage (zum Beispiel in Form eines Datenblatts) das fachlich passendste EPLAN-Fenstermakro EPLAN GmbH & Co. KG 2025 identifiziert werden.

Diese Problemstellung kann als Rankingaufgabe formuliert werden, bei der für jede Anfrage eine Menge bekannter EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 vorliegt. Dabei sind alle Kandidaten dieser Menge potenzielle Ergebnisse für den 1. Rang. Das System soll alle vorhandenen EPLAN-Artikel EPLAN GmbH & Co. KG 2026b analysieren, bewerten und anschließend das ähnlichste Zugrundeliegende EPLAN-Fenstermakro EPLAN GmbH & Co. KG 2025 auswählen. Ziel dabei ist es, dass das passendste EPLAN-Fenstermakro EPLAN GmbH & Co. KG 2025 möglichst auf Rang 1 erscheint. Die weniger ähnlichen Kandidaten sollen entsprechend der Bewertung hierachisch auf den nachfolgenden Rängen einsortiert werden.

Im Gegensatz zu Klassifikationsaufgaben liegt der Fokus dieses Systems nicht direkt auf der Bestimmung einer einzelnen Klasse oder Produktfamilie. Vielmehr geht es darum eine möglichst präzise Variantenauflösung zu erreichen. Dafür sollen die technischen Eigenschaften und Merkmale aus einer Anfrage systematisch erfasst und mit den Eigenschaften der EPLAN-Artikel EPLAN GmbH & Co. KG 2026b abgeglichen werden.

Die Herausforderung besteht darin, dass sich viele Produkte lediglich in einzelnen technischen Eigenschaften und Konfigurationsmerkmalen unterscheiden. Geringe Abweichungen können deshalb zu unterschiedlichen Makrozuordnungen führen. Das System muss daher in der Lage sein allgemeine technischen Zusammenhänge als auch merkmalspezifische Unterschiede zwischen ähnlichen Varianten zu erkennen.

Zur Lösung dieses Problems wird ein Learning-to-Rank-System entwickelt, welches unterschiedliche Retrivalsignale, strukturierte technische Merkmale sowie unstrukturierte Textinformationen aus technischen Anfragen kombiniert, um die Relevanz der EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 zu bewerten.

3.2 Methodisches Vorgehen

Das methodische Vorgehen orientiert sich an der *Design Science Research Methodology* (DSRM) nach Peffers et al. Peffers u. a. 2007. Die DSRM beschreibt einen strukturierten Forschungsprozess zur Entwicklung und Evaluation technischer Artefakte und eignet sich insbesondere für die Entwicklung von IT-Systemen. Das Ziel der Methodik besteht darin, eine konkrete Problemstellung systematisch zu analysieren, ein geeignetes Artefakt zu entwickeln und den Nutzen durch eine Evaluation nachzuweisen.

Der von Peffers et al. beschriebene Forschungsprozess umfasst die folgenden Schritte:

1. Problemidentifikation und Motivation
2. Definition der Lösungsziele
3. Design und Entwicklung des Artefakts
4. Demonstration der entwickelten Lösung
5. Evaluation des Artefakts
6. Kommunikation der Ergebnisse

In dieser Arbeit bildet die DSRM den übergeordneten Rahmen. Die iterative Entwicklung des Ranking-Systems erfolgt innerhalb der Design-, Entwicklungs- und Evaluationsphase durch wiederkehrende Entwicklungszyklen.

3.3 Iterativer Entwicklungsprozess

Zur Entwicklung des Artefakts wird die Design-Science-Methodik durch die Prinzipien des *Action Design Research* (ADR) nach Sein et al. verwendet Sein u. a. 2011. ADR verbindet dabei die Entwicklung eines Artefakts mit der fortlaufenden Anwendung, Evaluation und Verbesserung. Während die DSRM den strukturellen Prozess beschreibt, liefert ADR den Entwicklungszyklus zur kontinuierlichen Verbesserung des Systems.

Der iterative Entwicklungsprozess besteht dabei aus den folgenden Schritten:

1. Analyse des aktuellen Zustands und Identifikation von Verbesserungspotentialen
2. Recherche wissenschaftlicher und technischer Lösungen
3. Konzeption neuer Komponenten, Merkmale oder Optimierungen
4. Implementierung und Anpassung der entwickelten Ansätze
5. Durchführung von Tests und Validierungen
6. Evaluation anhand definierter Qualitätsmetriken
7. Interpretation der Ergebnisse
8. Ableitung weiterer Verbesserungen

Die Ergebnisse einer Iteration bilden jeweils die Grundlage für die nachfolgenden Iterationen. Auf diese Weise entsteht ein kontinuierlicher Verbesserungsprozess, in dem Forschung, Entwicklung, Evaluation und Optimierung miteinander verzahnt sind. Die Kombination aus DSRM und ADR ermöglicht somit auf der einen Seite einen strukturierten Forschungsprozess und auf der anderen Seite eine iterative Verbesserung des entwickelten Ranking-Systems.

Die verwendeten Qualitätsmetriken sowie deren mathematische Definitionen werden in Kapitel *06_evaluierungskonzept_und_ergebnisse* vorgestellt. Eine Darstellung der finalen Systemarchitektur und der vollständigen Pipeline befindet sich ebenfalls in diesem Kapitel.

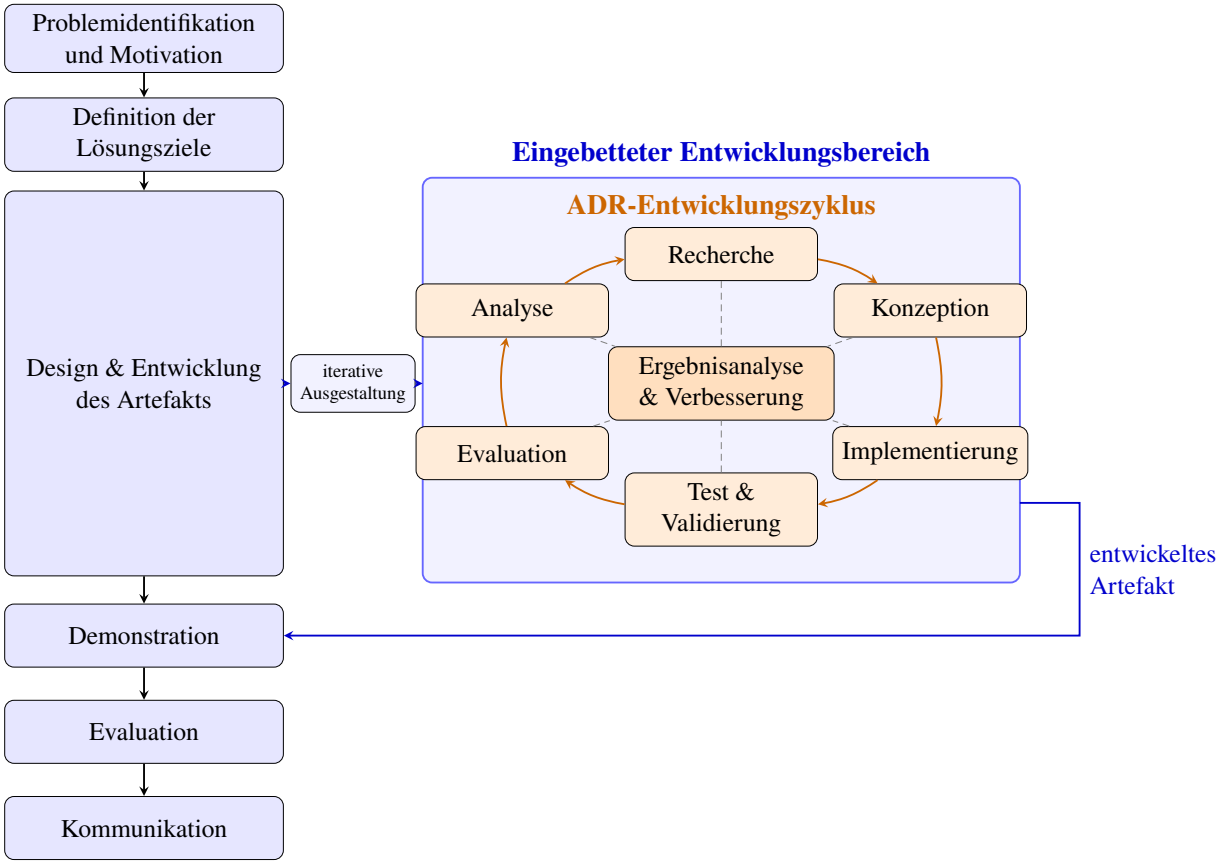


Abbildung 3.1: Verzahnung von DSRM und ADR. Die DSRM bildet den übergeordneten Forschungsrahmen, während ADR als iterativer Entwicklungszyklus innerhalb der Phase „Design & Entwicklung des Artefakts“ eingesetzt wird.

4 Architekturübersicht

4.1 Gesamtarchitektur

Die entwickelte Lösung basiert auf einer mehrstufigen Architektur, die aus Retrieval-, Feature-Engineering- und Ranking-Komponenten besteht. Im Gegensatz zu klassischen Suchsystemen, bei denen auf eine Anfrage direkte Ergebnisse gerankt werden, wird in diesem System ein anderer Ansatz verwendet. Dabei werden mehrere Retrievalsignale erzeugt, die im Anschluss zusammen mit technischen Merkmalen als Eingabe für das Learning-to-Rank-Modell verwendet werden.

Die einzelnen Schritte der Pipeline reichen von der Datenaufbereitung, über die Kandidatenbildung bis hin zum modellbasierten Ranking.

Abbildung 4.1 zeigt die implementierte End-to-End-Pipeline des Systems.

Die Orchestrierung aller Verarbeitungsschritte erfolgt zentral über die Trainingspipeline Project: KI-Makrotraining 2026d.

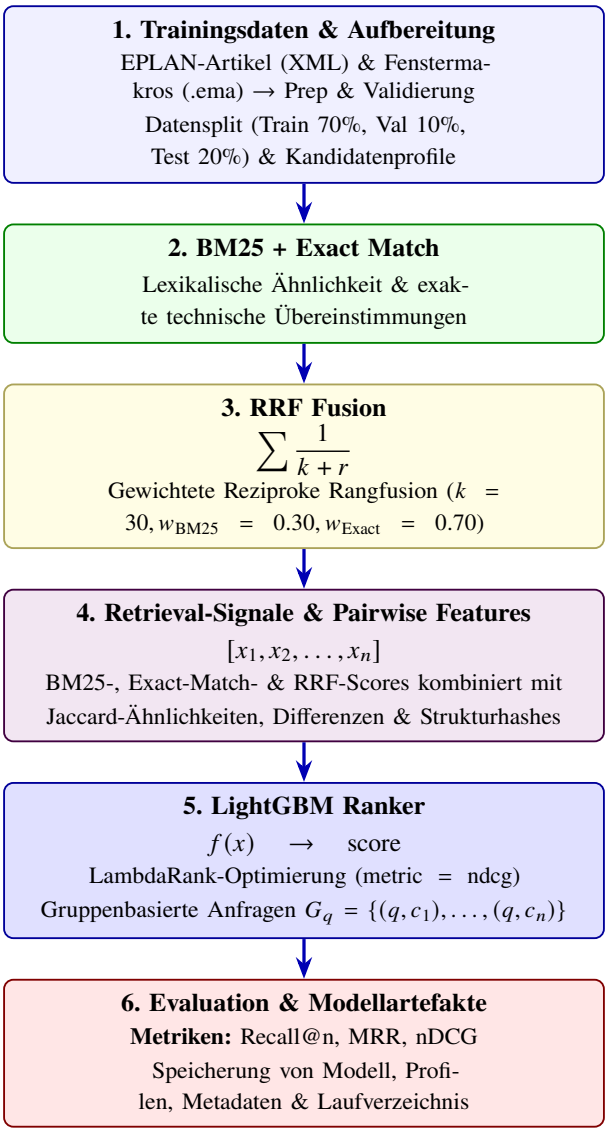


Abbildung 4.1: Architektur der Trainings- und Rankingpipeline.

5 Analyse der Datenstrukturen und Ableitung eines Trainingsformats

5.1 Analyse der Ausgangsdaten

Die Datengrundlage für das entwickelte System bilden EPLAN-Artikel EPLAN GmbH & Co. KG 2026b und EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025. Diese liegen in Form von strukturierten XML-Dateien und .ema-Dateien, einem XML-ähnlichen Format, vor Project: KI-Makrotraining 2026b. Um diese Daten für ein Learning-to-Rank-System nutzbar zu machen, müssen diese zunächst aufbereitet und in ein maschinenverständliches Format überführt werden.

Das Ziel der Datenaufbereitung besteht darin, alle technisch wichtigen Informationen der EPLAN-Artikel EPLAN GmbH & Co. KG 2026b sowie die strukturellen Merkmale der EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 zu extrahieren. Auf dieser Grundlage kann die Eignung eines EPLAN-Artikels EPLAN GmbH & Co. KG 2026b für ein EPLAN-Fenstermakro EPLAN GmbH & Co. KG 2025 bewertet werden. Die Umsetzung dieser Datenaufbereitung erfolgt innerhalb der entwickelten Trainings- und Rankingpipeline Project: KI-Makrotraining 2026b; Project: KI-Makrotraining 2026d.

5.2 Analyse der Makrostrukturen

Die Analyse der Makrostrukturen der EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 konzentriert sich auf die enthaltenen Funktions- und Strukturmerkmale, welche die Grundstruktur und Funktionalität der Makros bestimmen Project: KI-Makrotraining 2026b. Tabelle 5.1 fasst die analysierten Merkmalsgruppen, die jeweils extrahierten Informationen und deren Bedeutung zusammen.

Die Makrostrukturmerkmale werden beim Aufbau der Makrokandidatenprofile gespeichert. In der regulären Query-Kandidat-Feature-Berechnung werden diese jedoch nicht direkt mit einer unbekannten Artikelanfrage verglichen, da deren Zielmakrostruktur zur Anfragezeit nicht verfügbar ist.

Tabelle 5.1: Analysierte Merkmalsgruppen der EPLAN-Fenstermakros

Merkmalsgruppe	**Extrahierte Merkmale und Bedeutung**
Function-Template-Struktur	**Merkmale:** Function-Template-Kategorien, Function-Template-Gruppen, Function-Template-IDs, Function-Template-Sequenzen, Struktur-Hashes, Sequenz-Hashes. **Bedeutung:** Function-Templates sind grundlegende Bausteine, welche die Funktionalität und Logik der EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 im EPLAN-System EPLAN GmbH & Co. KG 2026a bestimmen. Die Merkmale beschreiben die funktionale Struktur und ermöglichen die Identifikation ähnlicher oder identischer Makrostrukturen.
Anschluss- und Signalstruktur	**Merkmale:** Anzahl der Anschlüsse, Anschlussrollen, Anschlussarten, Signalanzahlen, Kanalzahlen, I/O-Schemata, Klemmeninformationen. **Bedeutung:** Beschreibt die technische Funktion sowie die Anschlusslogik eines EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025.
Geräteeigenschaften	**Merkmale:** Bus-Systeme, Steckersysteme, Safety-Eigenschaften, LED-Eigenschaften, Leistungsmerkmale, Kommunikationsinformationen. **Bedeutung:** Ordnet Makros technisch im Maschinen- und Anlagenbau-Kontext ein.
Varianten-informationen	**Merkmale:** Variantenkennungen, Baugruppeninformationen, Konfigurationsmerkmale, produktspezifische Strukturinformationen. **Bedeutung:** Unterstützt die Auflösung fachlich ähnlicher Varianten, die sich nur durch einzelne technische Eigenschaften oder Konfigurationsmerkmale unterscheiden.

5.3 Aufbereitung der Artikeldaten

Neben den vorhandenen EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 werden auch die EPLAN-Artikeldaten EPLAN GmbH & Co. KG 2026b aufbereitet und analysiert Project: KI-Makrotraining 2026b. Die verwendeten Merkmalsgruppen sind in Tabelle 5.2 zusammengefasst.

Vor der Extraktion der Merkmale werden die Ursprungsdaten normalisiert und in ein einheitliches Format überführt. Dabei werden Texte, Schreibvarianten sowie technische Einheiten per Regular Expressions (RegEx) aufbereitet Project: KI-Makrotraining 2026b.

Tabelle 5.2: Aufbereitete Merkmalsgruppen der EPLAN-Artikeldaten

Merkmalsgruppe	**Merkmale**
Identifikationsmerkmale	Hersteller, Produktfamilie, Produkttyp, Bestellnummer, Produktcodes
Elektrische Eigenschaften	Spannungswerte, Stromwerte, Leistungswerte, Frequenzangaben
Mechanische Eigenschaften	Abmessungen, Gewicht, Baugrößen, Gehäusemerkmale
Technologische Eigenschaften	Schutzarten, Kommunikationsstandards, Anschlussinformationen, spezielle Gerätefunktionen

5.4 Erstellung von Makrokandidatenprofilen

Im nächsten Schritt wird für jedes bekannte EPLAN-Fenstermakro EPLAN GmbH & Co. KG 2025 ein Makrokandidatenprofil erstellt. Ein Makrokandidatenprofil fasst dabei die technischen Eigenschaften des jeweiligen Makros zusammen. Für Merkmals-Kategorien werden die häufigsten Ausprägungen gespeichert. Für numerische Merkmale werden statistische Werte wie Mittelwert, Median, Minimum, Maximum und Häufigkeiten berechnet. Die Berechnung dieser Kandidatenprofile erfolgt innerhalb der Trainingspipeline Project: KI-Makrotraining 2026c; Project: KI-Makrotraining 2026a.

5.5 Transformation in ein Rankingproblem

Die Zuordnung der EPLAN-Fenstermakros EPLAN GmbH & Co. KG 2025 wird nicht als Klassifikationsproblem, sondern als Ranking-Aufgabe betrachtet. Für jede Anfrage werden alle EPLAN-Fenstermakro-Kandidaten EPLAN GmbH & Co. KG 2025 betrachtet, deren Profile ausschließlich aus dem Trainingssplit abgeleitet wurden. Eine vorgeschaltete Reduktion auf eine Top-N-Kandidatenmenge findet im aktuellen System nicht statt, sodass alle Trainingsartikel für die Paar-Bildung verwendet werden.

$$C_q = \{c_1, c_2, \ldots, c_n\} \tag{5.1}$$

Dabei bezeichnet q die Anfrage bzw. den Eingangsartikel, C_q die Menge aller Makrokandidaten und c_i einen einzelnen Makrokandidaten. Für jede Anfrage wird anschließend jeweils ein Paar (q, c_i) gebildet. Dadurch entsteht eine Rankingstruktur, in der die Makrokandidaten gegeneinander bewertet werden.

5.6 Berechnung der Pairwise-Merkmale

Für jedes Paar von Anfrage und EPLAN-Fenstermakro-Kandidat EPLAN GmbH & Co. KG 2025 wird ein numerischer Feature-Vektor erzeugt. Die Merkmale der Paare lassen sich in mehrere Gruppen unterteilen: mengenbasierte Ähnlichkeiten, numerische Distanzmerkmale, Struktur- und Identitätsmerkmale sowie Retrieval-Merkmale.

Zur Bewertung von Merkmalsüberschneidungen wird unter anderem die Jaccard-Ähnlichkeit verwendet:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{5.2}$$

Dabei bezeichnet A die Merkmalsmenge der Anfrage und B die Merkmalsmenge des Makrokandidaten. Der Wertebereich liegt zwischen 0 und 1.

Um numerische Eigenschaften zu bewerten, werden Differenzmerkmale berechnet. Die absolute Differenz ist definiert als:

$$d(x, y) = |x - y| \tag{5.3}$$

Die relative Differenz wird berechnet durch:

$$d_{rel}(x, y) = \frac{|x - y|}{\max(|x|, |y|, \varepsilon)} \tag{5.4}$$

Dabei bezeichnen x den Eigenschaftswert der Anfrage, y den Eigenschaftswert des Kandidaten und ε eine kleine Konstante zur Vermeidung von Division durch Null. Durch diese Metriken können technische Kennwerte aus unterschiedlichen Größenordnungen verglichen werden.

Die weiteren Pairwise-Merkmale sind in Tabelle 5.3 zusammengefasst. BM25, Exact Match und Reciprocal Rank Fusion dienen im aktuellen System nicht als harte Kandidatenselektion. Sie werden für alle Makrokandidaten berechnet und als zusätzliche Merkmale an das Learning-to-Rank-Modell übergeben. Die theoretischen Grundlagen dieser Verfahren wurden bereits in Kapitel *02_stand_der_technik* erläutert. Die Berechnung der Pairwise-Merkmale erfolgt innerhalb der entwickelten Trainingspipeline Project: KI-Makrotraining 2026c; Project: KI-Makrotraining 2026a.

Tabelle 5.3: Gruppen der Pairwise-Merkmale

Merkmalsgruppe	**Merkmale und Funktion im Ranking**
Mengenbasierte Ähnlichkeiten	**Merkmale:** Jaccard-Ähnlichkeit und Merkmalsüberschneidungen. **Funktion:** Bewertung gemeinsamer technischer Eigenschaften von Anfrage und Kandidat
Numerische Distanzmerkmale	**Merkmale:** Absolute und relative Differenzen technischer Kennwerte. **Funktion:** Vergleich von Größenordnungen, Einheiten und technischen Wertebereichen
Struktur- und Identitätsmerkmale	**Merkmale:** Produktcode-Matches, Strukturhash-Übereinstimmungen, Function-Template-Übereinstimmungen, Kanalzahlvergleiche, Variantenmerkmale, I/O-Strukturvergleiche. **Funktion:** Beschreibung der technischen Identität eines Kandidaten
Retrieval-Merkmale	**Merkmale:** BM25-Scores, Exact-Match-Scores, RRF-Scores, Retrieval-Ränge. **Funktion:** Zusätzliche Trainingssignale für textuelle und exakte Übereinstimmungen

5.7 Erzeugung der Relevanzlabels

Für jedes Anfrage-Kandidaten-Paar wird ein Relevanzlabel erzeugt, das angibt, ob der Kandidat für die jeweilige Anfrage relevant ist oder nicht Project: KI-Makrotraining 2026c. Im verwendeten Trainingsmodus existiert pro Anfrage genau ein korrektes EPLAN-Fenstermakro EPLAN GmbH & Co. KG 2025. Die Funktion für die Relevanz lautet:

$$y(q,c) = \begin{cases} 1, & \text{wenn } c \text{ das Zielmakro von } q \text{ ist} \\ 0, & \text{sonst} \end{cases} \tag{5.5}$$

Dabei bezeichnet $y(q,c)$ das Relevanzlabel, q die Anfrage und c den Makrokandidaten. Jede Anfragegruppe enthält genau einen positiven Kandidaten und mehrere negative Kandidaten. Die negativen Kandidaten sind dazu da, das Modell darauf zu trainieren, irrelevante Makros korrekt zu erkennen und von relevanten zu unterscheiden. Dadurch werden nicht einzelne Objekte klassifiziert, sondern die korrekte Sortierung der Menge an Kandidaten Project: KI-Makrotraining 2026c.

5.8 Erstellung des Trainingsformats

Die berechneten Merkmale werden als Matrix gespeichert. Jede Zeile steht für ein Anfrage-Kandidat-Paar Project: KI-Makrotraining 2026c:

$$(q, c_i) \rightarrow [x_1, x_2, \ldots, x_n] \tag{5.6}$$

Dabei bezeichnet q die Anfrage, c_i den Makrokandidaten und $x_1, \ldots, x_n$ die berechneten Features. Zusätzlich wird die Zuordnung jeder Anfrage zu einer Gruppe von Kandidaten gespeichert:

$$G_q = \{(q, c_1), (q, c_2), \ldots, (q, c_n)\} \tag{5.7}$$

Dabei beschreibt G_q die Menge aller Anfrage-Kandidat-Paare für die Anfrage q. Die Informationen aus den Gruppen werden zusammen mit den Featurevektoren an den LambdaRANK-Algorithmus übergeben Project: KI-Makrotraining 2026c. Dadurch können die Kandidaten innerhalb derselben Anfrage gegeneinander bewertet werden und somit die optimale Rangfolge erlernt werden.

5.9 Vermeidung von Zielinformations-Leakage

Eine weitere wichtige Anforderung beim Aufbau der Trainingsdaten ist die Vermeidung von Zielinformations-Leakage. Dabei darf die Query-Seite ausschließlich Informationen enthalten, die aus eingehenden EPLAN-Artikeln EPLAN GmbH & Co. KG 2026b abgeleitet werden können. Informationen über das direkte Ziel-Fenster-Makro EPLAN GmbH & Co. KG 2025 dürfen nicht in die Eingabeseite einfließen.

Für die regulären Pairwise-Merkmale wird die Query-Seite auf Informationen beschränkt, die aus einem eingehenden Artikel abgeleitet werden können. Bezeichnungen wie $\mathrm{target_macro}$ und $\mathrm{target_family}$ sowie Strukturinformationen aus Makros werden für diese Query-Darstellung ausgeschlossen **srcLeakageGuard**; Project: KI-Makrotraining 2026a.

Die Makrostrukturmerkmale werden dagegen in den Kandidatenprofilen gespeichert. Sie beschreiben somit zusätzlich die Eigenschaften eines zu bewertenden EPLAN-Fenster-Makros EPLAN GmbH & Co. KG 2025 und können für kandidatenbezogene Merkmale genutzt werden, ohne dass das Ziel-Fenster-Makro EPLAN GmbH & Co. KG 2025 direkt als Labelinformation in die Query eingeht **srcLeakageGuard**.

Für eine bessere Veranschaulichung des Datenflusses innerhalb der Datenaufbereitung für das Traing wird in Abbildung 5.1 ein schematisches Diagramm dargestellt.

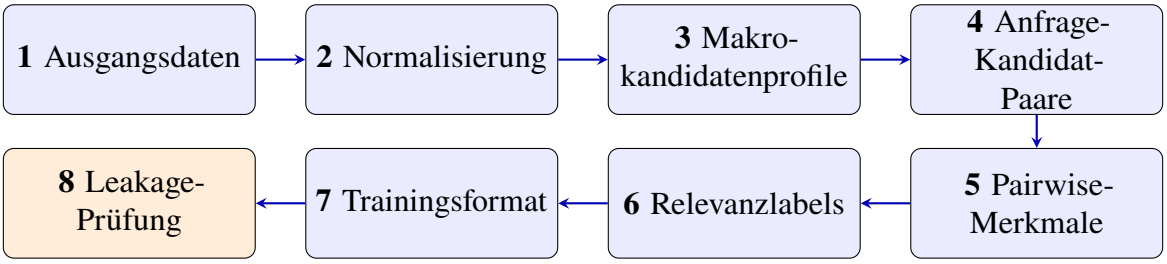


Abbildung 5.1: Verarbeitungsschritte von den Ausgangsdaten bis zum Trainingsformat.

6 Datensplit und Training

6.1 Anforderrungen an die Datenbasis

Um eine konsistente, validierte und reproduzierbare Datenbasis zu haben, wurde ein idealer Datensatz erstellt. Der ideale Datensatz setzt sich aus besten geeigneten Artikel und Makrokandidaten nach der Datenbereiningung zusammen **srcIdealDataset**; **srcStep913**. Dabei wurden folgende Anforderrungen wurden an den idealen Datensatz gestellt:

6.2 Datensplit und Trainingsbasis

Nach der Datenaufbereitung, der Qualitätsprüfung der Daten sowie der Erstellung des idealen Datensatzes erfolgt die Aufteilung in Trainings-, Validierungs- und Testdaten **srcStep913**; **srcIdealDataset**; **srcStep921**; Project: KI-Makrotraining 2026b. Ziel ist es eine klare Trennung zwischen Modelltraining, Hyperparameteroptimierung und Modellbewertung zu schaffen.

$$\text{Train} = 70\,\%, \qquad \text{Validation} = 10\,\%, \qquad \text{Test} = 20\,\% \tag{6.1}$$

Um reproduzierbare Ergebnisse mit einem erstellten Datensplitt zu gewährleisten, wird ein fester Zufallseed erstellt, der sicherstellt, dass die Aufteilung in Trainings-, Validierungs- und Testdaten bei jeder Ausführung identisch bleibt **srcStep921**.

$$\text{RANDOM_SEED} = 42 \tag{6.2}$$

Dabei wird keine reine Zufallsaufteilung vorgenommen, sondern fachliche Zusammenhänge der Daten berücksichtigt, um eine konsistente Vertreilung über die Anfragegruppen sicherzustellen. Dies verhindert, dass eng verwandte Beispiele in unterschiedlichen Datensplits landen und somit die Glaubwürdigkeit der Modellbewertung negativ beeinflussen **srcStep921**.

Tabelle 6.1: Anforderungen an den idealen Datensatz

Anforderung	**Beschreibung und Zielsetzung**
Reale Datenbasis	Der Datensatz enthält ausschließlich tatsächlich vorhandene EPLAN-Artikel aus der gesamten Datenbasis.
Eindeutiges Zielmakro	Jeder Artikel muss eindeutig einem Zielmakro (target_macro) zugeordnet sein.
Vorhandene Ground Truth	Für jedes Zielmakro muss eine passende reale .ema-Makrodatei existieren.
Vollständige technische Merkmale	Die Feature-Vektoren müssen vorhanden und mit technischen Informationen gefüllt sein.
Vollständige Grunddaten	Jeder Datensatz benötigt eine ID, ein Zielmakro, eine Makrofamilie und einen Fingerprint.
Keine Duplikate	Artikel-IDs dürfen nicht mehrfach vorkommen, damit kein Artikel versehentlich doppelt trainiert wird.
Keine widersprüchlichen Fingerprints	Ein Fingerprint darf nicht zu mehreren unterschiedlichen Zielmakros gehören. Andernfalls wäre die Zuordnung technisch nicht eindeutig.
Ausgeglichener Target-Support	Jedes Zielmakro sollte ungefähr gleich häufig vertreten sein. Dadurch lernt das Modell nicht überwiegend die am häufigsten vorkommenden Makros.
Vergleichbare Makrofamilien	Der Datensatz sollte mehrere Zielmakros derselben Familie enthalten. So kann geprüft werden, ob das Modell auch zwischen ähnlichen Makros unterscheiden kann.
Leakage-freie und reproduzierbare Aufteilung	Die Daten werden mit einem festen Zufallswert (RANDOM_SEED = 42) in 70 % Training, 10 % Validierung und 20 % Test aufgeteilt. Artikel mit zusammengehörigem Fingerprint bleiben dabei im selben Teil des Datensatzes **srcStep921**.

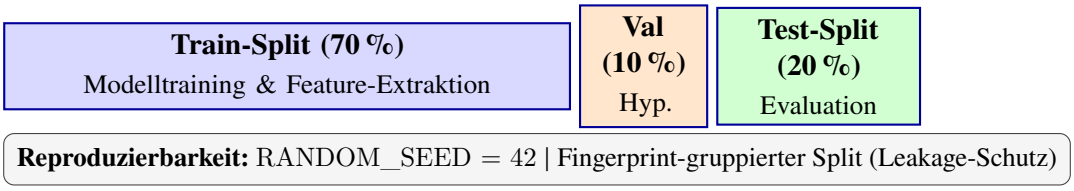


Abbildung 6.1: Schematische Aufteilung der Trainings-, Validierungs- und Testdatenbasis.

6.3 Aufbau der Retrievalsignale

Vor dem Modelltraining werden für jede Anfrage unterschiedliche Retrievalsignale berechenet (siehe Kapitel 5) Project: KI-Makrotraining 2026a. Diese dienen als erste Ähnlichkeitsabschätzung zwischen Anfrage und Kandidat.

Die theoretischen Grundlagen der Verwendeten Verfahren wurden bereits im Kapitel 2 beschrieben. Die Retrievalsignale dienen innerhalb der Pipeline-Architektur 4.1 nicht als eigenständige Rankingstufen, sondern als zusätzliche Merkmale für das Learning-to-Rank-Modell Project: KI-Makrotraining 2026a; Project: KI-Makrotraining 2026c.

Die folgenden Tabelle 6.2 zeigt die verwendeten Retrievalsignale sowie deren Funktion.

Tabelle 6.2: Verwendete Retrievalsignale

Signal	**Funktion**
BM25	Lexikalische Ähnlichkeit zwischen Anfrage und Makrokandidatenprofil
Exact Match	Exakte technische Übereinstimmungen strukturierter Merkmale
RRF	Fusion der Retrievalrankings zu einem kombinierten Retrievalsignal

Die verwendeten Parameter der Retrievalkomponenten wurden wie folgt festgelegt Project: KI-Makrotraining 2026a:

$$\mathrm{BM25}_{k1} = 1.2 \tag{6.3}$$

$$\mathrm{BM25}_{b} = 0.50 \tag{6.4}$$

$$\mathrm{RRF}_{k} = 30 \tag{6.5}$$

Dabei steuert k_1 wie stark wiederholte Treffer eines Begriffes berücksichtigt werden. Hier wurden 1,2 gewählt, da sich wiederholende lexikalische Begriffe zwar relevant sein können, aber nicht automatisch bedeuten, das ein EPLAN-Artikel EPLAN GmbH & Co. KG 2026b für ein EPLAN-Fenstermakro EPLAN GmbH & Co. KG 2025 relevanter ist.

Der Parameter b steuert die Normaliserung der Dokumentenlänge. Dieser liegt zwischen 0 und 1 und wurde hier auf 0,50 gesetzt. Dadurch wird berücksichtigt, dass längere Kandidatenprofile mehr Treffer enthalten können, diese aber nicht aufgrund der Länge einen übermäßigen Vorteil erhalten Project: KI-Makrotraining 2026a.

RRF_k steuert den Einfluss der Spitzenpositionen. Bei kleinem k dominiert Rang 1 stark, während bei größerem k auch niedrigere Ränge stärker berücksichtigt werden. 60 ist die übliche Wahl. Hier wurde 30 verwendet, um die Spiztenpositionen nicht zu stark zu reduziern um damit dem Ranking auf Top 1 mehr Abstand zu verleihen Project: KI-Makrotraining 2026a.

Die Fusion der Retrievalsignale erfolgt über die Gewichtung der Reciprocal Rank Fusion (RRF) Project: KI-Makrotraining 2026a:

$$w_{\text{BM25}} = 0.30 \qquad \text{und} \qquad w_{\text{Exact}} = 0.70 \tag{6.6}$$

Die höher Gewichtung von Exact Match gegenüber BM25 spiegelt die Priorität technischer Merkmale innerhalb der Maschienen- und Anlagebau-Domäne wider.

6.4 Training des Learning-to-Rank-Modells

Das zentrale Element der Architektur ist das Learning-to-Rank-Modell. Hierfür wird der LGBMRanker der LightGBM-Bibliothek verwendet Project: KI-Makrotraining 2026c. Dieser basiert auf dem in Kapitel 2 beschriebenen LambdaRank-/LambdaMART-Prinzip.

Das Modell wird mit den Parametern

$$\text{objective} = \text{lambdarank} \qquad \text{und} \qquad \text{metric} = \text{ndcg} \tag{6.7}$$

trainiert Project: KI-Makrotraining 2026c.

Wie in Kapitel 5 beschrieben, werden Kandidaten einer Anfrage als gemeinsame Rankinggruppe betrachtet. Wiederholend entsteht für jede Anfrage eine Gruppe:

$$G_q = \{(q, c_1), (q, c_2), \ldots, (q, c_n)\} \tag{6.8}$$

mit der Anfrage q und den zugehörigen Makrokandidaten c_i.

Dadurch erlernt das Modell nicht die allgemeine Zugehörigkeit eines einzelnen Kandidaten zu einer Klasse. Stattdessen wird die optimale Kandidatenreihenfolge innerhalb derselben Anfrage gelernt. Ziel dabei ist es, dass der relevanteste Kandidat möglichst weit oben in der Rangliste erscheint.

Die Eingaben für das Modell sind die im Kapitel 5 beschriebenen Pairwise-Merkmale. Das Training erfolgt dabei ausschließlich auf den Trainingsdaten, während die Optimierung der Hyperparameter über die Validierungsdaten erfolgt Project: KI-Makrotraining 2026c.

6.5 Hyperparameteroptimierung

Die Leistungsfähigkeit eines Learning-to-Rank-Modells hängt von der Wahl der Hyperparameter ab. Deswegen erfolgt die Modellkonfiguration nicht manuell, sondern durch eine systematische Hyperparameteroptimierung. Dafür wird hier eine Grid-Search-basierte Strategie verwendet. Bei dieser werden verschiedene Kombinationen von Hyperparametern getestet und anhand der Ergebnisse der Validierung verglichen Project: KI-Makrotraining 2026c.

Die folgenden Tabelle 6.5 zeigt die untersuchten Hyperparameterkombinationen:

Tabelle 6.3: Verwendete Hyperparameterkombinationen
Project: KI-Makrotraining 2026c

Parameter	**Wertebereich**
n_estimators	300, 500, 700
learning_rate	0.05, 0.04, 0.035
num_leaves	31, 63
min_child_samples	10, 20, 50
lambdarank_truncation_level	10, 20

Dabei sind die Hyperparameter wie folgt zu verstehen:

- n_estimators**:** Anzahl der aufgebauten Entscheidungsbäume im Modell. Mehr Bäume = komplexere Zusammenhänge, aber mehr Rechenaufwand.
- learning_rate**:** Lernrate pro Trainingsschritt. Kleinere Werte führen zu vorsichtigerem, aber stabileren Lernen.
- num_leaves**:** Maximale Anzahl der Blätter pro Baum. Mehr Blätter = komplexere Bäume, aber höheres Risiko für Overfitting.
- min_child_samples**:** Minimale Anzahl an Trainingsbeispielen in einem Blatt. Kleinere Werte = mehr Detailtreue pro Blatt, Größere Werte = bessere Regularisierung (verhindert Overfitting).
- lambdarank_truncation_level**:** Begrenzung des Ranglistenbereichs, der durch LambdaRank optimiert werden soll (Top 10, Top 20).

Für jede Parameterkombination wird ein vollständiger Trainingsdurchlauf durchgeführt. Die Bewertung erfolgt anschließend auf dem Validierungsdatensatz. Das finale Modell wird auf Basis der Rankingqualität anhand der Valiederungsdaten bestimmt Project: KI-Makrotraining 2026c.

Die verwendeten Bewertungsmetriken werden später in Kapitel *Evaluierungskonzept und Ergebnisse* ausführlich beschrieben.

6.6 Modellartefakte und Reproduzierbarkeit

Ein wichtiges Ziel dieser Trainingspipeline besteht darin die Trainingsabläufe reproduzierbar zu gestalten. Deswegen werden nach jedem Trainigslauf alle relvanten Artefakte gespeichert und dokumentiert Project: KI-Makrotraining 2026c.

Ablagestruktur im Laufverzeichnis:

```
run_directory/
|– model/
|– training/
|– evaluation/
|– summary/
\– error_analysis/
```

Gespeicherte Modellartefakte:

- das trainierte LightGBM-Modell,
- die verwendeten Hyperparameter,
- die erzielten Validierungsmetriken,
- die verwendeten Featuredefinitionen,
- die Makrokandidatenprofile,
- Konfigurations- und Laufmetadaten.

Abbildung 6.2: Strukturierte Ablage der Modellartefakte im Laufverzeichnis.

Dadurch lässt sich sicherstellen, dass jeder Trainigsablauf zu einem späteren Zeitpunkt vollständig nachvollzogen und reproduziert werden kann Project: KI-Makrotraining 2026c.

6.7 Pipeline-Orchestrierung

Die Ausführung der Gesamten Pipeline erfolgt über eine zentrale Komponente, die die Orchestrierung übernimmt. Dadurch wird sichergestellt dass alle Verarbeitungsschritte in der richtigen Reihenfolge ausgeführt werden **srcStep936**.

Die folgende Reihenfolge der Schritte, stellt den Ablauf der Pipeline dar. Diese können auch aus dem Architekturdiagramm 4.1 entnommen werden:

1. Datenaufbereitung
2. Qualitätsprüfung und Datenvalidierung
3. Datensplit
4. Berechnung der Retrievalsignale
5. Erstellung der Pairwise-Features
6. Training des Rankingmodells
7. Speicherung der Modellartefakte
8. Evaluation des trainierten Modells

Jeder Verarbeitungsschritt vewendet dabei die Artefakte des vorherigen Schrittes als Eingabe und erzuegt selbst Artefakte für den nächsten Schritt als Ausgabe. Dadurch wird ein konsistenter Datenfluss von den Roh-Daten bis zum trainierten Modell sichergestellt **srcStep936**; Project: KI-Makrotraining 2026d.

7 Evaluierungskonzept und Ergebnisse

7.1 Evaluierung von Retrieval- und Ranking-Systemen

7.1.1 Recall@K

Recall gehört zu den grundlegenden Metriken des Information Retrieval Manning u. a. 2008.

$$Recall@K = \frac{\text{\# relevante Treffer in Top-K}}{\text{\# relevante Treffer}} \tag{7.1}$$

Im vorliegenden System werden insbesondere

- target_recall@1
- target_recall@3
- target_recall@5
- target_recall@10

sowie Family-Recall-Metriken verwendet.

7.1.2 Discounted Cumulative Gain

Järvelin und Kekäläinen führten DCG und nDCG zur Bewertung gewichteter Ranglisten ein Järvelin und Kekäläinen 2002.

$$DCG@K = \sum_{i=1}^{K} \frac{2^{rel_i} - 1}{\log_2(i+1)} \tag{7.2}$$

mit

rel_i Relevanz am Rangplatz i

7.1.3 Normalized Discounted Cumulative Gain

Die Normalisierung erfolgt mittels

$$nDCG@K = \frac{DCG@K}{IDCG@K} \tag{7.3}$$

Der Wertebereich liegt zwischen 0 und 1.

7.1.4 Hierarchical nDCG

Für technische Katalogsysteme besitzen Fehler unterschiedliche Schweregrade. Daher wird eine hierarchische Relevanzfunktion verwendet:

$$rel = \begin{cases} 3 & \text{exaktes Ziel} \\ 2 & \text{gleiche Familie} \\ 0 & \text{sonst} \end{cases} \tag{7.4}$$

Diese Erweiterung erlaubt die differenzierte Bewertung von Variantenfehlern innerhalb derselben Produktfamilie.

7.1.5 Candidate Coverage

Die Candidate Coverage bewertet die maximale Leistungsfähigkeit des Retrievalsystems vor dem eigentlichen Ranking. Hierbei wird gemessen, ob sich das korrekte Ziel überhaupt im Kandidatenpool befindet.

7.1.6 Data Leakage Detection

Kaufman et al. definieren Data Leakage als unbeabsichtigte Nutzung von Informationen, die zum Zeitpunkt der Vorhersage nicht verfügbar sein dürfen Kaufman u. a. 2012. Die Verhinderung von Leakage stellt eine zentrale Voraussetzung für valide Evaluierungen und reproduzierbare Modellqualität dar.

8 Diskussion, Grenzen und Ausblick

9 Zusammenfassung und Fazit

Erklärung zur Abschlussarbeit

Hiermit versichere ich, die eingereichte Abschlussarbeit selbständig verfasst und keine andere als die von mir angegebenen Quellen und Hilfsmittel benutzt zu haben. Wörtlich oder inhaltlich verwendete Quellen wurden entsprechend den anerkannten Regeln wissenschaftlichen Arbeitens zitiert. Ich erkläre weiterhin, dass die vorliegende Arbeit noch nicht anderweitig als Abschlussarbeit eingereicht wurde. Das Merkblatt zum Täuschungsverbot im Prüfungsverfahren der Hochschule Augsburg habe ich gelesen und zur Kenntnis genommen. Ich versichere, dass die von mir abgegebene Arbeit keinerlei Plagiate, Texte oder Bilder umfasst, die durch von mir beauftragte Dritte erstellt wurden.

Augsburg, den 3. September 2026

Andreas Alstetter

Abbildungsverzeichnis

3.1 Verzahnung von DSRM und ADR. Die DSRM bildet den übergeordneten Forschungsrahmen, während ADR als iterativer Entwicklungszyklus innerhalb der Phase „Design & Entwicklung des Artefakts“ eingesetzt wird. 13

4.1 Architektur der Trainings- und Rankingpipeline. 15

5.1 Verarbeitungsschritte von den Ausgangsdaten bis zum Trainingsformat. 22

6.1 Schematische Aufteilung der Trainings-, Validierungs- und Testdatenbasis. 24
6.2 Strukturierte Ablage der Modellartefakte im Laufverzeichnis. 28

Tabellenverzeichnis

5.1 Analysierte Merkmalsgruppen der EPLAN-Fenstermakros 17
5.2 Aufbereitete Merkmalsgruppen der EPLAN-Artikeldaten 18
5.3 Gruppen der Pairwise-Merkmale 20

6.1 Anforderungen an den idealen Datensatz 24
6.2 Verwendete Retrievalsignale 25
6.3 Verwendete Hyperparameterkombinationen 27

Literaturverzeichnis

Baeza-Yates, Ricardo und Berthier Ribeiro-Neto (2011). *Modern Information Retrieval: The Concepts and Technology behind Search*. 2. Aufl. Addison-Wesley (siehe S. 6).

Bundesministerium für Wirtschaft und Energie (2026). *Wirtschaft und Forschung richten Plattform Industrie 4.0 auf industrielle KI aus*. Bundesministerium für Wirtschaft und Energie (siehe S. 2).

Burges, Christopher J. C. (2010). „From RankNet to LambdaRank to LambdaMART: An Overview“. In: *Microsoft Research Technical Report* (siehe S. 4, 8, 9).

Cormack, Gordon V., Charles L. A. Clarke und Stefan Büttcher (2009). „Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods“. In: *SIGIR 2009*, S. 758–759. DOI: 10.1145/1571941.1572114 (siehe S. 7).

EPLAN GmbH & Co. KG (2025). *Makros*. EPLAN-Plattform Infoportal (siehe S. 2, 3, 11, 16–21, 25).

EPLAN GmbH & Co. KG (2026a). *Eplan, Software und Services für die Elektrokonstruktion*. https://www.eplan.com/de-de/. Zugegriffen am 02.09.2026 (siehe S. 2, 17).

EPLAN GmbH & Co. KG (2026b). *Artikelverwaltung*. EPLAN-Hilfe (siehe S. 2, 3, 11, 16, 17, 21, 25).

Gao, Luyu, Zhuyun Dai und Jamie Callan (2021). „COIL: Revisit Exact Lexical Match in Information Retrieval with Contextualized Inverted List“. In: *Proceedings of NAACL-HLT 2021*, S. 3030–3042. DOI: 10.18653/v1/2021.naacl-main.241 (siehe S. 7).

Järvelin, Kalervo und Jaana Kekäläinen (2002). „Cumulated Gain-Based Evaluation of IR Techniques“. In: *ACM TOIS*. Bd. 20. 4, S. 422–446. DOI: 10.1145/582415.582418 (siehe S. 29).

Joshi, Tripuresh, Bhavesh Joshi, Karimulla Syed, S. Vijayarani, Sandeep Kumar und Naveen Naval (2024). „Industrial data analysis using Machine Learning Techniques“. In: *2024 IEEE North Karnataka Subsection Flagship International Conference (NKCon)*. IEEE. DOI: 10.1109/NKCon62728.2024.10774728 (siehe S. 2).

Kabir, Md. Ahsanul, Mohammad Al Hasan, Aritra Mandal, Daniel Tunkelang und Zhe Wu (2024). „A Survey on E-Commerce Learning to Rank“. In: *Procedia Computer Science* (siehe S. 4, 10).

Kaufman, Shachar, Saharon Rosset und Claudia Perlich (2012). „Leakage in Data Mining: Formulation, Detection, and Avoidance“. In: *ACM Transactions on Knowledge Discovery from Data* 6.4. DOI: 10.1145/2382577.2382579 (siehe S. 30).

Liu, Tie-Yan (2009). „Learning to Rank for Information Retrieval“. In: *Foundations and Trends in Information Retrieval* 3.3, S. 225–331. DOI: 10.1561/1500000016 (siehe S. 4, 8).

Lyzhin, Ivan, Aleksei Ustimenko, Andrey Gulin und Liudmila Prokhorenkova (2023). „Which Tricks Are Important for Learning to Rank?“ In: *Proceedings of ICML* (siehe S. 10).

Manning, Christopher D., Prabhakar Raghavan und Hinrich Schütze (2008). *Introduction to Information Retrieval*. Cambridge University Press (siehe S. 6, 29).

Nayak, Srikumar (2025). „Enhancing Manufacturing with Artificial Intelligence: An Overview of the Present Situation, Insights, Recommended Practices, Obstacles and Future Trends“. In: *World Journal of Advanced Research and Reviews* 28.3, S. 009–019. DOI: 10.30574/wjarr.2025.28.3.4033 (siehe S. 3).

Peffers, Ken, Tuure Tuunanen, Marcus A. Rothenberger und Samir Chatterjee (2007). „A Design Science Research Methodology for Information Systems Research“. In: *Journal of Management Information Systems* 24.3, S. 45–77. DOI: 10.2753/MIS0742-1222240302 (siehe S. 12).

Pfenning, Michael (2022). *Wie Maschinenbauer die Variantenvielfalt beherrschen* (siehe S. 2).

Project: KI-Makrotraining (2026a). *Macro candidate retrieval*. Source code, src/pkg_600_retrieval/ret_640_macro_candidate_retrieval.py (siehe S. 18, 19, 21, 25, 26).

Project: KI-Makrotraining (2026b). *Pipeline step 911: Raw EPLAN article XML parsing and data preparation*. Source code, src/pkg_900_pipeline/stage_910_data_preparation/step_911_prepare_raw_data.py (siehe S. 16, 17, 23).

Project: KI-Makrotraining (2026c). *Pipeline step 931: Learning-to-Rank macro ranker training*. Source code, src/pkg_900_pipeline/stage_930_model_training/step_931_train_macro_ltr_ranker.py (siehe S. 18–21, 25–28).

Project: KI-Makrotraining (2026d). *Training and ranking pipeline for EPLAN macros*. Project source code and documentation, README.md and docs/PROJECT_DOCUMENTATION.md (siehe S. 14, 16, 28).

Robertson, Stephen und Hugo Zaragoza (2009). „The Probabilistic Relevance Framework: BM25 and Beyond“. In: *Foundations and Trends in Information Retrieval* 3.4, S. 333–389. DOI: 10.1561/1500000019 (siehe S. 4).

Sein, Maung K., Ola Henfridsson, Sandeep Purao, Matti Rossi und Rikard Lindgren (2011). „Action Design Research“. In: *MIS Quarterly* 35.1, S. 37–56. DOI: 10.2307/23043488 (siehe S. 12).

Thakur, Nandan, Nils Reimers, Andreas Rücklé, Abhishek Srivastava und Iryna Gurevych (2021). „BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models“. In: *NeurIPS Datasets and Benchmarks* (siehe S. 5).

Zhang, Yue, Chengcheng Hu, Yuqi Liu, Hui Fang und Jimmy Lin (2021). „Learning to Rank in the Age of Muppets: Effectiveness-Efficiency Tradeoffs in Multi-Stage Ranking“. In: *SustaiNLP 2021* (siehe S. 8).

Zheng, Kai, Haijun Zhao, Rui Huang, Beichuan Zhang, Na Mou, Yanan Niu, Yang Song, Hongning Wang und Kun Gai (2024). „Full Stage Learning to Rank: A Unified Framework for Multi-Stage Systems“. In: *WWW 2024* (siehe S. 8).