Technische Hochschule Augsburg

Fakultät für Informatik

Thesis

zur Erlangung des Grades
Bachelor of Engineering in Mathematik

Proximitätssuche von EPLAN-Makros auf Basis des LambdaRank-Algorithmus

erstellt von Andreas Alstetter

Andreas Alstetter

Pfarrer-Kempter Str. 4
89358 Kammeltal/Behlingen
T +49 3141-5926
andreas.alstetter@tha.de

Matrikelnummer:
2147455

Technische Hochschule Augsburg

An der Hochschule 1
D-86161 Augsburg
T +49 821 5586-0
F +49 821 5586-3222
www.tha.de
info@tha.de

Erstprüfer	Prof. Dr. Thomas Kirchmeier
Zweitprüfer	Prof. Dr. Jürgen Grinninger
Themenvergabe am	4. September 2026
Eingereicht am	4. September 2026
Geheimhaltungsvereinbarung	Nein

Inhaltsverzeichnis

1 Motivation 2

2 Stand der Technik 4
2.1 Architektur- und Rankingansatz . . . 4
2.2 BM25 . . . 5
2.2.1 Grundidee von BM25 . . . 5
2.2.2 Bedeutung in modernen Rankingarchitekturen . . . 6
2.3 Exact-Match . . . 6
2.3.1 Grundprinzip des Exact Matching . . . 6
2.3.2 Bedeutung von Exact-Match im modernen Information Retrieval . . . 7
2.4 Fusion von Retrievalsignalen mittels Reciprocal Rank Fusion . . . 7
2.4.1 Grundidee von Reciprocal Rank Fusion . . . 7
2.4.2 Klassische RRF-Formulierung . . . 8
2.4.3 Aktuelle Bedeutung von Rank-Fusion-Verfahren . . . 8
2.5 Learning-to-Rank mit LambdaRank . . . 8
2.5.1 Grundprinzip von Learning-to-Rank . . . 8
2.5.2 LambdaRank . . . 9
2.5.3 LambdaMART und LightGBM . . . 10
2.5.4 Aktuelle Bedeutung von LambdaMART . . . 10

3 Zielsetzung und Vorgehensweise 12
3.1 Zielsetzung . . . 12
3.2 Methodisches Vorgehen . . . 13
3.3 Iterativer Entwicklungsprozess . . . 13

4 Architekturübersicht 15
4.1 Gesamtarchitektur . . . 15

5 Analyse der Datenstrukturen und Ableitung eines Trainingsformats 17
5.1 Analyse der Ausgangsdaten . . . 17
5.2 Analyse der Makrostrukturen . . . 17
5.3 Aufbereitung der Artikeldaten . . . 18
5.4 Erstellung von Makrokandidatenprofilen . . . 19
5.5 Transformation in ein Rankingproblem . . . 19
5.6 Berechnung der Pairwise-Merkmale . . . 20

5.7 Erzeugung der Relevanzlabels . . . 21
5.8 Erstellung des Trainingsformats . . . 22
5.9 Vermeidung von Zielinformations-Leakage . . . 22

6 Datensplit und Training 24
6.1 Anforderungen an die Datenbasis . . . 24
6.2 Datensplit und Trainingsbasis . . . 24
6.3 Aufbau der Retrievalsignale . . . 25
6.4 Training des Learning-to-Rank-Modells . . . 27
6.5 Hyperparameteroptimierung . . . 28
6.6 Modellartefakte und Reproduzierbarkeit . . . 29
6.7 Pipeline-Orchestrierung . . . 29

7 Evaluierungskonzept und Ergebnisse 31
7.1 Evaluationsdatensätze . . . 31
7.2 Aufbau der Evaluations-Suite . . . 31
7.3 Verwendete Rankingmetriken . . . 32
7.3.1 Target Recall@k . . . 32
7.3.2 Family Recall@k . . . 33
7.3.3 Mean Reciprocal Rank . . . 34
7.3.4 Hierarchical nDCG . . . 34
7.3.5 Bedeutung der Metriken innerhalb der Evaluation . . . 35
7.4 Evaluation der Retrievalphase . . . 36
7.4.1 Bewertung des Retrieval-Index . . . 36
7.4.2 Candidate Coverage . . . 37
7.4.3 Interpretation der Retrievalergebnisse . . . 37
7.5 Leakage-Sicherheitsprüfung . . . 38
7.5.1 Ziele der Leakage-Prüfung . . . 38
7.5.2 Prüfung der Query-Daten . . . 39
7.5.3 Prüfung der Datensplits . . . 39
7.5.4 Prüfung der Kandidatenprofile . . . 39
7.5.5 Evaluierungsergebnis . . . 40

8 Diskussion, Grenzen und Ausblick 41

9 Zusammenfassung und Fazit 42

Literaturverzeichnis 46

1 Motivation

Die zunehmende Digitalisierung von industriellen Prozessen führt zu einer immer größer werdenden Menge an Prozess- und Produktdaten. Die Informationen liegen dabei oft in strukturierter und unstrukturierter Form wie Datenblätter, Produktbeschreibungen sowie Spezifikationen vor. Im gleichen Zuge steigt die Bedeutung von datengetriebenen Methoden für die Innovations- und Wettbewerbsfähigkeit in Deutschland. KI und dessen Potential, die Daten sowie das Know-How der Industrie 4.0 zu nutzen, schafft somit den Grundstein, um diese Herausforderung für die Industrie und deren Systeme zu meistern (Bundesministerium für Wirtschaft und Energie 2026).

Im Anlagen- sowie Maschinenbau entsteht durch die Variantenvielfalt technischer Komponenten eine besondere Herausforderung. Dabei werden von Unternehmen einerseits häufig umfangreiche Artikelbestände verwaltet, die eine Vielzahl an technischen Merkmalen beinhalten, während andererseits große Mengen an Dokumentationen und Datenblättern vorliegen. Eine Auswahl geeigneter Komponenten sowie die Artikelzuordnung zu standardisierten Lösungen erfolgt oftmals auf Basis von manueller Recherche und Erfahrung einzelner Mitarbeiter. Dadurch entsteht ein hoher Bearbeitungsaufwand, geringere Skalierbarkeit und eine hohe Abhängigkeit von Expertenwissen (Pfenning 2022).

Arbeiten aus der Wissenschaft zeigen, dass zur erfolgreichen Wissensextraktion, Automatisierung und Entscheidungsfindung KI-Verfahren in industriellen Prozessen eingesetzt werden. Einer der zentralen Punkte ist dabei die Extraktion von Informationen und Wissen aus heterogenen Datenquellen sowie die anschließende Nutzung dieser Extraktion für die technische Entscheidungsfindung. Als bewährter Ansatz hierfür eignen sich Empfehlungssysteme, die den Anwender dabei unterstützen, die am besten geeigneten Optionen für einen konkreten Anwendungsfall aus einer Vielzahl an Alternativen zu finden. Die ursprüngliche Verwendung solcher Systeme aus dem E-Commerce-Bereich wird zunehmend auch im industriellen Kontext angewendet, wie zum Beispiel bei der Auswahl von Produkten, Konfigurationen oder der erneuten Verwendung von Systemen (Joshi u. a. 2024).

Eine bekannte Software in diesem Kontext ist EPLAN, welche für die Planung und Dokumentation elektrotechnischer Systeme eingesetzt wird. Diese unterstützt Ingenieure bei der Erstellung von Schaltplänen, Stücklisten und weiteren technischen Dokumentationen. Des Weiteren ermöglicht EPLAN die Verwaltung von EPLAN-Artikeln (EPLAN GmbH & Co. KG 2026b) und die Integration von EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025), wodurch die Effizienz und Konsistenz in der Planung und Dokumentation elektrotechnischer Systeme erhöht wird (EPLAN GmbH & Co. KG 2026a).

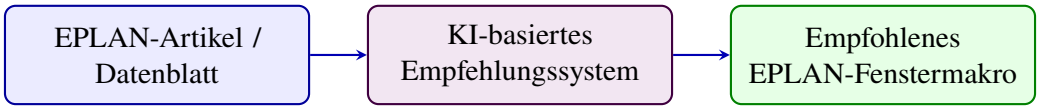


Abbildung 1.1: Grundidee der automatisierten Zuordnung von EPLAN-Artikeln zu EPLAN-Fenstermakros.

Auf Basis dieser Recherche ergibt sich ein erhebliches Potential für ein KI-basiertes Empfehlungssystem zur automatisierten Zuordnung von EPLAN-Artikeln (EPLAN GmbH & Co. KG 2026b) zu EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025). Hierfür notwendige Informationen sind bereits in den vorhandenen EPLAN-Artikeln (EPLAN GmbH & Co. KG 2026b) enthalten, werden aber für die automatisierte Verarbeitung bislang nur unzureichend genutzt. Die intelligente Auswertung dieser strukturierten und unstrukturierten Daten bietet die Grundlage für die Erkennung relevanter Zusammenhänge und die Empfehlung passender EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025). Hierdurch wird der manuelle Aufwand entscheidend reduziert, sowie das vorhandene Unternehmenswissen besser genutzt und für eine konsistentere Entscheidungsfindung verwendet. Das Projekt leistet somit einen Beitrag zur praktischen Umsetzung von datengetriebenen und KI-unterstützten Entscheidungen im Industrie-4.0-Umfeld (Nayak 2025). Abbildung 1.1 veranschaulicht die zugrunde liegende Idee dieser automatisierten Zuordnung.

2 Stand der Technik

2.1 Architektur- und Rankingansatz

Rankingprobleme treten in einer Vielzahl von Anwendungsfällen auf, wie zum Beispiel in Suchmaschinen, Produktempfehlungen oder Enterprise-Search-Systemen. Die Bewertung durch ein komplexes Rankingmodell wird dabei schnell unübersichtlich und bietet weniger Raum für Analysen und Interpretationen. Stattdessen haben sich mehrstufige Architekturen etabliert, die zu Beginn eine schnelle Kandidatenselektion durchführen und im Anschluss ein Rankingmodell auf die selektierten Kandidaten anwenden. Dieses Konzept wird in der Literatur als *Candidate Generation* und *Learning-to-Rank* bezeichnet (Robertson und Zaragoza 2009; Liu 2009; Burges 2010). Teile davon werden für diese Arbeit übernommen und in abgeändeter Form für die Trainingsvorbereitung sowie das eigentliche Rankingmodell verwendet. Abbildung 2.1 zeigt diesen zweistufigen Rankingansatz schematisch.

Im E-Commerce-Bereich werden mehrstufige Architekturen bereits seit Jahren erfolgreich eingesetzt, um die Relevanz von Suchergebnissen und Empfehlungen zu verbessern. Aktuelle Untersuchungen in diesem Bereich zeigen, dass Produktsuchen großer Plattformen wie Amazon, eBay oder Alibaba weiterhin stark auf mehrstufige Retrievalpipelines, strukturierte Merkmale, und Learning-to-Rank-Verfahren setzen. (Kabir u. a. 2024).

In diesem Kapitel werden die verwendeten technischen Grundlagen für die Entwicklung des Systems erläutert. Die genaue Architektur sowie die Verwendung der einzelnen Komponenten wird im Kapitel 4 beschrieben.

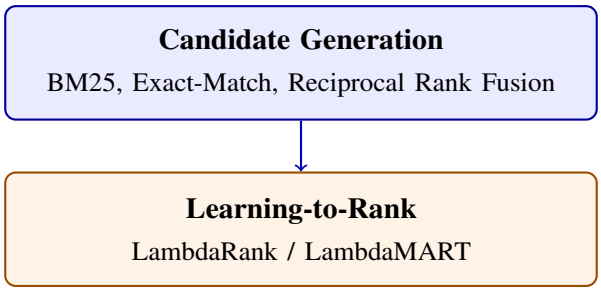


Abbildung 2.1: Zweistufiger Rankingansatz aus Candidate Generation und Learning-to-Rank.

2.2 BM25

2.2.1 Grundidee von BM25

BM25 basiert auf dem Probabilistic Relevance Framework von Robertson und Zaragoza. Dabei wird für jedes Anfrage-Dokument-Paar einen Relevanzwert bestimmt (Robertson und Zaragoza 2009).

Die Grundannahme besteht darin, dass ein Dokument umso relevanter ist,

- je häufiger relevante Suchbegriffe darin vorkommen,
- je seltener diese Begriffe innerhalb der Gesamtdokumentensammlung auftreten,
- und je besser die Dokumentlänge berücksichtigt wird.

Dadurch erlangen seltene und spezifische Begriffe eine höhere Gewichtung, während häufige Begriffe wie ünd", öderöder "der"weniger Einfluss auf die Relevanzbewertung haben. Bei technischen Produktdaten ist dies besonders relevant, da Artikelnummern, Typenbezeichnungen oder normierte Fachbegriffe häufig eine hohe Differenzierungskraft besitzen.

$$Score(D, Q) = \sum_{i=1}^{n} IDF(q_i) \cdot \frac{f(q_i, D)(k_1 + 1)}{f(q_i, D) + k_1 \left(1 - b + b\frac{|D|}{avgdl}\right)} \tag{2.1}$$

Die einzelnen Parameter besitzen folgende Bedeutung:

q_i Suchbegriff der Anfrage
$f(q_i, D)$ Häufigkeit des Begriffs q_i im Dokument
$|D|$ Dokumentlänge
$avgdl$ durchschnittliche Dokumentlänge aller Dokumente
k_1 Parameter zur Steuerung der Termfrequenzsättigung
b Parameter zur Dokumentlängennormalisierung
$IDF(q_i)$ inverse Dokumenthäufigkeit

Die inverse Dokumenthäufigkeit wird durch

$$IDF(q_i) = \log \frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} \tag{2.2}$$

mit

N Gesamtzahl aller Dokumente
$n(q_i)$ Anzahl der Dokumente, welche den Begriff q_i enthalten

berechnet.

Die resultierende Kennzahl stellt somit einen Relevanzscore dar, die die lexikalische Ähnlichkeit zwischen einer Anfrage und einem Kandidaten beschreibt.

2.2.2 Bedeutung in modernen Rankingarchitekturen

Trotz der zunehmenden Verbreitung von Deep-Learning-basierten Ansätzen im Information Retrieval, bleibt BM25 ein weit verbreitetes und effektives Verfahren. Aktuelle Studien zeigen, dass BM25 insbesondere bei domänenspezifischen Datensätzen und als Basis für Learning-to-Rank-Modelle weiterhin eine hohe Relevanz besitzt (Thakur u. a. 2021).

2.3 Exact-Match

2.3.1 Grundprinzip des Exact Matching

Exact-Match-Verfahren sind Teil der klassischen Konzepte des Information Retrieval und basieren auf dem Prinzip der exakten Übereinstimmung von Merkmalen zwischen einer Anfrage und einem Dokument (Manning u. a. 2008; Baeza-Yates und Ribeiro-Neto 2011). Klassische Boolean-Systeme unterscheiden zwischen Treffer und kein Treffer. Ein Dokument erfüllt nur dann die Anfrage, wenn alle geforderten Merkmale exakt übereinstimmen. Um quantitative Übereinstimmungen zu berücksichtigen, kann die Anzahl bzw. das Gewicht der übereinstimmenden Merkmale berücksichtigt werden.

Der Exact-Match-Score berechnet sich aus dem Verhältnis der Gewichte aller übereinstimmenden Merkmale zu den Gewichten aller in der Anfrage spezifizierten Merkmale:

$$ExactScore = \frac{\sum_{i=1}^{n} w_i \cdot m_i}{\sum_{i=1}^{n} w_i} \tag{2.3}$$

mit

w_i Gewicht des Merkmals i
m_i Match-Indikator des Merkmals i

Der Match-Indikator wird definiert als

$$m_i = \begin{cases} 1, & \text{wenn der Merkmalswert exakt übereinstimmt} \\ 0, & \text{sonst} \end{cases} \tag{2.4}$$

Der resultierende Score liegt im Intervall

$$0 \leq ExactScore \leq 1. \tag{2.5}$$

Ein Wert von 1 bedeutet, dass sämtliche relevanten technischen Eigenschaften übereinstimmen. Ein Wert von 0 signalisiert das Fehlen jeglicher fachlich relevanter Übereinstimmung.

2.3.2 Bedeutung von Exact-Match im modernen Information Retrieval

Eine aktuelle wissenschaftliche Arbeit zeigt mit dem COIL-Ansatz, dass exakte lexikalische Übereinstimmungen im Zeitalter neuronaler Suchverfahren weiterhin eine hohe Relevanz besitzen. Die Autoren kombinieren klassische Exact-Match-Mechanismen mit modernen Sprachmodellrepräsentationen und zeigen, dass exakte Trefferinformationen weiterhin hochrelevante Signale für Retrieval- und Rankingverfahren darstellen (Gao u. a. 2021).

2.4 Fusion von Retrievalsignalen mittels Reciprocal Rank Fusion

2.4.1 Grundidee von Reciprocal Rank Fusion

Reciprocal Rank Fusion (RRF) ist ein Verfahren zur Aggregation von Ranglisten, das die Rangpositionen der Dokumente in den einzelnen Listen berücksichtigt. Dabei lautet die zentrale Annahme, dass ein Kandidat eine hohe Relevanz besitzt, wenn er in mehreren Ranglisten einen hohen Rang besitzt. Wenn ein Kandidat nur von einer Rangliste hoch bewertet wird, erhält er dadurch eine geringere Gewichtung. Dies führt zu einer robusteren Gesamtrangliste, die die Stärken der einzelnen Retrievalverfahren kombiniert. Ein wesentlicher Vorteil von RRF besteht darin, dass unterschiedliche Scales und Bewertungsmetriken problemlos kombiniert werden können. Hierfür ist keine Normalisierung der Scores auf einen Wertebereich erforderlich, da ausschließlich die Rangpositionen berücksichtigt werden (Cormack u. a. 2009).

2.4.2 Klassische RRF-Formulierung

Die ursprüngliche Formel von Cormack et al. lautet:

$$RRF(d) = \sum_{r \in R} \frac{1}{k + r(d)} \tag{2.6}$$

mit

R Menge aller Ranglisten
$r(d)$ Rangposition des Dokuments d in der jeweiligen Rangliste
k Glättungskonstante

Die Konstante k wird typischerweise auf den Wert 60 gesetzt und reduziert den Einfluss sehr hoher Einzelplatzierungen (Cormack u. a. 2009).

2.4.3 Aktuelle Bedeutung von Rank-Fusion-Verfahren

In der aktuellen Forschung zu mehrstufigen Retrieval- und Rankingarchitekturen wird die Zusammenführung von Retrievalsignalen als wichtiger Bestandteil betrachtet, um die Leistungsfähigkeit von Rankingmodellen zu verbessern. Zhang et al. zeigen im Rahmen einer Multi-Stage-Ranking-Pipeline, dass unterschiedliche Kombinationen von Relevanzsignalen eine hohe Retrievalqualität ermöglichen (2021). Darüber hinaus beschreiben Zheng et al. im Rahmen des Full-Stage-Learning-to-Rank-Ansatz moderne Rankingarchitekturen, bei denen unterschiedliche Retrievalsignale in einem System optimiert werden und zur finalen Entscheidungsfindung beitragen (2024).

2.5 Learning-to-Rank mit LambdaRank

2.5.1 Grundprinzip von Learning-to-Rank

Learning-to-Rank (LTR) bezeichnet eine Klasse an maschinellen Lernverfahren, die das Ziel besitzen die Reihenfolge in einer Ergebnisliste zu optimieren (Liu 2009). Im Gegensatz zu klassischen Klassifikations- oder Regressionsansätzen, bewertet Learning-to-Rank keine einzelnen Objekte isoliert, sondern die relative Relevanz dieser Objekte in einer Kandidatenmenge. Die Aufgabe eines Rankingmodells besteht darin, dass für eine Anfrage die relevanten Dokumente anhand ihrer Merkmale bewertet werden und anschließend in eine Rangliste überführt werden.

2.5.2 LambdaRank

LambdaRank ist eines der bekanntesten Verfahren im Bereich des Learning-to-Rank. (Burges 2010)

Die Grundidee von LambdaRank ist der paarweise Vergleich von Kandidaten. Dabei wird für zwei Kandidaten i und j mit den vorhergesagten Ergebnissen s_i und s_j die Wahrscheinlichkeit berechnet, dass Kandidat i vor Kandidat j eingeordnet werden sollte:

$$P_{ij} = \frac{1}{1 + e^{-\sigma(s_i - s_j)}} \tag{2.7}$$

mit

P_{ij} Wahrscheinlichkeit, dass Kandidat i vor Kandidat j gerankt wird
s_i vorhergesagter Score von Kandidat i
s_j vorhergesagter Score von Kandidat j
σ Skalierungsparameter der Sigmoidfunktion

Die Optimierung erfolgt anschließend durch die Änderung einer Rankingmetrik. Typischerweise wird dabei die Normalized Discounted Cumulative Gain (nDCG)-Funktion verwendet. Dabei werden die Gradienten anhand ihres Einflusses auf die Qualität der Rangliste gewichtet.

Der sogenannte Lambda-Gradient berechnet sich vereinfacht zu:

$$\lambda_{ij} = \frac{\partial L_{ij}}{\partial s_i} \cdot |\Delta nDCG| \tag{2.8}$$

mit

λ_{ij} gewichteter Gradient des Kandidatenpaares
$\frac{\partial L_{ij}}{\partial s_i}$ Ableitung der Verlustfunktion
$|\Delta nDCG|$ Änderung der Rankingqualität bei Vertauschung der Kandidaten

Kandidatenpaare, deren Reihenfolge einen größeren Einfluss auf die Ranglisten-Qualität besitzen, erhalten einen höheren Einfluss auf den Lernprozess. Dadurch wird das Modell auf die Qualität der Ergebnisliste optimiert und nicht auf die Vorhersage korrekter Einzelentscheidungen (Burges 2010).

2.5.3 LambdaMART und LightGBM

LambdaRank wird in modernen Rankinganwendungen häufig mit Gradient Boosted Decision Trees kombiniert, was als LambdaMART bezeichnet wird. Diese zählt zu den erfolgreichsten Verfahren im Bereich der strukturierten Rankingdaten (Burges 2010).

Die zugrunde liegende Logik ist eine additive Zusammensetzung von Entscheidungsbäumen:

$$F(x) = \sum_{m=1}^{M} \gamma_m h_m(x) \tag{2.9}$$

mit

$F(x)$ vorhergesagter Gesamtscore
$h_m(x)$ Entscheidungsbaum m
γ_m Gewichtung des Baumes
M Anzahl aller Entscheidungsbäume

Dabei versucht jeder neu hinzugefügte Entscheidungsbaum, die Fehler des bisherigen Modells zu korrigieren.

Eine weit verbreitete Implementierung in der Industrie ist der `LGBMRanker` der LightGBM-Bibliothek. Dabei wird das Modell gruppenbasiert trainiert und alle Kandidaten einer Anfrage bilden eine Rankinggruppe, mit dem Ziel, die Reihenfolge der Kandidaten innerhalb einer Gruppe zu optimieren.

2.5.4 Aktuelle Bedeutung von LambdaMART

Trotz der zunehmenden Forschung im Bereich neuronaler Rankingverfahren, gehören LambdaMART-basierte Modelle weiterhin zu den leistungsfähigsten Verfahren im Bereich der strukturierten tabellarischen Daten. Eine aktuelle Vergleichsstudie zeigt, dass Gradient-Boosted-Decision-Tree-Verfahren vor allem bei heterogenen Datensätzen noch immer State of the Art sind (Lyzhin u. a. 2023).

Lyzhin et al. vergleichen in ihrer Studie mehrere moderne Learning-to-Rank-Verfahren miteinander und kommen zu dem Ergebnis, dass LambdaMART-basierte Modelle immer noch äußerst konkurrenzfähig sind. Neue Optimierungsverfahren wie YetiRank und StochasticRank liefern dabei nur begrenzte Verbesserungen gegenüber LambdaMART-Modellen (Lyzhin u. a. 2023).

Aktuelle Untersuchungen im Bereich der Rankingarchitekturen im E-Commerce zeigen, dass Learning-to-Rank-Modelle mit Gradient-Boosted-Decision-Trees weiterhin eine führende Rolle spielen. Dabei ist die Kombination aus strukturierten Merkmalen, Retrievalsignalen und

LambdaMART-Optimierung insbesondere für strukturierte Domänen wie Produktkataloge und technische Informationssysteme von besonderer Bedeutung (Kabir u. a. 2024).

3 Zielsetzung und Vorgehensweise

3.1 Zielsetzung

Das Projektziel ist die Entwicklung eines Systems, welches automatisiert EPLAN-Artikel (EPLAN GmbH & Co. KG 2026b) zu EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) zuordnet. Für einen vorhanden technischen EPLAN-Artikel (EPLAN GmbH & Co. KG 2026b) soll anhand einer technischen Anfrage (zum Beispiel in Form eines Datenblatts) das fachlich passendste EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) identifiziert werden.

Diese Problemstellung kann als Rankingaufgabe formuliert werden, bei der für jede Anfrage eine Menge bekannter EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) vorliegt. Dabei sind alle Kandidaten dieser Menge potenzielle Ergebnisse für den 1. Rang. Das System soll alle vorhandenen EPLAN-Artikel (EPLAN GmbH & Co. KG 2026b) analysieren, bewerten und anschließend das ähnlichste zugrundeliegende EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) auswählen. Ziel dabei ist es, dass das passendste EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) möglichst auf Rang 1 erscheint. Die weniger ähnlichen Kandidaten sollen entsprechend der Bewertung hierarchisch auf den nachfolgenden Rängen einsortiert werden.

Im Gegensatz zu Klassifikationsaufgaben liegt der Fokus dieses Systems nicht direkt auf der Bestimmung einer einzelnen Klasse oder Produktfamilie. Vielmehr geht es darum eine möglichst präzise Variantenauflösung zu erreichen. Dafür sollen die technischen Eigenschaften und Merkmale aus einer Anfrage systematisch erfasst und mit den Eigenschaften der EPLAN-Artikel (EPLAN GmbH & Co. KG 2026b) abgeglichen werden.

Die Herausforderung besteht darin, dass sich viele Produkte lediglich in einzelnen technischen Eigenschaften und Konfigurationsmerkmalen unterscheiden. Geringe Abweichungen können deshalb zu unterschiedlichen Makrozuordnungen führen. Das System muss daher in der Lage sein allgemeine technischen Zusammenhänge als auch merkmalspezifische Unterschiede zwischen ähnlichen Varianten zu erkennen.

Zur Lösung dieses Problems wird ein Learning-to-Rank-System entwickelt, welches unterschiedliche Retrievalsignale, strukturierte technische Merkmale sowie unstrukturierte Textinformationen aus technischen Anfragen kombiniert, um die Relevanz der EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) zu bewerten.

3.2 Methodisches Vorgehen

Das methodische Vorgehen orientiert sich an der *Design Science Research Methodology* (DSRM) nach Peffers et al. (2007). Die DSRM beschreibt einen strukturierten Forschungsprozess zur Entwicklung und Evaluation technischer Artefakte und eignet sich insbesondere für die Entwicklung von IT-Systemen. Das Ziel der Methodik besteht darin, eine konkrete Problemstellung systematisch zu analysieren, ein geeignetes Artefakt zu entwickeln und den Nutzen durch eine Evaluation nachzuweisen.

Der von Peffers et al. beschriebene Forschungsprozess umfasst die folgenden Schritte:

1. Problemidentifikation und Motivation
2. Definition der Lösungsziele
3. Design und Entwicklung des Artefakts
4. Demonstration der entwickelten Lösung
5. Evaluation des Artefakts
6. Kommunikation der Ergebnisse

In dieser Arbeit bildet die DSRM den übergeordneten Rahmen. Die iterative Entwicklung des Ranking-Systems erfolgt innerhalb der Design-, Entwicklungs- und Evaluationsphase durch wiederkehrende Entwicklungszyklen.

3.3 Iterativer Entwicklungsprozess

Zur Entwicklung des Artefakts wird die Design-Science-Methodik durch die Prinzipien des *Action Design Research* (ADR) nach Sein et al. verwendet (2011). ADR verbindet dabei die Entwicklung eines Artefakts mit der fortlaufenden Anwendung, Evaluation und Verbesserung. Während die DSRM den strukturellen Prozess beschreibt, liefert ADR den Entwicklungszyklus zur kontinuierlichen Verbesserung des Systems.

Der iterative Entwicklungsprozess besteht dabei aus den folgenden Schritten:

1. Analyse des aktuellen Zustands und Identifikation von Verbesserungspotentialen
2. Recherche wissenschaftlicher und technischer Lösungen
3. Konzeption neuer Komponenten, Merkmale oder Optimierungen
4. Implementierung und Anpassung der entwickelten Ansätze
5. Durchführung von Tests und Validierungen
6. Evaluation anhand definierter Qualitätsmetriken
7. Interpretation der Ergebnisse
8. Ableitung weiterer Verbesserungen

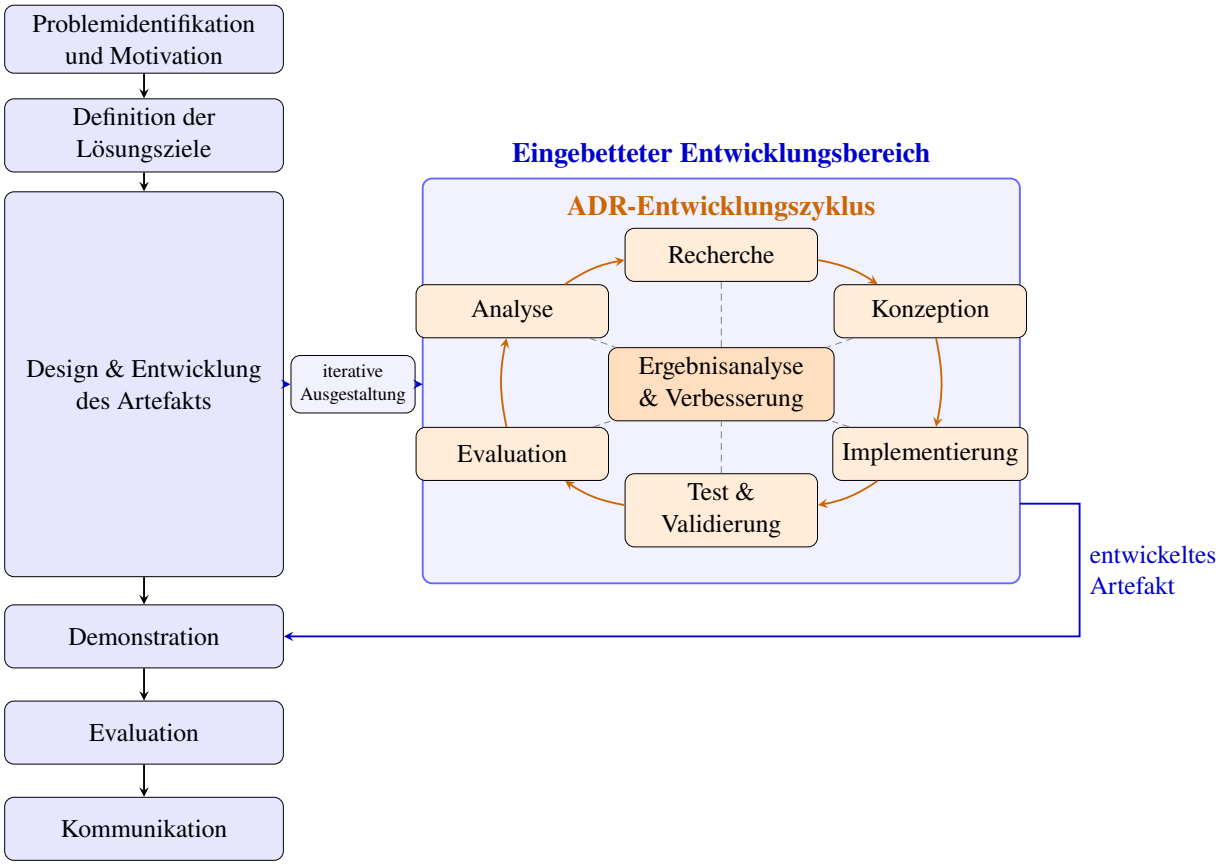


Abbildung 3.1: Verzahnung von DSRM und ADR. Die DSRM bildet den übergeordneten Forschungsrahmen, während ADR als iterativer Entwicklungszyklus innerhalb der Phase „Design & Entwicklung des Artefakts“ eingesetzt wird.

Die Ergebnisse einer Iteration bilden jeweils die Grundlage für die nachfolgenden Iterationen. Auf diese Weise entsteht ein kontinuierlicher Verbesserungsprozess, in dem Forschung, Entwicklung, Evaluation und Optimierung miteinander verzahnt sind. Die Kombination aus DSRM und ADR ermöglicht somit auf der einen Seite einen strukturierten Forschungsprozess und auf der anderen Seite eine iterative Verbesserung des entwickelten Ranking-Systems. Abbildung 3.1 veranschaulicht diese Verzahnung der beiden Methodiken.

Die verwendeten Qualitätsmetriken sowie deren mathematische Definitionen werden in Kapitel 7 vorgestellt. Eine Darstellung der finalen Systemarchitektur und der vollständigen Pipeline befindet sich ebenfalls in diesem Kapitel.

4 Architekturübersicht

4.1 Gesamtarchitektur

Die entwickelte Lösung basiert auf einer mehrstufigen Architektur, die aus Retrieval-, Feature-Engineering- und Ranking-Komponenten besteht. Im Gegensatz zu klassischen Suchsystemen, bei denen auf eine Anfrage direkte Ergebnisse gerankt werden, wird in diesem System ein anderer Ansatz verwendet. Dabei werden mehrere Retrievalsignale erzeugt, die im Anschluss zusammen mit technischen Merkmalen als Eingabe für das Learning-to-Rank-Modell verwendet werden.

Die einzelnen Schritte der Pipeline reichen von der Datenaufbereitung, über die Kandidatenbildung bis hin zum modellbasierten Ranking.

Abbildung 4.1 zeigt die implementierte End-to-End-Pipeline des Systems.

Die Orchestrierung aller Verarbeitungsschritte erfolgt zentral über die Trainingspipeline (KI-Makrotraining Project 2026n).

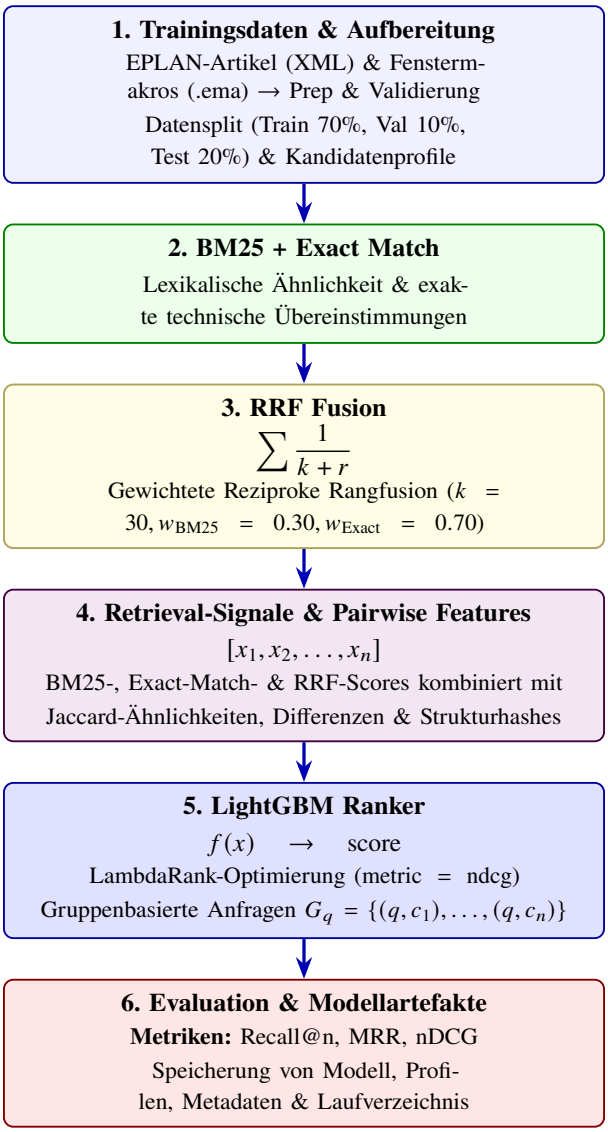


Abbildung 4.1: Architektur der Trainings- und Rankingpipeline.

5 Analyse der Datenstrukturen und Ableitung eines Trainingsformats

5.1 Analyse der Ausgangsdaten

Die Datengrundlage für das entwickelte System bilden EPLAN-Artikel (EPLAN GmbH & Co. KG 2026b) und EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025). Diese liegen in Form von strukturierten XML-Dateien und .ema-Dateien, einem XML-ähnlichen Format, vor (KI-Makrotraining Project 2026d). Um diese Daten für ein Learning-to-Rank-System nutzbar zu machen, müssen diese zunächst aufbereitet und in ein maschinenverständliches Format überführt werden.

Das Ziel der Datenaufbereitung besteht darin, alle technisch wichtigen Informationen der EPLAN-Artikel (EPLAN GmbH & Co. KG 2026b) sowie die strukturellen Merkmale der EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) zu extrahieren. Auf dieser Grundlage kann die Eignung eines EPLAN-Artikels (EPLAN GmbH & Co. KG 2026b) für ein EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) bewertet werden. Die Umsetzung dieser Datenaufbereitung erfolgt innerhalb der entwickelten Trainings- und Rankingpipeline (KI-Makrotraining Project 2026d; KI-Makrotraining Project 2026n).

5.2 Analyse der Makrostrukturen

Die Analyse der Makrostrukturen der EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) konzentriert sich auf die enthaltenen Funktions- und Strukturmerkmale, welche die Grundstruktur und Funktionalität der Makros bestimmen (KI-Makrotraining Project 2026d). Tabelle 5.1 fasst die analysierten Merkmalsgruppen, die jeweils extrahierten Informationen und deren Bedeutung zusammen.

Die Makrostrukturmerkmale werden beim Aufbau der Makrokandidatenprofile gespeichert. In der regulären Query-Kandidat-Feature-Berechnung werden diese jedoch nicht direkt mit einer unbekannten Artikelanfrage verglichen, da deren Zielmakrostruktur zur Anfragezeit nicht verfügbar ist.

Tabelle 5.1: Analysierte Merkmalsgruppen der EPLAN-Fenstermakros

Merkmalsgruppe	**Extrahierte Merkmale und Bedeutung**
Function-Template-Struktur	**Merkmale:** Function-Template-Kategorien, Function-Template-Gruppen, Function-Template-IDs, Function-Template-Sequenzen, Struktur-Hashes, Sequenz-Hashes. **Bedeutung:** Function-Templates sind grundlegende Bausteine, welche die Funktionalität und Logik der EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) im EPLAN-System (EPLAN GmbH & Co. KG 2026a) bestimmen. Die Merkmale beschreiben die funktionale Struktur und ermöglichen die Identifikation ähnlicher oder identischer Makrostrukturen.
Anschluss- und Signalstruktur	**Merkmale:** Anzahl der Anschlüsse, Anschlussrollen, Anschlussarten, Signalanzahlen, Kanalzahlen, I/O-Schemata, Klemmeninformationen. **Bedeutung:** Beschreibt die technische Funktion sowie die Anschlusslogik eines EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025).
Geräteeigenschaften	**Merkmale:** Bus-Systeme, Steckersysteme, Safety-Eigenschaften, LED-Eigenschaften, Leistungsmerkmale, Kommunikationsinformationen. **Bedeutung:** Ordnet Makros technisch im Maschinen- und Anlagenbau-Kontext ein.
Varianten-informationen	**Merkmale:** Variantenkennungen, Baugruppeninformationen, Konfigurationsmerkmale, produktspezifische Strukturinformationen. **Bedeutung:** Unterstützt die Auflösung fachlich ähnlicher Varianten, die sich nur durch einzelne technische Eigenschaften oder Konfigurationsmerkmale unterscheiden.

5.3 Aufbereitung der Artikeldaten

Neben den vorhandenen EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) werden auch die EPLAN-Artikeldaten (EPLAN GmbH & Co. KG 2026b) aufbereitet und analysiert (KI-Makrotraining Project 2026d). Die verwendeten Merkmalsgruppen sind in Tabelle 5.2 zusammengefasst.

Vor der Extraktion der Merkmale werden die Ursprungsdaten normalisiert und in ein einheitliches Format überführt. Dabei werden Texte, Schreibvarianten sowie technische Einheiten per Regular Expressions (RegEx) aufbereitet (KI-Makrotraining Project 2026d).

Tabelle 5.2: Aufbereitete Merkmalsgruppen der EPLAN-Artikeldaten

Merkmalsgruppe	**Merkmale**
Identifikationsmerkmale	Hersteller, Produktfamilie, Produkttyp, Bestellnummer, Produktcodes
Elektrische Eigenschaften	Spannungswerte, Stromwerte, Leistungswerte, Frequenzangaben
Mechanische Eigenschaften	Abmessungen, Gewicht, Baugrößen, Gehäusemerkmale
Technologische Eigenschaften	Schutzarten, Kommunikationsstandards, Anschlussinformationen, spezielle Gerätefunktionen

5.4 Erstellung von Makrokandidatenprofilen

Im nächsten Schritt wird für jedes bekannte EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) ein Makrokandidatenprofil erstellt. Ein Makrokandidatenprofil fasst dabei die technischen Eigenschaften des jeweiligen Makros zusammen. Für Merkmals-Kategorien werden die häufigsten Ausprägungen gespeichert. Für numerische Merkmale werden statistische Werte wie Mittelwert, Median, Minimum, Maximum und Häufigkeiten berechnet. Die Berechnung dieser Kandidatenprofile erfolgt innerhalb der Trainingspipeline (KI-Makrotraining Project 2026g; KI-Makrotraining Project 2026c).

5.5 Transformation in ein Rankingproblem

Die Zuordnung der EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) wird nicht als Klassifikationsproblem, sondern als Ranking-Aufgabe betrachtet. Für jede Anfrage werden alle EPLAN-Fenstermakro-Kandidaten (EPLAN GmbH & Co. KG 2025) betrachtet, deren Profile ausschließlich aus dem Trainingssplit abgeleitet wurden. Eine vorgeschaltete Reduktion auf eine Top-N-Kandidatenmenge findet im aktuellen System nicht statt, sodass alle Trainingsartikel für die Paar-Bildung verwendet werden.

$$C_q = \{c_1, c_2, \ldots, c_n\} \tag{5.1}$$

Dabei bezeichnet q die Anfrage bzw. den Eingangsartikel, C_q die Menge aller Makrokandidaten und c_i einen einzelnen Makrokandidaten. Für jede Anfrage wird anschließend jeweils ein Paar (q, c_i) gebildet. Dadurch entsteht eine Rankingstruktur, in der die Makrokandidaten gegeneinander bewertet werden.

5.6 Berechnung der Pairwise-Merkmale

Für jedes Paar von Anfrage und EPLAN-Fenstermakro-Kandidat (EPLAN GmbH & Co. KG 2025) wird ein numerischer Feature-Vektor erzeugt. Die Merkmale der Paare lassen sich in mehrere Gruppen unterteilen: mengenbasierte Ähnlichkeiten, numerische Distanzmerkmale, Struktur- und Identitätsmerkmale sowie Retrieval-Merkmale.

Zur Bewertung von Merkmalsüberschneidungen wird unter anderem die Jaccard-Ähnlichkeit verwendet:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{5.2}$$

Dabei bezeichnet A die Merkmalsmenge der Anfrage und B die Merkmalsmenge des Makrokandidaten. Der Wertebereich liegt zwischen 0 und 1.

Um numerische Eigenschaften zu bewerten, werden Differenzmerkmale berechnet. Die absolute Differenz ist definiert als:

$$d(x, y) = |x - y| \tag{5.3}$$

Die relative Differenz wird berechnet durch:

$$d_{rel}(x, y) = \frac{|x - y|}{\max(|x|, |y|, \varepsilon)} \tag{5.4}$$

Dabei bezeichnen x den Eigenschaftswert der Anfrage, y den Eigenschaftswert des Kandidaten und ε eine kleine Konstante zur Vermeidung von Division durch Null. Durch diese Metriken können technische Kennwerte aus unterschiedlichen Größenordnungen verglichen werden.

Die weiteren Pairwise-Merkmale sind in Tabelle 5.3 zusammengefasst. BM25, Exact Match und Reciprocal Rank Fusion dienen im aktuellen System nicht als harte Kandidatenselektion. Sie werden für alle Makrokandidaten berechnet und als zusätzliche Merkmale an das Learning-to-Rank-Modell übergeben. Die theoretischen Grundlagen dieser Verfahren wurden bereits in Kapitel 2 erläutert. Die Berechnung der Pairwise-Merkmale erfolgt innerhalb der entwickelten Trainingspipeline (KI-Makrotraining Project 2026g; KI-Makrotraining Project 2026c).

Tabelle 5.3: Gruppen der Pairwise-Merkmale

Merkmalsgruppe	**Merkmale und Funktion im Ranking**
Mengenbasierte Ähnlichkeiten	**Merkmale:** Jaccard-Ähnlichkeit und Merkmalsüberschneidungen. **Funktion:** Bewertung gemeinsamer technischer Eigenschaften von Anfrage und Kandidat
Numerische Distanzmerkmale	**Merkmale:** Absolute und relative Differenzen technischer Kennwerte. **Funktion:** Vergleich von Größenordnungen, Einheiten und technischen Wertebereichen
Struktur- und Identitätsmerkmale	**Merkmale:** Produktcode-Matches, Strukturhash-Übereinstimmungen, Function-Template-Übereinstimmungen, Kanalzahlvergleiche, Variantenmerkmale, I/O-Strukturvergleiche. **Funktion:** Beschreibung der technischen Identität eines Kandidaten
Retrieval-Merkmale	**Merkmale:** BM25-Scores, Exact-Match-Scores, RRF-Scores, Retrieval-Ränge. **Funktion:** Zusätzliche Trainingssignale für textuelle und exakte Übereinstimmungen

5.7 Erzeugung der Relevanzlabels

Für jedes Anfrage-Kandidaten-Paar wird ein Relevanzlabel erzeugt, das angibt, ob der Kandidat für die jeweilige Anfrage relevant ist oder nicht (KI-Makrotraining Project 2026g). Im verwendeten Trainingsmodus existiert pro Anfrage genau ein korrektes EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025). Die Funktion für die Relevanz lautet:

$$y(q,c) = \begin{cases} 1, & \text{wenn } c \text{ das Zielmakro von } q \text{ ist} \\ 0, & \text{sonst} \end{cases} \tag{5.5}$$

Dabei bezeichnet $y(q,c)$ das Relevanzlabel, q die Anfrage und c den Makrokandidaten. Jede Anfragegruppe enthält genau einen positiven Kandidaten und mehrere negative Kandidaten. Die negativen Kandidaten sind dazu da, das Modell darauf zu trainieren, irrelevante Makros korrekt zu erkennen und von relevanten zu unterscheiden. Dadurch werden nicht einzelne Objekte klassifiziert, sondern die korrekte Sortierung der Menge an Kandidaten (KI-Makrotraining Project 2026g).

5.8 Erstellung des Trainingsformats

Die berechneten Merkmale werden als Matrix gespeichert. Jede Zeile steht für ein Anfrage-Kandidat-Paar (KI-Makrotraining Project 2026g):

$$(q, c_i) \rightarrow [x_1, x_2, \ldots, x_n] \tag{5.6}$$

Dabei bezeichnet q die Anfrage, c_i den Makrokandidaten und $x_1, \ldots, x_n$ die berechneten Features. Zusätzlich wird die Zuordnung jeder Anfrage zu einer Gruppe von Kandidaten gespeichert:

$$G_q = \{(q, c_1), (q, c_2), \ldots, (q, c_n)\} \tag{5.7}$$

Dabei beschreibt G_q die Menge aller Anfrage-Kandidat-Paare für die Anfrage q. Die Informationen aus den Gruppen werden zusammen mit den Featurevektoren an den LambdaRANK-Algorithmus übergeben (KI-Makrotraining Project 2026g). Dadurch können die Kandidaten innerhalb derselben Anfrage gegeneinander bewertet werden und somit die optimale Rangfolge erlernt werden.

5.9 Vermeidung von Zielinformations-Leakage

Eine weitere wichtige Anforderung beim Aufbau der Trainingsdaten ist die Vermeidung von Zielinformations-Leakage. Dabei darf die Query-Seite ausschließlich Informationen enthalten, die aus eingehenden EPLAN-Artikeln (EPLAN GmbH & Co. KG 2026b) abgeleitet werden können. Informationen über das direkte Ziel-Fenster-Makro (EPLAN GmbH & Co. KG 2025) dürfen nicht in die Eingabeseite einfließen.

Für die regulären Pairwise-Merkmale wird die Query-Seite auf Informationen beschränkt, die aus einem eingehenden Artikel abgeleitet werden können. Bezeichnungen wie `target_macro` und `target_family` sowie Strukturinformationen aus Makros werden für diese Query-Darstellung ausgeschlossen (KI-Makrotraining Project 2026m; KI-Makrotraining Project 2026c).

Die Makrostrukturmerkmale werden dagegen in den Kandidatenprofilen gespeichert. Sie beschreiben somit zusätzlich die Eigenschaften eines zu bewertenden EPLAN-Fenster-Makros (EPLAN GmbH & Co. KG 2025) und können für kandidatenbezogene Merkmale genutzt werden, ohne dass das Ziel-Fenster-Makro (EPLAN GmbH & Co. KG 2025) direkt als Labelinformation in die Query eingeht (KI-Makrotraining Project 2026m).

Eine genauere Betrachtung der Leakage-Sicherheit erfolgt im Kapitel 7.

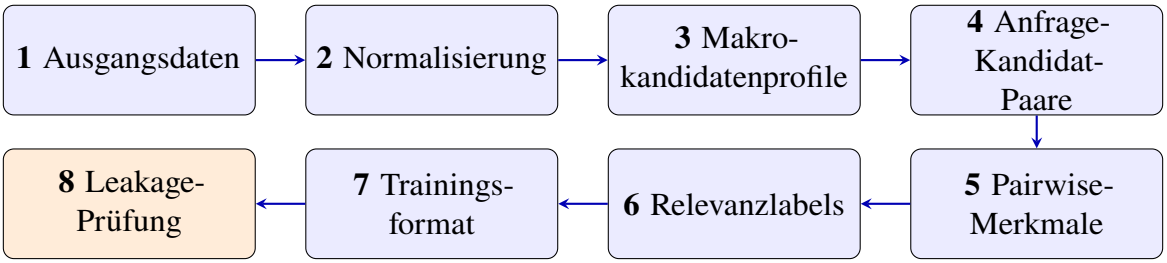


Abbildung 5.1: Verarbeitungsschritte von den Ausgangsdaten bis zum Trainingsformat.

Für eine bessere Veranschaulichung des Datenflusses innerhalb der Datenaufbereitung für das Training wird in Abbildung 5.1 ein schematisches Diagramm dargestellt.

6 Datensplit und Training

6.1 Anforderungen an die Datenbasis

Um eine konsistente, validierte und reproduzierbare Datenbasis zu haben, wurde ein idealer Datensatz erstellt. Der ideale Datensatz setzt sich aus den bestgeeigneten Artikeln und Makrokandidaten nach der Datenbereinigung zusammen (KI-Makrotraining Project 2026b; KI-Makrotraining Project 2026e). Dabei wurden die Anforderungen an den idealen Datensatz in Tabelle 6.1 zusammengefasst.

6.2 Datensplit und Trainingsbasis

Nach der Datenaufbereitung, der Qualitätsprüfung der Daten sowie der Erstellung des idealen Datensatzes erfolgt die Aufteilung in Trainings-, Validierungs- und Testdaten (KI-Makrotraining Project 2026d; KI-Makrotraining Project 2026e; KI-Makrotraining Project 2026b; KI-Makrotraining Project 2026f). Ziel ist es eine klare Trennung zwischen Modelltraining, Hyperparameteroptimierung und Modellbewertung zu schaffen.

$$\text{Train} = 70\,\%, \qquad \text{Validation} = 10\,\%, \qquad \text{Test} = 20\,\% \tag{6.1}$$

Um reproduzierbare Ergebnisse mit einem erstellten Datensplit zu gewährleisten, wird ein fester Zufallsseed verwendet, der sicherstellt, dass die Aufteilung in Trainings-, Validierungs- und Testdaten bei jeder Ausführung identisch bleibt (KI-Makrotraining Project 2026f).

$$\text{RANDOM_SEED} = 42 \tag{6.2}$$

Dabei wird keine reine Zufallsaufteilung vorgenommen, sondern fachliche Zusammenhänge der Daten berücksichtigt, um eine konsistente Verteilung über die Anfragegruppen sicherzustellen. Dies verhindert, dass eng verwandte Beispiele in unterschiedlichen Datensplits landen und somit die Glaubwürdigkeit der Modellbewertung negativ beeinflussen. Durch die unterschiedlichen

Tabelle 6.1: Anforderungen an den idealen Datensatz (KI-Makrotraining Project 2026b; KI-Makrotraining Project 2026e; KI-Makrotraining Project 2026f)

Anforderung	**Beschreibung und Zielsetzung**
Reale Datenbasis	Der Datensatz enthält ausschließlich tatsächlich vorhandene EPLAN-Artikel aus der gesamten Datenbasis.
Eindeutiges Zielmakro	Jeder Artikel muss eindeutig einem Zielmakro (`target_macro`) zugeordnet sein.
Vorhandene Ground Truth	Für jedes Zielmakro muss eine passende reale `.ema`-Makrodatei existieren.
Vollständige technische Merkmale	Die Feature-Vektoren müssen vorhanden und mit technischen Informationen gefüllt sein.
Vollständige Grunddaten	Jeder Datensatz benötigt eine ID, ein Zielmakro, eine Makrofamilie und einen Fingerprint.
Keine Duplikate	Artikel-IDs dürfen nicht mehrfach vorkommen, damit kein Artikel versehentlich doppelt trainiert wird.
Keine widersprüchlichen Fingerprints	Ein Fingerprint darf nicht zu mehreren unterschiedlichen Zielmakros gehören. Andernfalls wäre die Zuordnung technisch nicht eindeutig.
Ausgeglichener Target-Support	Jedes Zielmakro sollte ungefähr gleich häufig vertreten sein. Dadurch lernt das Modell nicht überwiegend die am häufigsten vorkommenden Makros.
Vergleichbare Makrofamilien	Der Datensatz sollte mehrere Zielmakros derselben Familie enthalten. So kann geprüft werden, ob das Modell auch zwischen ähnlichen Makros unterscheiden kann.
Leakage-freie und reproduzierbare Aufteilung	Die Daten werden mit einem festen Zufallswert (`RANDOM_SEED` = 42) in 70 % Training, 10 % Validierung und 20 % Test aufgeteilt. Artikel mit zusammengehörigem Fingerprint bleiben dabei im selben Teil des Datensatzes (KI-Makrotraining Project 2026f).

Seed-Werte lässt sich dann auch ein Mittelwert über mehrere Splits ableiten (KI-Makrotraining Project 2026f). Abbildung 6.1 fasst diese Aufteilung schematisch zusammen.

6.3 Aufbau der Retrievalsignale

Vor dem Modelltraining werden für jede Anfrage unterschiedliche Retrievalsignale berechnet (siehe Kapitel 5) (KI-Makrotraining Project 2026c). Diese dienen als erste Ähnlichkeitsabschätzung zwischen Anfrage und Kandidat.

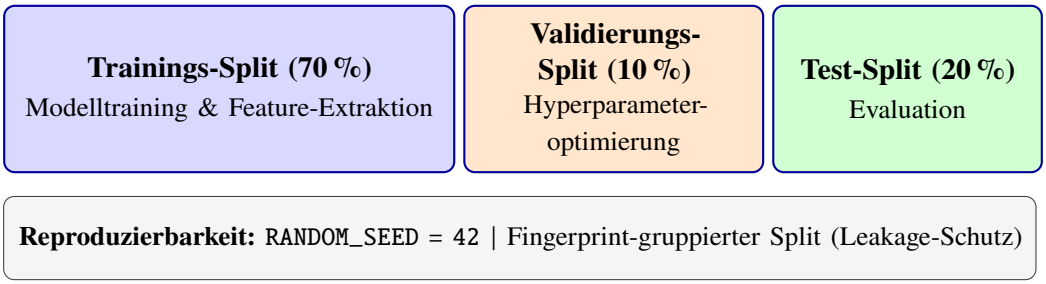


Abbildung 6.1: Schematische Aufteilung der Trainings-, Validierungs- und Testdatenbasis.

Tabelle 6.2: Verwendete Retrievalsignale

Signal	**Funktion**
BM25	Lexikalische Ähnlichkeit zwischen Anfrage und Makrokandidatenprofil
Exact Match	Exakte technische Übereinstimmungen strukturierter Merkmale
RRF	Fusion der Retrievalrankings zu einem kombinierten Retrievalsignal

Die theoretischen Grundlagen der verwendeten Verfahren wurden bereits im Kapitel 2 beschrieben. Die Retrievalsignale dienen innerhalb der in Abbildung 4.1 dargestellten Pipeline-Architektur nicht als eigenständige Rankingstufen, sondern als zusätzliche Merkmale für das Learning-to-Rank-Modell (KI-Makrotraining Project 2026c; KI-Makrotraining Project 2026g).

Die folgende Tabelle 6.2 zeigt die verwendeten Retrievalsignale sowie deren Funktion.

Die verwendeten Parameter der Retrievalkomponenten wurden wie folgt festgelegt (KI-Makrotraining Project 2026c):

$$\mathrm{BM25}_{k1} = 1.2 \tag{6.3}$$

$$\mathrm{BM25}_{b} = 0.50 \tag{6.4}$$

$$\mathrm{RRF}_{k} = 30 \tag{6.5}$$

Dabei steuert k_1 wie stark wiederholte Treffer eines Begriffes berücksichtigt werden. Hier wurden 1,2 gewählt, da sich wiederholende lexikalische Begriffe zwar relevant sein können, aber nicht automatisch bedeuten, das ein EPLAN-Artikel (EPLAN GmbH & Co. KG 2026b) für ein EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) relevanter ist.

Der Parameter b steuert die Normalisierung der Dokumentenlänge. Dieser liegt zwischen 0 und 1 und wurde hier auf 0,50 gesetzt. Dadurch wird berücksichtigt, dass längere Kandidatenprofile mehr Treffer enthalten können, diese aber nicht aufgrund der Länge einen übermäßigen Vorteil erhalten (KI-Makrotraining Project 2026c).

RRF_k steuert den Einfluss der Spitzenpositionen. Bei kleinem k dominiert Rang 1 stark, während bei größerem k auch niedrigere Ränge stärker berücksichtigt werden. 60 ist die übliche Wahl. Hier wurde 30 verwendet, um die Spitzenpositionen nicht zu stark zu reduzieren und damit dem Ranking auf Top 1 mehr Abstand zu verleihen (KI-Makrotraining Project 2026c).

Die Fusion der Retrievalsignale erfolgt über die Gewichtung der Reciprocal Rank Fusion (RRF) (KI-Makrotraining Project 2026c):

$$w_{\mathrm{BM25}} = 0.30 \qquad \text{und} \qquad w_{\mathrm{Exact}} = 0.70 \tag{6.6}$$

Die höhere Gewichtung von Exact Match gegenüber BM25 spiegelt die Priorität technischer Merkmale innerhalb der Maschinen- und Anlagenbau-Domäne wider.

6.4 Training des Learning-to-Rank-Modells

Das zentrale Element der Architektur ist das Learning-to-Rank-Modell. Hierfür wird der `LGBMRanker` der LightGBM-Bibliothek verwendet (KI-Makrotraining Project 2026g). Dieser basiert auf dem in Kapitel 2 beschriebenen LambdaRank-/LambdaMART-Prinzip.

Das Modell wird mit den Parametern

$$\text{objective} = \text{lambdarank} \qquad \text{und} \qquad \text{metric} = \text{ndcg} \tag{6.7}$$

trainiert (KI-Makrotraining Project 2026g).

Wie in Kapitel 5 beschrieben, werden Kandidaten einer Anfrage als gemeinsame Rankinggruppe betrachtet. Wiederholend entsteht für jede Anfrage eine Gruppe:

$$G_q = \{(q, c_1), (q, c_2), \ldots, (q, c_n)\} \tag{6.8}$$

mit der Anfrage q und den zugehörigen Makrokandidaten c_i.

Dadurch erlernt das Modell nicht die allgemeine Zugehörigkeit eines einzelnen Kandidaten zu einer Klasse. Stattdessen wird die optimale Kandidatenreihenfolge innerhalb derselben Anfrage gelernt. Ziel dabei ist es, dass der relevanteste Kandidat möglichst weit oben in der Rangliste erscheint.

Tabelle 6.3: Verwendete Hyperparameterkombinationen (KI-Makrotraining Project 2026g)

Parameter	**Wertebereich**
`n_estimators`	300, 500, 700
`learning_rate`	0.05, 0.04, 0.035
`num_leaves`	31, 63
`min_child_samples`	10, 20, 50
`lambdarank_truncation_level`	10, 20

Die Eingaben für das Modell sind die im Kapitel 5 beschriebenen Pairwise-Merkmale. Das Training erfolgt dabei ausschließlich auf den Trainingsdaten, während die Optimierung der Hyperparameter über die Validierungsdaten erfolgt (KI-Makrotraining Project 2026g).

6.5 Hyperparameteroptimierung

Die Leistungsfähigkeit eines Learning-to-Rank-Modells hängt von der Wahl der Hyperparameter ab. Deswegen erfolgt die Modellkonfiguration nicht manuell, sondern durch eine systematische Hyperparameteroptimierung. Dafür wird hier eine Grid-Search-basierte Strategie verwendet. Bei dieser werden verschiedene Kombinationen von Hyperparametern getestet und anhand der Ergebnisse der Validierung verglichen (KI-Makrotraining Project 2026g).

Die folgende Tabelle 6.3 zeigt die untersuchten Hyperparameterkombinationen:

Dabei sind die Hyperparameter wie folgt zu verstehen:

- **`n_estimators`:** Anzahl der aufgebauten Entscheidungsbäume im Modell. Mehr Bäume = komplexere Zusammenhänge, aber mehr Rechenaufwand.
- **`learning_rate`:** Lernrate pro Trainingsschritt. Kleinere Werte führen zu vorsichtigerem, aber stabileren Lernen.
- **`num_leaves`:** Maximale Anzahl der Blätter pro Baum. Mehr Blätter = komplexere Bäume, aber höheres Risiko für Overfitting.
- **`min_child_samples`:** Minimale Anzahl an Trainingsbeispielen in einem Blatt. Kleinere Werte = mehr Detailtreue pro Blatt, größere Werte = bessere Regularisierung (verhindert Overfitting).
- **`lambdarank_truncation_level`:** Begrenzung des Ranglistenbereichs, der durch LambdaRank optimiert werden soll (Top 10, Top 20).

Für jede Parameterkombination wird ein vollständiger Trainingsdurchlauf durchgeführt. Die Bewertung erfolgt anschließend auf dem Validierungsdatensatz. Das finale Modell wird auf Basis der Rankingqualität anhand der Validierungsdaten bestimmt (KI-Makrotraining Project 2026g).

Ablagestruktur im Laufverzeichnis:

```
run_directory/
|-- model/
|-- training/
|-- evaluation/
|-- summary/
\-- error_analysis/
```

Gespeicherte Modellartefakte:

- das trainierte LightGBM-Modell,
- die verwendeten Hyperparameter,
- die erzielten Validierungsmetriken,
- die verwendeten Featuredefinitionen,
- die Makrokandidatenprofile,
- Konfigurations- und Laufmetadaten.

Abbildung 6.2: Strukturierte Ablage der Modellartefakte im Laufverzeichnis.

Die verwendeten Bewertungsmetriken werden später in Kapitel 7 ausführlich beschrieben.

6.6 Modellartefakte und Reproduzierbarkeit

Ein wichtiges Ziel dieser Trainingspipeline besteht darin, die Trainingsabläufe reproduzierbar zu gestalten. Deswegen werden nach jedem Trainingslauf alle relevanten Artefakte gespeichert und dokumentiert (KI-Makrotraining Project 2026g). Abbildung 6.2 zeigt die zugehörige Ablagestruktur.

Dadurch lässt sich sicherstellen, dass jeder Trainingsablauf zu einem späteren Zeitpunkt vollständig nachvollzogen und reproduziert werden kann (KI-Makrotraining Project 2026g).

6.7 Pipeline-Orchestrierung

Die Ausführung der gesamten Pipeline erfolgt über eine zentrale Komponente, die die Orchestrierung übernimmt. Dadurch wird sichergestellt, dass alle Verarbeitungsschritte in der richtigen Reihenfolge ausgeführt werden (KI-Makrotraining Project 2026h).

Die folgende Reihenfolge der Schritte stellt den Ablauf der Pipeline dar. Diese können auch aus dem Architekturdiagramm in Abbildung 4.1 entnommen werden:

1. Datenaufbereitung
2. Qualitätsprüfung und Datenvalidierung
3. Datensplit
4. Berechnung der Retrievalsignale
5. Erstellung der Pairwise-Features
6. Training des Rankingmodells
7. Speicherung der Modellartefakte
8. Evaluation des trainierten Modells

Jeder Verarbeitungsschritt verwendet dabei die Artefakte des vorherigen Schrittes als Eingabe und erzeugt selbst Artefakte für den nächsten Schritt als Ausgabe. Dadurch wird ein konsistenter Datenfluss von den Roh-Daten bis zum trainierten Modell sichergestellt (KI-Makrotraining Project 2026h; KI-Makrotraining Project 2026n). ?

7 Evaluierungskonzept und Ergebnisse

7.1 Evaluationsdatensätze

Die Bewertung der Modelleistung erfolgt getrennt auf Trainings-, Validierungs- und Testdatensätzen. Diese Aufteilung wird im Rahmen des zuvor beschriebenen Kapitels 6 vorgenommen.

Der Testdatensatz wird erst nach der finalen Modellauswahl für die abschließenden Evaluierungen verwendet. Dadurch wird verhindert, dass Informationen aus dem Testdatensatz in die Optimierung des Modells einfließen und die Bewertung verfälschen.

Ein wichtiger Aspekt dabei ist die Behandlung von fachlich Zusammenhängenden Daten. Artikel die denselben Fingerprint besitzen, dürfen nur gemeinsam in einem Teil des Splits vorkommen. Ein Fingerprint repräsentiert die Struktur und die wesentlichen Merkmale eines Artikels, sodass Artikel mit demselben Fingerprint als fachlich zusammenhängend betrachtet werden.

Dadurch wird verhindert, dass nahezu ähnliche Beispiele gleichzeitig im Trainings- und Testdatensatz vorkommen.

7.2 Aufbau der Evaluations-Suite

Die Evaluation des Learning-To-Rank-Modells erfolgt automatisiert mithilfe der implementierten Evaluations-Suite (KI-Makrotraining Project 2026a).

Die Evaluationspipeline besteht dabei aus den in Tabelle 7.1 dargestellten vier Schritten. Abbildung 7.1 zeigt den zugehörigen sequentiellen Ablauf:

Die Ergebnisse dieser Pipeline werden strukturiert in den folgenden Verzeichnissen abgelegt:

- `evaluation/step_941_leakage_safety` für die Prüfung auf Zielinformations-Leakage
- `evaluation/step_942_retrieval_validation` für die Bewertung des Retrieval-Index

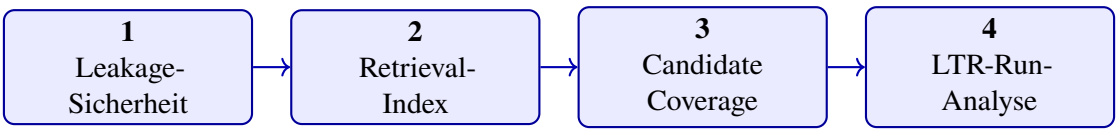


Abbildung 7.1: Sequentieller Ablauf der vierstufigen Evaluations-Suite.

Tabelle 7.1: Aufbau der Evaluations-Suite

Nr.	Skript	Zielsetzung
1	`step_941_validate_leakage_safety.py`	Prüfung auf Zielinformations-Leakage
2	`step_942_validate_retrieval_index.py`	Bewertung des Retrieval-Index
3	`step_943_analyze_candidate_coverage.py`	Analyse der Kandidatenabdeckung
4	`step_944_analyze_ltr_run.py`	Analyse des Learning-to-Rank-Modells

- `evaluation/step_943_candidate_coverage` für die Analyse der Kandidatenabdeckung
- `evaluation/step_944_ltr_run_analysis` für die Analyse des Learning-to-Rank-Modells

7.3 Verwendete Rankingmetriken

Bei einem Learning-To-Rank-Modell steht die Qualität der gesamten Rangliste im Vordergrund. Für vorliegende Aufgabe, ein EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) anhand eines oder mehrerer EPLAN-Artikel (EPLAN GmbH & Co. KG 2026b) zu finden, wurde mehrere komplementäre Rankingmetriken verwendet. Hierdurch lassen sich unterschiedliche Aspekte der Modellqualität wie Position des Ziel-Makros (EPLAN GmbH & Co. KG 2025), Erkennung fachlich verwandter Makros (EPLAN GmbH & Co. KG 2025) sowie die allgemeine Qualität der Rangfolge beurteilen.

Die Berechnung erfolgt innerhalb des Trainingsmoduls und der Evaluationspipeline (KI-Makrotraining Project 2026g; KI-Makrotraining Project 2026l).

7.3.1 Target Recall@k

Durch den Target Recall@k wird gemessen, ob sich das korrekte Ziel-Makro (EPLAN GmbH & Co. KG 2025) innerhalb der ersten k Elemente einer Rangliste befindet (Manning u. a. 2008).

Dieser berechnet sich wie folgt:

$$Recall@k = \frac{\#\text{Anfragen mit korrektem Ziel in Top-}k}{\#\text{Anfragen}} \tag{7.1}$$

mit

k Anzahl der betrachteten Top-Ränge der Rangliste
#Anfragen mit korrektem Ziel in Top-k Anzahl der Anfragen, bei denen das korrekte Ziel-Makro innerhalb der ersten k Ränge liegt
#Anfragen Gesamtzahl aller ausgewerteten Anfragen

Die Kennzahl gehört zu den grundlegenden Bewertungsmetriken des Information Retrievals (Manning u. a. 2008).

Der Wertebereich liegt zwischen 0 und 1. Ein Wert von $Recall@1 = 0.80$ bedeutet zum Beispiel, dass bei 80 % der Anfragen das korrekte EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) direkt auf Rang 1 liegt.

Folgenden Varianten werden im Projek verwendet:

- target_recall@1
- target_recall@3
- target_recall@5
- target_recall@10

Diese Metriken sind die wichtigsten Kennzahlen für die Beurteilung der Makrozuordnung.

7.3.2 Family Recall@k

Neben der Erkennung des exakten Ziel-Makros (EPLAN GmbH & Co. KG 2025) wird auch die Erkennung der korrekten Makro-Familie bewertet. Die Berechnung erfolgt analog zum Target Recall@k und basiert damit auf dem klassischen Recall-Konzept des Information Retrieval (Manning u. a. 2008). Der Unterschied liegt darin, dass jedes EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) als Treffer zählt, das in der gleichen Makro-Familie wie das Ziel-Makro (EPLAN GmbH & Co. KG 2025) vorkommt. Dadurch kann erkannt werden, ob das System die richtige Makro-Familie erkennt, auch wenn das exakte Ziel-Makro (EPLAN GmbH & Co. KG 2025) nicht in den Top-k-Ergebnissen enthalten ist.

Hierfür werden folgenden Ausprägungen verwendet:

- family_recall@1
- family_recall@3
- family_recall@5
- family_recall@10

Die Differenz zwischen dem Family Recall@k und dem Target Recall@k liefert einen Hinweis über die Variantenfehler innerhalb einer Makro-Familie.

7.3.3 Mean Reciprocal Rank

Der Mean Reciprocal Rank (MRR) zählt zu den etablierten Bewertungsmetriken des Information Retrievals und wird bis heute sowohl in klassischen Suchsystemen als auch in modernen Retrieval- und Rankingverfahren eingesetzt (Voorhees und Tice 1999; Zhu u. a. 2024).

Dieser berechnet sich wie folgt:

$$MRR = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{rank_i} \tag{7.2}$$

mit

N Anzahl der Anfragen
$rank_i$ Rangposition des korrekten Zielmakros für Anfrage i

Diese Metrik bevorzugt Platzierungen auf den ersten Rängen der Rangliste. Ein EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) auf Rang 1 trägt somit stärker zur MRR bei als ein EPLAN-Fenstermakro (EPLAN GmbH & Co. KG 2025) auf Rang 5.

Dadurch lässt sich die praktische Nutzbarkeit des Ranking-Systens besser bewerten.

7.3.4 Hierarchical nDCG

Für das vorliegende Projekt sind nicht alle Fehler gleich kritisch. Wenn zwei nahezu identische Makros verwechselt werden ist dies weniger schwerwiegend, als die Verwechslung von EPLAN-Fenstermakros (EPLAN GmbH & Co. KG 2025) aus unterschiedlichen Familien. Deswegen wird zur Bewertung eine hierarchische Bewertungsmetrik verwendet. Grundlage der Berechnung bildet die von Järvelin und Kekäläinen eingeführte Kennzahl Discounted Cumulative Gain (DCG) (2002).

Die Berechnung ergibt sich wie folgt:

$$DCG@k = \sum_{i=1}^{k} \frac{2^{rel_i} - 1}{\log_2(i+1)} \tag{7.3}$$

mit

k Anzahl der betrachteten Top-Ränge der Rangliste
i Rangposition innerhalb der Top-k-Ergebnisse
rel_i hierarchische Relevanz des Kandidaten auf Rangposition i

nDCG@k (normalized Discounted Cumulative Gain) ist die Erweiterung des DCG, die die Bewertung der Rangliste auf einen normierten Bereich [0,1] skaliert. nDCG zählt heute zu den wichtigsten Bewertungsmetriken für Ranking- und Suchsysteme (Järvelin und Kekäläinen 2002) und wird wie folgt berechnet:

$$nDCG@k = \frac{DCG@k}{IDCG@k} \tag{7.4}$$

mit

$DCG@k$ unnormierter Discounted-Cumulative-Gain-Wert der erzielten Rangliste
$IDCG@k$ Discounted-Cumulative-Gain-Wert der ideal sortierten Rangliste

Diese Metrik wird auch von dem verwendeten Lambda-Rank-Algorithmus genutzt (siehe Kapitel 6).

Für die vorliegende Anwendung wird die hierarchische Relevanz verwendet:

$$rel = \begin{cases} 3, & \text{exaktes Zielmakro} \\ 2, & \text{Makro derselben Familie} \\ 0, & \text{sonst} \end{cases} \tag{7.5}$$

Dadurch wird ein Ranking vorzugsweise verwendet, welches fachlich näher Alternativen auf den vorderen Positionen platziert.

In diesem Projekt werden die folgenen Metriken verwendet:

- hierarchical_ndcg@1
- hierarchical_ndcg@3
- hierarchical_ndcg@5
- hierarchical_ndcg@10

7.3.5 Bedeutung der Metriken innerhalb der Evaluation

Die Bewertungsmetriken bilden gemeinsam verschiedene Aspekte der Rankingqualität ab, wie in Tabelle 7.2 zusammengefasst.

Tabelle 7.2: Bedeutung der verwendeten Rankingmetriken

Metrik	Bewerteter Qualitätsaspekt
Target Recall@k	Position des exakten Ziel-Makros (EPLAN GmbH & Co. KG 2025)
Family Recall@k	Erkennung der korrekten Makrofamilie
MRR	Durchschnittlicher Zielrang
Hierarchical nDCG	Qualität der gesamten Rangfolge

7.4 Evaluation der Retrievalphase

Bevor die Qualität des Learning-to-Rank-Modells bewertet wird, muss untersucht werden, ob das korrekte Ziel-Makro (EPLAN GmbH & Co. KG 2025) überhaupt durch Retrievalkomponenten gefunden wird. Ein Rankingmodell kann ein Ziel-Makro (EPLAN GmbH & Co. KG 2025) nur dann korrekt platzieren, wenn es in der Kandidatenmenge vorhanden ist.

Deswegen erfolgt die Evaluation dieser Retrievalphase in einem getrennten Abschnitt.

Diese Analysen werden durch die Module `step_942_validate_retrieval_index.py` und `step_943_analyze_candidate_coverage.py` durchgeführt (KI-Makrotraining Project 2026j; KI-Makrotraining Project 2026k).

7.4.1 Bewertung des Retrieval-Index

Die Qualität des Retrievalindexes wird durch die erste Evaluationsstufe untersucht. Hierzu werden die Kandidatenlisten, die durch das Retrieval erzeugt werden, direkt ausgewertet. Dies erfolgt durch `step_942_validate_retrieval_index.py` (KI-Makrotraining Project 2026j).

Dabei werden folgende Kennzahlen berechnet:

- Target Recall@1
- Target Recall@10
- Target Recall@100
- Family Recall@1
- Family Recall@10
- Family Recall@100
- durchschnittlicher Zielrang
- Rangperzentile
- Anzahl nicht gefundener Zielmakros

Dadurch kann die grundsätzliche Leistungsfähigkeit der Retrievalkomponenten bewertet werden, um die Eignung der Kandidatenmenge für die nachfolgende Rankingphase zu beurteilen.

Target Recall@100 besitzt hier eine hohe Bedeutung. Wenn ein Ziel-Makro (EPLAN GmbH & Co. KG 2025) nicht unter den Top-100-Kandidaten gefunden wird, kann es durch das spätere Learning-to-Rank-Modell nicht korrekt platziert werden. Hierdurch wird dann die theoretische maximale Leistung des Learning-to-Rank-Modells festgelegt.

7.4.2 Candidate Coverage

Die Abdeckung der Kandidaten ist neben der Retrievalqualität ein weiterer wichtiger Faktor.

Die Analyse erfolgt dabei über `step_943_analyze_candidate_coverage.py` (KI-Makrotraining Project 2026k).

Dabei werden unterschiedliche Retrievalsignale darauf bewertet, wie gut das korrekte Ziel-Makro (EPLAN GmbH & Co. KG 2025) in der Kandidatenmenge aufgenommen wird.

Hierzu werden die einezelen Retrievalsignale getrennt voneinander analysiert:

- BM25
- Exact Match
- Reciprocal Rank Fusion
- kombinierte Retrievalvarianten

Für jede Variante wird dabei bewertet, wie oft das korrekte Ziel-Makro (EPLAN GmbH & Co. KG 2025) in den verschiedenen Kandidatenmengen enthalten ist.

Die Analyse erfolgt dabei für Top_{10}, Top_{50} und Top_{100} der Kandidaten.

Dadurch kann der Beitrag der einzelnen Retrievalkomponenten auf die Kandidatenmenge und der Einfluss der einzelnen Retrievalsignale auf die spätere Rankingqualität bewertet werden.

7.4.3 Interpretation der Retrievalergebnisse

Dies getrennte Evaluation ermöglicht es, Fehlklassifikationen in zwei Kategorien zu unterteilen:

1. Das korrekte Ziel-Makro (EPLAN GmbH & Co. KG 2025) ist nicht Bestandteil der Kandidatenmenge.
2. Das korrekte Ziel-Makro (EPLAN GmbH & Co. KG 2025) ist vorhanden, wird jedoch durch das Rankingmodell falsch eingeordnet.

Im ersten Fall liegt das Problem im Retrievalprozess. Das Rankingmodell kann somit das korrekte Ziel-Makro (EPLAN GmbH & Co. KG 2025) nicht finden. Im zweiten Fall liegt das Problem im Rankingprozess. Das korrekte Ziel-Makro (EPLAN GmbH & Co. KG 2025) ist zwar in der Kandidatenmenge enthalten, wird jedoch vom Learning-to-Rank-Modell nicht auf die vorderen Ränge eingeordnet.

Abbildung 7.2 veranschaulicht diese Unterscheidung der Fehlerquellen.

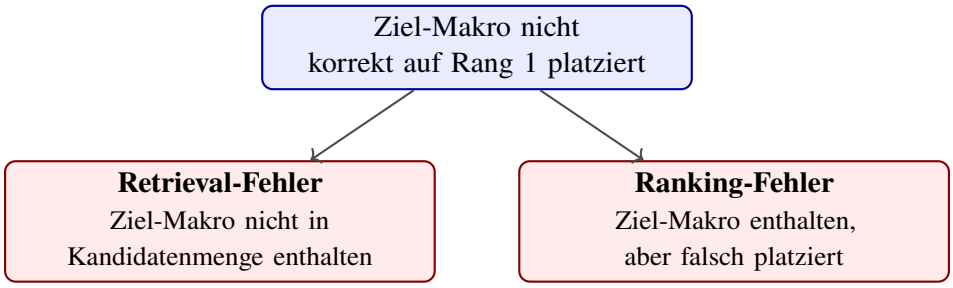


Abbildung 7.2: Unterscheidung der Fehlerquellen in Retrieval- und Rankingprozess.

Dadurch lassen sich die Fehlerquellen im Retrieval- und Rankingprozess voneinander unterscheiden und gezielt verbessern.

7.5 Leakage-Sicherheitsprüfung

Ein zentraler Bestandteil in der Evaluation ist eine Leakage-Sicherheitsprüfung auf Zielinformationen. Unter Leakage wird die unbeabsichtigte Nutzung von Informationen verstanden, die zum Zeitpunkt einer realen Vorhersage nicht verfügbar sein dürften und dadurch zu unrealistisch guten Modellergebnissen führen würden (Kaufman u. a. 2012). Da dieses System auf Artikel (EPLAN GmbH & Co. KG 2026b) - Makro (EPLAN GmbH & Co. KG 2025) -Zuordnungen trainiert wird, besteht das Risiko, das Informationen über das tatsächliche Ziel-Makro (EPLAN GmbH & Co. KG 2025) in die Trainings- und Evaluierungsdaten gelangen können und somit die Aussagekraft der verwendeten Evaluationsmetriken verfälscht wird.

Um dies zu vermeiden, enthält die Pipeline eine Leakage-Prüfung, die vor der eigentlichen Modellbewertung ausgeführt wird. Die Implementierung erfolgt in `step_941_validate_leakage_safety.py` (KI-Makrotraining Project 2026i).

7.5.1 Ziele der Leakage-Prüfung

Die Ziele der Leakage-Prüfung sind:

- Identifikation verbotener Zielinformationen innerhalb der Query-Daten
- Erkennung direkter Ziel-Makro (EPLAN GmbH & Co. KG 2025) -Referenzen
- Prüfung auf Familien- und Zielinformationen innerhalb von Eingangsmerkmalen
- Kontrolle der Kandidatenprofile
- Überprüfung der Datensplits auf Überschneidungen
- Sicherstellung der Trennung von Training, Validierung und Test

Somit wird sichergestellt, dass das Modelltraining nur mit den Informationen erfolgt, die später auch im Produktivbetrieb verfügbar sind.

7.5.2 Prüfung der Query-Daten

Die verwendete Query-Darstellung repräsentiert einen eingehenden Artikel (EPLAN GmbH & Co. KG 2026b) beziehungsweise die Informationen aus einem Datenblatt, die für eine Suchanfrage an das trainierte Modell wichtig sind.

Wichtig hierbei ist es, dass keine direkten Hinweise auf das Ziel-Makro (EPLAN GmbH & Co. KG 2025) in den Query-Daten enthalten sind, welche unmittelbar auf dieses verweisen können.

Deswegen untersucht die Leakage-Prüfung folgenden Punkte:

- Zielmakrokennungen
- Zielfamilieninformationen
- direkten Zielmakro-Tokens
- verbotenen Metadatenfeldern
- impliziten Zielhinweisen in den Featurevektoren

Sobald solche Informationen gefunden werden, wird der Lauf als Ungültig markiert.

7.5.3 Prüfung der Datensplits

Neben der Query-Prüfung erfolgt auch eine Prüfung des erzeugten Datensplits. Dabei wird überprüft, ob unerlaubte Überschneidungen zwischen Training, Validierung und Test vorhanden sind.

Dabei werden folgende Aspekte überprüft:

- Fingerprint-Gruppen
- Fenstermakrozuordnungen (EPLAN GmbH & Co. KG 2025)
- Kandidatenprofile
- technische Zusammenhangskomponenten
- gruppierte Artikelstrukturen

Das Ziel dieser Prüfung ist es, sicherzustellen, dass keine fachlich identischen Beispiele gleichzeitig in mehreren Datensplits vorhanden sind. Dadurch wird ein künstliche Modell-Verbesserung verhindert, die die Generalisierungsfähigkeit des Modells beeinträchtigen würde.

7.5.4 Prüfung der Kandidatenprofile

Ein weiterer Bereich der Prüfung betrifft die Makro-Kandidatenprofile (EPLAN GmbH & Co. KG 2025). Da diese Profile aus den Trainingsdaten entstehen, muss sichergestellt werden, dass keine Informationen aus den Validierungs- oder Testdaten in die Kandidatenprofile einfließen.

Deswegen werden sämtliche Profilinformationen auf ihre Herkunft geprüft, um sicherzustellen, dass ausschließlich Daten des Trainingssplits zur Erstellung der Kandidatenprofile verwendet werden (KI-Makrotraining Project 2026m).

7.5.5 Evaluierungsergebnis

Nach der Leakage-Prüfung wird ein struktruierter Sicherheitsbericht erstellt. Der Evaluationslauf gilt nur dann als bestanden, wenn keine Verstöße gegen die definierten Leakage-Regeln festgestellt wurden. Diese Basis bildet die Voraussetzung für die Interpretierbarkeit der nachfolgenden Rankingmetriken.

8 Diskussion, Grenzen und Ausblick

9 Zusammenfassung und Fazit

Erklärung zur Abschlussarbeit

Hiermit versichere ich, die eingereichte Abschlussarbeit selbständig verfasst und keine andere als die von mir angegebenen Quellen und Hilfsmittel benutzt zu haben. Wörtlich oder inhaltlich verwendete Quellen wurden entsprechend den anerkannten Regeln wissenschaftlichen Arbeitens zitiert. Ich erkläre weiterhin, dass die vorliegende Arbeit noch nicht anderweitig als Abschlussarbeit eingereicht wurde. Das Merkblatt zum Täuschungsverbot im Prüfungsverfahren der Hochschule Augsburg habe ich gelesen und zur Kenntnis genommen. Ich versichere, dass die von mir abgegebene Arbeit keinerlei Plagiate, Texte oder Bilder umfasst, die durch von mir beauftragte Dritte erstellt wurden.

Augsburg, den 4. September 2026

_____

Andreas Alstetter

Abbildungsverzeichnis

1.1 Grundidee der automatisierten Zuordnung von EPLAN-Artikeln zu EPLAN-Fenstermakros. 3

2.1 Zweistufiger Rankingansatz aus Candidate Generation und Learning-to-Rank. . . 4

3.1 Verzahnung von DSRM und ADR. Die DSRM bildet den übergeordneten Forschungsrahmen, während ADR als iterativer Entwicklungszyklus innerhalb der Phase „Design & Entwicklung des Artefakts“ eingesetzt wird. 14

4.1 Architektur der Trainings- und Rankingpipeline. 16

5.1 Verarbeitungsschritte von den Ausgangsdaten bis zum Trainingsformat. 23

6.1 Schematische Aufteilung der Trainings-, Validierungs- und Testdatenbasis. 26
6.2 Strukturierte Ablage der Modellartefakte im Laufverzeichnis. 29

7.1 Sequentieller Ablauf der vierstufigen Evaluations-Suite. 31
7.2 Unterscheidung der Fehlerquellen in Retrieval- und Rankingprozess. 38

Tabellenverzeichnis

5.1 Analysierte Merkmalsgruppen der EPLAN-Fenstermakros 18
5.2 Aufbereitete Merkmalsgruppen der EPLAN-Artikeldaten 19
5.3 Gruppen der Pairwise-Merkmale 21

6.1 Anforderungen an den idealen Datensatz (KI-Makrotraining Project 2026b; KI-Makrotraining Project 2026e; KI-Makrotraining Project 2026f) 25
6.2 Verwendete Retrievalsignale 26
6.3 Verwendete Hyperparameterkombinationen (KI-Makrotraining Project 2026g) . . 28

7.1 Aufbau der Evaluations-Suite 32
7.2 Bedeutung der verwendeten Rankingmetriken 36

Literaturverzeichnis

Baeza-Yates, Ricardo und Berthier Ribeiro-Neto (2011). *Modern Information Retrieval: The Concepts and Technology behind Search*. 2. Aufl. Addison-Wesley (siehe S. 6).

Bundesministerium für Wirtschaft und Energie (2026). *Wirtschaft und Forschung richten Plattform Industrie 4.0 auf industrielle KI aus*. Bundesministerium für Wirtschaft und Energie (siehe S. 2).

Burges, Christopher J. C. (2010). „From RankNet to LambdaRank to LambdaMART: An Overview“. In: *Microsoft Research Technical Report* (siehe S. 4, 9, 10).

Cormack, Gordon V., Charles L. A. Clarke und Stefan Büttcher (2009). „Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods“. In: *SIGIR 2009*, S. 758–759. DOI: 10.1145/1571941.1572114 (siehe S. 7, 8).

EPLAN GmbH & Co. KG (2025). *Makros*. EPLAN-Plattform Infoportal (siehe S. 2, 3, 12, 17–22, 26, 32–34, 36–39).

EPLAN GmbH & Co. KG (2026a). *Eplan, Software und Services für die Elektrokonstruktion*. https://www.eplan.com/de-de/. Zugegriffen am 02.09.2026 (siehe S. 2, 18).

EPLAN GmbH & Co. KG (2026b). *Artikelverwaltung*. EPLAN-Hilfe (siehe S. 2, 3, 12, 17, 18, 22, 26, 32, 38, 39).

Gao, Luyu, Zhuyun Dai und Jamie Callan (2021). „COIL: Revisit Exact Lexical Match in Information Retrieval with Contextualized Inverted List“. In: *Proceedings of NAACL-HLT 2021*, S. 3030–3042. DOI: 10.18653/v1/2021.naacl-main.241 (siehe S. 7).

Järvelin, Kalervo und Jaana Kekäläinen (2002). „Cumulated Gain-Based Evaluation of IR Techniques“. In: *ACM TOIS*. Bd. 20. 4, S. 422–446. DOI: 10.1145/582415.582418 (siehe S. 34, 35).

Joshi, Tripuresh, Bhavesh Joshi, Karimulla Syed, S. Vijayarani, Sandeep Kumar und Naveen Naval (2024). „Industrial data analysis using Machine Learning Techniques“. In: *2024 IEEE North Karnataka Subsection Flagship International Conference (NKCon)*. IEEE. DOI: 10.1109/NKCon62728.2024.10774728 (siehe S. 2).

Kabir, Md. Ahsanul, Mohammad Al Hasan, Aritra Mandal, Daniel Tunkelang und Zhe Wu (2024). „A Survey on E-Commerce Learning to Rank“. In: *Procedia Computer Science* (siehe S. 4, 11).

Kaufman, Shachar, Saharon Rosset und Claudia Perlich (2012). „Leakage in Data Mining: Formulation, Detection, and Avoidance“. In: *ACM Transactions on Knowledge Discovery from Data* 6.4. DOI: 10.1145/2382577.2382579 (siehe S. 38).

Liu, Tie-Yan (2009). „Learning to Rank for Information Retrieval“. In: *Foundations and Trends in Information Retrieval* 3.3, S. 225–331. DOI: 10.1561/1500000016 (siehe S. 4, 8).

Lyzhin, Ivan, Aleksei Ustimenko, Andrey Gulin und Liudmila Prokhorenkova (2023). „Which Tricks Are Important for Learning to Rank?“ In: *Proceedings of ICML* (siehe S. 10).

KI-Makrotraining Project (2026a). *Evaluation suite for Learning-to-Rank macro ranking*. Interner Projektquellcode (siehe S. 31).

KI-Makrotraining Project (2026b). *Ideal dataset selection from cleaned Current articles*. Interner Projektquellcode (siehe S. 24, 25).

KI-Makrotraining Project (2026c). *Pipeline step 640: Macro candidate retrieval*. Interner Projektquellcode (siehe S. 19, 20, 22, 25–27).

KI-Makrotraining Project (2026d). *Pipeline step 911: Raw EPLAN article XML parsing and data preparation*. Interner Projektquellcode (siehe S. 17, 18, 24).

KI-Makrotraining Project (2026e). *Pipeline step 913: Training data quality filtering and quarantine*. Interner Projektquellcode (siehe S. 24, 25).

KI-Makrotraining Project (2026f). *Pipeline step 921: Fingerprint-grouped train, validation, and test split*. Interner Projektquellcode (siehe S. 24, 25).

KI-Makrotraining Project (2026g). *Pipeline step 931: Learning-to-Rank macro ranker training*. Interner Projektquellcode (siehe S. 19–22, 26–29, 32).

KI-Makrotraining Project (2026h). *Pipeline step 936: Full macro-LTR training-run orchestration*. Interner Projektquellcode (siehe S. 29, 30).

KI-Makrotraining Project (2026i). *Pipeline step 941: Leakage safety validation for evaluation runs*. Interner Projektquellcode (siehe S. 38).

KI-Makrotraining Project (2026j). *Pipeline step 942: Retrieval index validation*. Interner Projektquellcode (siehe S. 36).

KI-Makrotraining Project (2026k). *Pipeline step 943: Candidate coverage analysis*. Interner Projektquellcode (siehe S. 36, 37).

KI-Makrotraining Project (2026l). *Pipeline step 944: Learning-to-Rank run analysis*. Interner Projektquellcode (siehe S. 32).

KI-Makrotraining Project (2026m). *Retrieval leakage guard for label-clean query and candidate data*. Interner Projektquellcode (siehe S. 22, 40).

KI-Makrotraining Project (2026n). *Training and ranking pipeline for EPLAN macros*. Interner Projektquellcode und Dokumentation, README.md und docs/PROJECT_DOCUMENTATION.md (siehe S. 15, 17, 30).

Manning, Christopher D., Prabhakar Raghavan und Hinrich Schütze (2008). *Introduction to Information Retrieval*. Cambridge University Press (siehe S. 6, 32, 33).

Nayak, Srikumar (2025). „Enhancing Manufacturing with Artificial Intelligence: An Overview of the Present Situation, Insights, Recommended Practices, Obstacles and Future Trends“. In: *World Journal of Advanced Research and Reviews* 28.3, S. 009–019. DOI: 10.30574/wjarr.2025.28.3.4033 (siehe S. 3).

Peffers, Ken, Tuure Tuunanen, Marcus A. Rothenberger und Samir Chatterjee (2007). „A Design Science Research Methodology for Information Systems Research“. In: *Journal of Management Information Systems* 24.3, S. 45–77. DOI: 10.2753/MIS0742-1222240302 (siehe S. 13).

Pfenning, Michael (2022). *Wie Maschinenbauer die Variantenvielfalt beherrschen* (siehe S. 2).

Robertson, Stephen und Hugo Zaragoza (2009). „The Probabilistic Relevance Framework: BM25 and Beyond“. In: *Foundations and Trends in Information Retrieval* 3.4, S. 333–389. DOI: 10.1561/1500000019 (siehe S. 4, 5).

Sein, Maung K., Ola Henfridsson, Sandeep Purao, Matti Rossi und Rikard Lindgren (2011). „Action Design Research“. In: *MIS Quarterly* 35.1, S. 37–56. DOI: 10.2307/23043488 (siehe S. 13).

Thakur, Nandan, Nils Reimers, Andreas Rücklé, Abhishek Srivastava und Iryna Gurevych (2021). „BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models“. In: *NeurIPS Datasets and Benchmarks* (siehe S. 6).

Voorhees, Ellen M. und Dawn M. Tice (1999). „The TREC-8 Question Answering Track Evaluation“. In: *Proceedings of the Eighth Text REtrieval Conference (TREC-8)*. DOI: 10.6028/NIST.SP.500-246.qa-overview (siehe S. 34).

Zhang, Yue, Chengcheng Hu, Yuqi Liu, Hui Fang und Jimmy Lin (2021). „Learning to Rank in the Age of Muppets: Effectiveness-Efficiency Tradeoffs in Multi-Stage Ranking“. In: *SustaiNLP 2021* (siehe S. 8).

Zheng, Kai, Haijun Zhao, Rui Huang, Beichuan Zhang, Na Mou, Yanan Niu, Yang Song, Hongning Wang und Kun Gai (2024). „Full Stage Learning to Rank: A Unified Framework for Multi-Stage Systems“. In: *WWW 2024* (siehe S. 8).

Zhu, Yutao, Huaying Yuan, Shuting Wang, Jiongnan Liu, Wenhan Liu, Chenlong Deng, Haonan Chen, Zheng Liu, Zhicheng Dou und Ji-Rong Wen (2024). „Large Language Models for Information Retrieval: A Survey“. In: *arXiv preprint arXiv:2308.07107* (siehe S. 34).